PEMBANGUNAN MODEL NEUROPROSTHESIS BICARA DENGAN ARSITEKTUR DUA TAHAP DAN *END-TO-END* BERBASIS *FOUNDATION MODEL*

Disusun sebagai syarat kelulusan mata kuliah
IF4091/Penulisan Proposal

Oleh

Muhammad Neo Cicero Koda

NIM : 13522108

PROGRAM STUDI TEKNIK INFORMATIKA

SEKOLAH TEKNIK ELEKTRO & INFORMATIKA

INSTITUT TEKNOLOGI BANDUNG

Desember 2025

PEMBANGUNAN MODEL NEUROPROSTHESIS BICARA DENGAN ARSITEKTUR DUA TAHAP DAN *END-TO-END* BERBASIS *FOUNDATION MODEL*

Laporan Proposal Tugas Akhir

Oleh

Muhammad Neo Cicero Koda

NIM : 13522108

Program Studi Teknik Informatika

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Bandung, 24 Desember 2025

Mengetahui,

Pembimbing I,	Pembimbing II,
Dessi Puji Lestari, S.T, M.Eng., Ph.D.	Prof. Dr.-Ing. Sakriani Sakti, S.T., M.Sc.
NIP. 197912012012122005	

DAFTAR ISI

BAB I PENDAHULUAN 7
I.1 Latar Belakang 7
I.2 Rumusan Masalah 9
I.3 Tujuan dan Ukuran Keberhasilan Pencapaian 10
I.4 Batasan Masalah 11
I.5 Metodologi 11
BAB II KAJIAN PUSTAKA 13
II.1 Brain Computer Interface (BCI) 13
II.1.1 Paradigma Komunikasi BCI 14
II.1.2 Metode Akuisisi Sinyal pada BCI 15
II.1.3 Elektrokortikografi (ECoG) 16
II.2 Pemrosesan Sinyal ECoG Menjadi Teks 18
II.2.1 Praproses Sinyal ECoG dan Ekstraksi Fitur 19
II.2.2 Pemetaan Fitur ECoG Menjadi Probabilitas Fonem 20
II.2.3 Pemetaan Fonem ke Teks 21
II.2.4 Metrik Evaluasi pada Dekode Sinyal ECoG ke Teks 22
II.3 Transformer 23
II.4 Foundation Model 25
II.4.1 Varian Arsitektur Foundation Model 26
II.4.2 Adaptasi Foundation Model untuk Modalitas Baru 27
II.4.3 Teknik Fine-Tuning Foundation Model 29
II.4.4 Optimasi Kecepatan Foundation Model 30
II.5 Penelitian Terkait 31
BAB III ANALISIS MASALAH DAN RANCANGAN SOLUSI 32
III.1 Analisis Masalah dan Solusi 32
III.2 Gambaran Umum Solusi 33
BAB IV RENCANA PELAKSANAAN 35
IV.1 Jadwal 35
IV.2 Risiko 36

DAFTAR GAMBAR

Gambar II.1 Contoh pemasangan alat BCI (https://changlab.ucsf.edu).....12
Gambar II.2 Contoh penempatan kisi ECoG untuk sistem neuroprosthesis bicara (Metzger et al., 2023).....16
Gambar II.3 Proses mendekode sinyal ECoG menjadi teks (Willett et al., 2023).16
Gambar II.4 Arsitektur Transformer (Vaswani et al., 2017).....22
Gambar III.1 Alur sistem neuroprosthesis bicara dengan arsitektur dua tahap (atas) dan E2E (bawah).....32

DAFTAR TABEL

Tabel II.1 Metrik Evaluasi Sistem Dekode Ucapan.....20
Tabel II.2 Perbandingan metode penyelarasan modalitas.....26
Tabel II.3 Perbandingan strategi fine-tuning pada Foundation Model 27
Tabel IV-1 Gantt Chart Pelaksanaan Tugas Akhir 33

BAB I

PENDAHULUAN

Bab Pendahuluan menjelaskan tentang landasan dan arah penelitian sebagai dasar pengerjaan tugas akhir. Penjelasan meliputi latar belakang (I.1), rumusan masalah (I.2), tujuan dan ukuran keberhasilan pencapaian (I.3), batasan masalah (I.4), dan metodologi (I.5).

I.1 Latar Belakang

Komunikasi verbal adalah kemampuan mendasar manusia yang memiliki peran penting dalam interaksi sosial dan ekspresi diri. Sayangnya, jutaan individu kehilangan kemampuan tersebut akibat gangguan neurologis seperti *amyotrophic lateral sclerosis* (ALS), stroke batang otak, dan cedera sumsum tulang belakang. Gangguan tersebut membuat mereka berada dalam kondisi *locked-in*, yaitu kondisi ketika seseorang tetap memiliki fungsi kognitif, tetapi menderita *anarthria* (ketidakmampuan berbicara) dan *quadriplegia* (kelumpuhan) (Moses et al., 2021; Metzger et al., 2023). Akibatnya, keterhubungan mereka ke dunia sosial hilang dan kualitas hidup mereka berkurang secara drastis (Silva et al., 2024).

Untuk menghadapi permasalahan ini, sistem *neuroprosthesis* bicara dapat menjadi solusi dengan mendekode upaya berbicara seseorang secara langsung dari sinyal otak (Silva et al., 2024). Meskipun terdapat alternatif komunikasi lain, seperti *eye tracking*, metode tersebut kurang alami dan memiliki kecepatan yang jauh lebih rendah daripada berbicara (Willett et al., 2023). Agar komunikasi dapat berlangsung secara efektif, cepat, dan intuitif, sinyal otak yang diakuisisi juga harus berkualitas tinggi. Metode akuisisi sinyal noninvasif, seperti elektroensefalografi (EEG), kurang cocok karena memiliki tingkat kebisingan tinggi (Shih et al., 2012). Di samping itu, terdapat metode invasif seperti elektrokortikografi (ECoG) yang memperoleh sinyal dari elektroda yang diletakkan secara langsung pada permukaan otak (Metzger et al., 2023). Ini lebih cocok untuk sistem *neuroprosthesis* bicara karena kemampuan mendekode kalimat kompleks (Silva et al., 2024).

Arsitektur *state-of-the-art* sistem *neuroprosthesis* bicara saat ini dikembangkan oleh beberapa peneliti, Willett et al. (2023) dan Seto et al. (2025), melalui dua tahap. Pada tahap pertama, sinyal mentah dari otak dikonversi menjadi probabilitas fonem. Selanjutnya, probabilitas fonem dikonversi menjadi kalimat yang koheren menggunakan model bahasa. Awalnya, Willett et al. (2023) menggunakan *recurrent neural network* (RNN) untuk dekode probabilitas fonem dan model bahasa *n-gram* untuk menghasilkan kalimat. Pendekatan ini terbukti berhasil dengan mencapai *word error rate* (WER) sebesar 17.4%. Metode kemudian dikembangkan oleh Seto et al. (2025) dengan mengganti model bahasa *n-gram* menjadi Transformer sehingga WER turun menjadi 16.9%.

Meskipun menghasilkan kinerja yang cukup baik, arsitektur dua tahap tersebut memiliki keterbatasan tersendiri. Pertama, tahap dekode fonem yang digunakan oleh Willett et al. (2023) dan Seto et al. (2025) masih menggunakan model RNN yang memiliki kemampuan terbatas dalam menangkap hubungan spasiotemporal dibandingkan model yang lebih canggih. Seto et al. (2025) mendapatkan *phoneme error rate* (PER) sebesar 19.2%. Artinya, masih terjadi satu kesalahan untuk setiap lima fonem yang ada pada kalimat. Kedua, jika terdapat kesalahan pada langkah pertama dekode fonem, kesalahan tersebut dapat terpropagasi ke langkah selanjutnya dan membuat model gagal mendekode kalimat yang koheren.

Arsitektur Transformer yang diperkenalkan oleh Vaswani et al. (2017) merupakan alternatif yang mampu menanggulangi hambatan pada model tradisional. Berbeda dengan RNN yang memproses data secara sekuensial, Transformer memanfaatkan mekanisme *self-attention* yang memungkinkan model untuk mengintegrasikan konteks dari keseluruhan *input* saat memproses suatu elemen. Arsitektur ini memiliki potensi untuk meningkatkan akurasi pada tahap dekode fonem dalam sistem *neuroprosthesis* bicara yang saat ini masih memanfaatkan RNN. Dengan optimasi ini, diharapkan kualitas probabilitas fonem yang dihasilkan menjadi lebih akurat.

Meskipun penggunaan Transformer dapat meningkatkan akurasi pada suatu modul, secara desain, arsitektur dua tahap memiliki kelemahan berupa propagasi kesalahan

(*error propagation*) (Hannun et al., 2014). Jika terjadi kesalahan pada langkah dekode fonem, kesalahan tersebut akan diteruskan ke langkah selanjutnya. Akibatnya, model bahasa gagal merekonstruksi kalimat yang koheren.

Sebagai alternatif untuk mencegah masalah *error propagation*, terdapat arsitektur *end-to-end* (E2E) yang langsung memetakan *input* menjadi *output* tanpa melalui representasi perantara yang terdefinisi secara manual (contohnya fonem). Salah satu cara untuk membangun arsitektur E2E adalah dengan melatih model Transformer dari nol (*from scratch*). Akan tetapi, cara ini sulit dilakukan karena keterbatasan dataset ECoG yang tersedia dan kebutuhan komputasi yang sangat besar. Solusi yang lebih efisien adalah dengan memanfaatkan Foundation Model (FM). FM, seperti Qwen, LLaMA, dan Gemma, dilatih menggunakan triliunan token dari berbagai bahasa sehingga memiliki pemahaman mendalam tentang struktur, sintaksis, dan semantik bahasa (Bommasani et al, 2021). Ini membuat mereka berpotensi untuk digunakan dalam sistem *neuroprosthesis* bicara.

Dengan mempertimbangkan kemampuannya untuk mempertimbangkan keseluruhan *input* dalam pemrosesan suatu token, Transformer menjadi alternatif yang berpotensi mengurangi kesalahan dekode dalam sistem *neuroprosthesis* bicara. Di sisi lain, perbaikan juga dapat dilakukan dengan mengganti arsitektur dua tahap secara total dengan pendekatan *end-to-end* untuk mengurangi *error propagation*. Kedua pendekatan ini akan dibandingkan untuk menentukan sistem yang memberikan kinerja terbaik. Harapannya, kemajuan yang dihasilkan dari penelitian ini dapat membantu memulihkan kemampuan komunikasi bagi individu yang menderita gangguan bicara akibat kondisi neurologis.

I.2 Rumusan Masalah

Sistem *neuroprosthesis* bicara *state-of-the-art* oleh Seto et al. (2025) saat ini memiliki dua kelemahan utama. Pertama, modul dekode fonem masih menggunakan arsitektur yang kurang optimal dalam menangkap hubungan temporal yang kompleks. Untuk menyelesaikan masalah ini, salah satu alternatif yang diajukan adalah mengganti RNN menjadi Transformer pada modul dekode

fonem arsitektur dua tahap. Kedua, arsitektur dua tahap berisiko mempropagasi kesalahan pada tahap dekode fonem ke bagian selanjutnya sehingga menyebabkan kegagalan dekode. Oleh karena itu, alternatif lain yang diajukan adalah melakukan transisi dari arsitektur dua tahap ke *end-to-end* berbasis Foundation Model untuk menghindari masalah *error propagation*. Untuk mengevaluasi efektivitas masing-masing alternatif, penelitian ini akan mengembangkan dan membandingkan kedua arsitektur dalam sistem *neuroprosthesis* bicara. Oleh karena itu, tugas akhir ini akan memiliki fokus penelitian pada permasalahan-permasalahan berikut:

1. Bagaimana merancang dan mengimplementasikan arsitektur dua tahap berbasis Transformer sebagai *decoder* fonem untuk sistem *neuroprosthesis* bicara?
2. Bagaimana arsitektur *end-to-end* (E2E) berbasis Foundation Model untuk sistem *neuroprosthesis* bicara?
3. Bagaimana perbandingan kinerja antara arsitektur dua tahap dan arsitektur *end-to-end* berbasis Foundation Model untuk sistem *neuroprosthesis* bicara?

I.3 Tujuan dan Ukuran Keberhasilan Pencapaian

Penelitian tugas akhir ini memiliki tujuan sebagai berikut.

1. Merancang dan mengimplementasikan arsitektur dua tahap berbasis Transformer sebagai *decoder* fonem dalam sistem *neuroprosthesis bicara*. Keberhasilan diukur dari kinerja sistem yang meningkat dari penelitian Seto et al. (2025).
2. Mengimplementasikan arsitektur *end-to-end* berbasis Foundation Model untuk sistem *neuroprosthesis* bicara. Keberhasilan diukur dari kinerja sistem yang meningkat dari penelitian Seto et al. (2025).
3. Menganalisis perbandingan kinerja antara arsitektur dua tahap berbasis Transformer sebagai *decoder* fonem dan arsitektur *end-to-end*. Ukuran keberhasilan berupa hasil analisis perbandingan antara kedua arsitektur.

I.4 Batasan Masalah

Pelaksanaan tugas akhir ini memiliki batasan masalah sebagai berikut.

1. Sistem *neuroprosthesis* bicara dirancang dan dievaluasi menggunakan data yang disediakan oleh Willett et al. (2023). Penelitian ini memanfaatkan data publik dan tidak menggunakan data yang direkam sendiri.
2. Kosakata yang digunakan terbatas pada daftar kata yang tersedia dalam dataset.

I.5 Metodologi

Metodologi penelitian ini akan mengadopsi alur kerja CRISP-DM. Berikut merupakan tahap-tahap yang dilalui untuk menyelesaikan penelitian pada tugas akhir.

1. Persiapan Data

   Akan dilakukan *preprocessing* seperti *resampling*, *filtering*, dan normalisasi dari dataset Willett et al. (2023). Setelah itu, format data akan diubah menjadi bentuk yang dapat diterima oleh model.

2. Perancangan dan Optimasi Arsitektur Dua Tahap dan End-to-End

   Pada tahap ini, arsitektur dua tahap dan E2E akan dirancang. Untuk arsitektur dua tahap, metode yang dipaparkan oleh Seto et al. (2025) akan ditiru, namun modul dekode fonem diganti dengan Transformer. Untuk arsitektur E2E, beberapa jenis Foundation Model *pretrained* akan dipilih dan sebagian dari parameternya akan dibekukan. Setelah itu, suatu modul proyeksi fitur akan dirancang dan dilatih untuk memetakan sinyal ECoG ke ruang *embedding* Foundation Model. Optimasi dilakukan dengan melatih/melakukan *fine-tuning* beberapa parameter model agar dapat memproses sinyal otak dengan lebih baik.

3. Evaluasi dan Analisis

   Arsitektur dua tahap dan *end-to-end* akan dievaluasi dengan data uji yang berbeda dengan data latih. Kinerja diukur menggunakan metrik *phone error rate* (PER), *word error rate* (WER), dan *character error rate* (CER). Perbandingan akan dilakukan untuk menentukan arsitektur yang memberikan kinerja tertinggi.

BAB II

KAJIAN PUSTAKA

Bab ini membahas tentang pustaka yang menjadi dasar pengembangan sistem *neuroprosthesis* bicara serta penelitian terkait.

II.1 Brain Computer Interface (BCI)

Brain-Computer Interface (BCI) adalah sistem yang membangun jalur komunikasi langsung antara otak dan perangkat eksternal sehingga melewati jalur neuromuskular konvensional tubuh (Moses et al., 2021; Shih et al., 2012). Teknologi ini penting bagi individu dengan gangguan neurologis berat yang mengalami kelumpuhan seperti *amyotrophic lateral sclerosis* (ALS), stroke batang otak, atau cedera sumsum tulang belakang tingkat tinggi (Beukelman et al., 2007; Moses et al., 2021). Kondisi seperti ALS ditandai dengan pelumpuhan progresif pada neuron motorik yang menyebabkan hilangnya kendali otot secara drastis. Pada tingkat lanjut, hal ini dapat mengakibatkan kondisi *locked-in*, yaitu kondisi ketika fungsi kognitif seseorang tetap utuh, tetapi kemampuan mereka untuk berbicara atau bergerak hilang sepenuhnya (Moses et al., 2021). Studi menunjukkan bahwa 80% hingga 95% individu dengan ALS pada akhirnya akan kehilangan kemampuan untuk mengeluarkan ucapan. Akibatnya, kualitas hidup mereka menurun secara drastis dan koneksi penderita dengan dunia sosial terputus (Beukelman et al., 2007). BCI menyediakan alternatif untuk memulihkan kemampuan dasar manusia ini dengan menciptakan saluran komunikasi yang tidak memerlukan kendali otot.

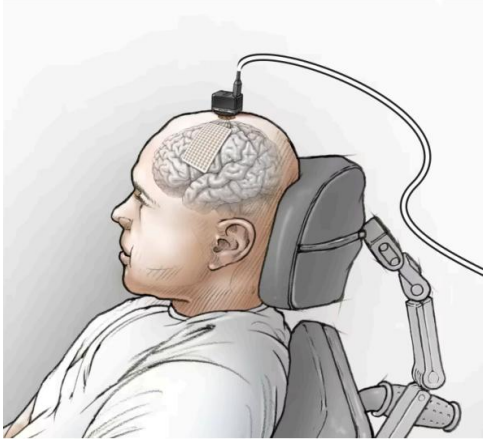

Gambar II.1 Contoh pemasangan alat BCI (https://changlab.ucsf.edu)

Perangkat *augmentative and alternative communication* (AAC) dapat merupakan alternatif, tetapi memiliki keterbatasan dan kendala tersendiri. Teknologi tersebut tetap memerlukan kemampuan mengontrol otot yang dapat menurun seiring berkembangnya tingkat keparahan penyakit (Moses et al., 2021). Lebih lanjut, perangkat ini seringkali lambat dan melelahkan dengan kecepatan komunikasi yang jauh di bawah kecepatan bicara rata-rata manusia, yaitu 160 kata per menit (Willett et al., 2023). Keterbatasan yang mencolok ini menciptakan kebutuhan yang jelas dan mendesak akan saluran komunikasi yang tidak hanya terpisah dari kontrol motorik, tetapi juga mampu mencapai *bandwidth* komunikasi yang lebih tinggi.

II.1.1 Paradigma Komunikasi BCI

Paradigma BCI memberikan definisi tentang aksi tertentu atau stimulus eksternal yang digunakan untuk menyandikan maksud pengguna menjadi sinyal otak yang dapat diproses. Secara historis, paradigma yang umum dan telah dipelajari dengan baik adalah *P300 speller* (Shih et al., 2012). Dalam sistem ini, pengguna disajikan dengan kisi-kisi karakter, dan seiring dengan adanya baris dan kolom yang berkedip secara berurutan, pengguna memfokuskan perhatian mereka pada karakter yang diinginkan. Pada kasus ini, BCI dilatih untuk mendeteksi gelombang otak yang dikenal sebagai peristiwa P300. P300 muncul dalam sinyal EEG sekitar 300 milisekon setelah pengguna menerima stimulus yang merupakan target pada tugasnya. Dalam hal ini, target tersebut merupakan kedipan karakter yang mereka

ingin eja (Shih et al., 2012). Dengan mengidentifikasi kedipan baris dan kolom mana yang memicu respon P300, sistem dapat menentukan karakter yang dipilih. Meskipun efektif, metode ini pada dasarnya bersifat serial dan memerlukan setiap karakter untuk dieja secara satu-persatu sehingga memperlambat *bandwidth* komunikasi.

Paradigma yang lebih maju bertujuan untuk mendekode langsung maksud motorik atau ucapan pengguna. Sistem ini mencoba menafsirkan perintah saraf yang terkait dengan tindakan yang diinginkan. Misalnya, pengguna mungkin membayangkan atau mencoba menggerakkan tangannya untuk mengontrol kursor. Sebagai contoh dalam *neuroprosthesis* bicara, pengguna membayangkan pengucapan kata atau kalimat (Moses et al., 2021). BCI dirancang untuk menerjemahkan pola aktivitas pada otak yang dihasilkan selama suatu tindakan dilakukan secara langsung menjadi perintah atau keluaran teks yang sesuai.

II.1.2 Metode Akuisisi Sinyal pada BCI

Sistem BCI dapat dikategorisasi berdasarkan metode akuisisi sinyalnya menjadi invasif atau non-invasif. Kedua pilihan ini memiliki *trade-off* antara keamanan dan kualitas sinyal.

Metode non-invasif, seperti elektroensefalografi (EEG), merekam aktivitas listrik otak dari elektroda yang dipasang di kulit kepala (Shih et al., 2012). EEG bersifat aman, relatif murah, dan portabel sehingga banyak digunakan dalam penelitian dan klinis. Namun, kegunaannya untuk BCI yang berkinerja tinggi sangat terbatas. Saat sinyal saraf bergerak dari korteks ke kulit kepala, sinyal tersebut dilemahkan dan dikaburkan secara spasial oleh lapisan di antaranya, terutama tengkorak. Hal ini menghasilkan *signal to noise ratio* (SNR) yang rendah, resolusi spasial yang buruk (berkisar beberapa sentimeter), dan kerentanan yang tinggi terhadap artefak dari aktivitas otot, seperti kedipan mata atau gerakan rahang (Schalk & Leuthardt, 2011).

Metode invasif digunakan untuk mengatasi keterbatasan ini. Elektrokortikografi (ECoG) adalah metode akuisisi sinyal yang dilakukan dengan meletakkan

serangkaian elektroda secara langsung ke permukaan otak melalui prosedur bedah. Elektroda umumnya diletakkan di ruang subdural di bawah dura mater (Schalk & Leuthardt, 2011). Prosedur bedah yang dilakukan bernama kraniotomi, prosedur yang membawa risiko seperti infeksi dan pendarahan. Namun, dengan menempatkan sensor di dekat sumber saraf, ECoG menghindari efek distorsi tengkorak. Hasilnya adalah sinyal dengan SNR yang jauh lebih unggul, resolusi spasial yang jauh lebih tinggi (dalam orde milimeter), dan *bandwidth* frekuensi yang lebih luas dibandingkan dengan EEG (Michel & Murray, 2011; Schalk & Leuthardt, 2011). Untuk tugas-tugas kompleks dan berkecepatan tinggi seperti mendekode sinyal saraf dari ucapan kalimat dengan kosakata beragam, kualitas sinyal yang ditawarkan oleh EEG umumnya tidak mencukupi. Oleh karena itu, kualitas data yang ditawarkan ECoG diperlukan untuk mampu melakukan dekode dengan kinerja tinggi.

II.1.3 Elektrokortikografi (ECoG)

ECoG merupakan jenis elektroensefalografi intrakranial yang merekam aktivitas listrik secara langsung dari permukaan korteks serebral (Metzger et al., 2023). Prosedur klinisnya melibatkan kraniotomi untuk menghasilkan bukaan sementara pada tengkorak dan membukakan dura mater, yaitu membran luar otak. Dura mater kemudian diiris untuk memperlihatkan permukaan kortikal. Serangkaian elektroda kemudian ditempatkan di ruang subdural otak (Schalk & Leuthardt, 2011).

Susunan elektroda tersebut biasanya dibentuk dari bahan yang bersifat biokompatibel, seperti karet silikon, yang dibubuhkan susunan elektroda cakram logam kecil yang terbuat dari paduan platinum-iridium atau *stainless steel* (Metzger et al., 2023). Pada sistem yang berkinerja tinggi, susunan yang dipakai umumnya berdensitas tinggi dan terdiri dari 253 hingga 256 elektroda dengan jarak antar pusat sebesar tiga hingga empat milimeter (Metzger et al., 2023). Sinyal saraf yang terekam ditransmisikan dari elektroda melalui kabel tipis yang disalurkan di bawah kulit menuju konektor pedestal perkutan yang dipasang secara edah pada tengkorak. Konektor ini berfungsi sebagai tempat pemasangan *headstage* digital untuk

melakukan digitalisasi dan transmisi data neural menuju komputer untuk pemrosesan (Metzger et al., 2023).

II.1.4 Mekanisme Neural dalam Produksi Ucapan

Produksi ucapan merupakan salah satu perilaku motorik paling kompleks yang dapat dilakukan manusia. Produksi ucapan memerlukan koordinasi yang tepat dan cepat untuk lebih dari 100 otot yang mengendalikan sistem pernapasan, laring, serta artikulator saluran vokal (bibir, lidah, rahang, dan velum). Tindakan motorik rumit ini diatur oleh jaringan kortikal yang tersebar luas, terutama di daerah lobus frontal, temporal, dan parietal di hemisfer dominan bahasa (yang umumnya merupakan hemisfer kiri).

Untuk keperluan BCI dalam ucapan, kisi ECoG diletakkan secara strategis di daerah kortikal yang memiliki peran penting dalam kontrol motorik dan artikulasi ucapan. Area penting di antaranya adalah *ventral sensorimotor cortex* (vSMC) yang mencakupi sebagian dari *precentral gyrus* dan *postcentral gyrus*. Daerah tersebut mengandung representasi neural dari muka, bibir, lidah, dan laring (Metzger et al., 2023). Daerah kritis lainnya di lobus frontal meliputi korteks premotor yang terlibat dalam merencanakan sekuens motorik. Selain itu, terdapat daerah seperti area Broca yang berperan dalam pemrosesan fonem dan sintaksis (Indefrey, 2011). Selain itu, area lobus temporal, khususnya *superior temporal gyrus* (STG), terlibat dalam memproses umpan balik suara selama ucapan. Pemrosesan ini penting untuk memantau dan membetulkan keluaran ucapan tersendiri (Moses et al., 2021). Area tersebut umum ditargetkan pada pemasangan elektroda ECoG, dengan susunan elektroda yang mencakup *precentral gyrus*, *postcentral gyrus*, *superior temporal gyrus*, serta *middle temporal gyrus* (Metzger et al., 2023; Willet et al., 2023). Pada sistem *neuroprosthesis* bicara milik Metzger et al. (2023), digunakan penempatan ECoG yang seperti pada Gambar II.2.

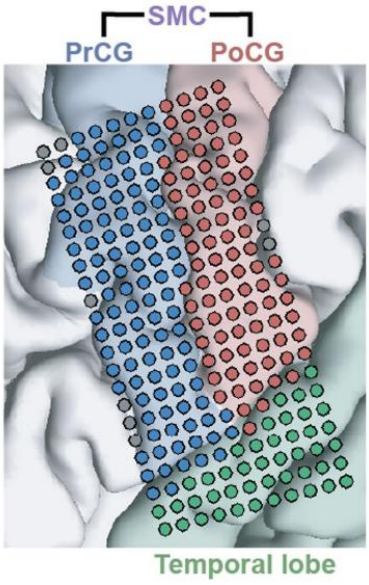

Gambar II.2 Contoh penempatan kisi ECoG untuk sistem *neuroprosthesis* bicara (Metzger et al., 2023)

II.2 Pemrosesan Sinyal ECoG Menjadi Teks

Bagian ini menjelaskan alur mendekode sinyal ECoG menjadi teks koheren sebagaimana dilakukan oleh Willett et al. (2023) pada Gambar III.3. Secara singkat, proses meliputi ekstraksi fitur neural, prediksi probabilitas fonem, dan konstruksi kalimat menggunakan prediksi probabilitas fonem dan model bahasa.

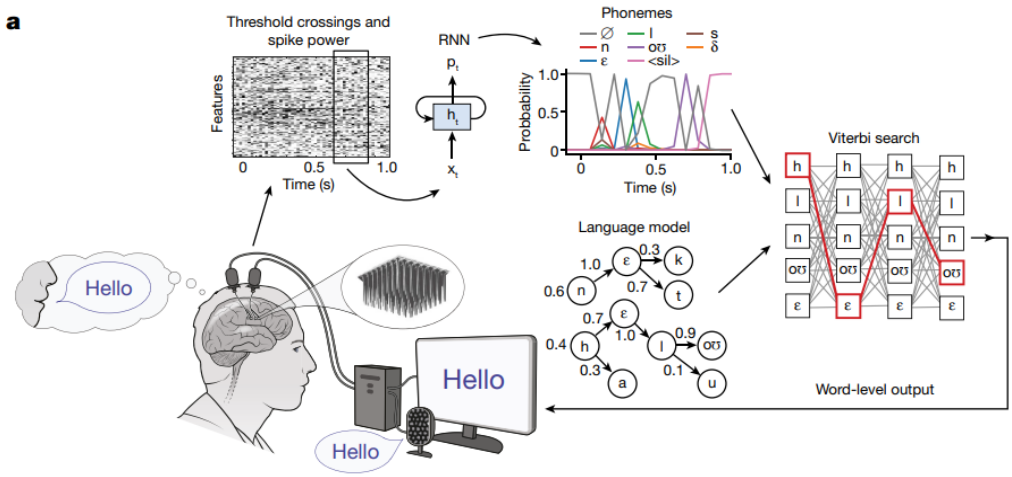

Gambar II.3 Proses mendekode sinyal ECoG menjadi teks (Willett et al., 2023)

II.2.1 Praproses Sinyal ECoG dan Ekstraksi Fitur

Sinyal ECoG mentah yang direkam dari susunan elektroda tidak diteruskan secara langsung ke model pembelajaran mesin. Sebelum itu, praproses dilakukan terlebih dahulu untuk menghilangkan *noise* dan mengekstraksi fitur yang lebih informatif tentang niat pengguna. Sinyal umumnya dikelompokkan menjadi jangka waktu yang pendek dan bertumpang-tindih terlebih dahulu. Proses pengelompokan ini dinamakan *temporal binning*. Pada referensi, rentang waktu suatu *bin* ditetapkan pada 20 ms (Metzger et al., 2023; Willett et al., 2023).

Langkah proposes meliputi beberapa langkah. Pertama, sinyal mentah disaring (*filter*) terlebih dahulu untuk mengisolasikan rentang filter tertentu. Sebagai contoh, filter *band-pass* berukuran 70 sampai dengan 200 Hz bertujuan untuk mengisolasi sinyal yang berada pada rentang frekuensi tersebut. Rentang ini biasa digunakan untuk mengisolasi *high-gamma activity* (HGA) dari sinyal, yaitu pola sinyal otak berpresisi spasiotemporal tinggi yang terasosiasi dengan aktivasi kortikal. Untuk setiap rentang waktu pendek, serangkaian fitur dikalkulasi untuk setiap elektroda.

Dua fitur yang umum digunakan pada tugas ini adalah *spike band power* dan *threshold crossings*. Fitur *spike band power* dihitung sebagai rata-rata dari nilai voltase yang dikuadratkan dari sinyal yang sudah difilter pada rentang waktu tertentu. Fitur ini merepresentasikan daya total aktivitas *spiking* yang terjadi secara lokal di dekat elektroda dan merupakan ukuran baik dari keterlibatan saraf (Willet et al., 2023). Fitur *threshold crossings* merupakan hitungan berapa kali sinyal tegangan yang telah difilter melintasi ambang batas negatif tertentu selama satu rentang waktu. Ambang waktu biasanya ditentukan secara relatif terhadap tingkat kebisingan dasar sinyal. Fitur ini berfungsi sebagai indikator untuk mendeteksi terjadinya potensial aksi dari populasi neural di sekitarnya (Willett et al., 2023).

Keluaran dari tahap ekstraksi fitur adalah matriks fitur dengan dimensi $T \times F$. Pada kasus ini, T adalah jumlah rentang waktu (*time bin*) yang dihasilkan dan F adalah total jumlah fitur yang dihasilkan.

II.2.2 Pemetaan Fitur ECoG Menjadi Probabilitas Fonem

Matriks fitur akan diteruskan ke suatu jaringan saraf buatan (*neural network*) berupa dekoder. Fungsi *neural network* adalah untuk mentranslasikan pola temporal dari fitur neural menjadi suatu representasi linguistik sementara.

Contoh arsitektur jaringan saraf buatan yang dipilih pada referensi, seperti yang dipilih oleh Metzger et al. (2023), adalah suatu *bidirectional recurrent neural network* (BiRNN). Suatu *recurrent neural network* (RNN) adalah jaringan saraf yang didesain secara spesifik untuk memodelkan data sekuensial dengan mempertahankan keadaan tersembunyi (*hidden state*) yang mengandung informasi dari waktu sebelumnya. Karakteristik *bidirectional* (dua arah) dari BiRNN berarti bahwa sekuens diproses secara maju dan mundur dalam segi waktu. Hal ini memungkinkan prediksinya pada waktu tertentu untuk diberikan konteks masa lalu dan masa depan. Hal ini berguna untuk mendekode ucapan karena representasi saraf dari suara dapat dipengaruhi oleh suara sebelumnya dan sesudahnya.

Alih-alih memprediksi kata secara langsung dari fitur neural, dekoder umumnya dilatih untuk memprediksi fonem, yaitu satuan mendasar dari suatu bahasa. Sebagai contoh, kata *cat* dalam Bahasa Inggris tersusun dari fonem /k/, /æ/, dan /t/. Pendekatan ini memiliki keunggulan dalam segi kompleksitas. Karena tidak memprediksi kata secara langsung dari ribuan kemungkinan kata, jumlah kelas yang dapat diprediksi, contohnya pada fonem Bahasa Inggris, hanya berjumlah 41. Hal ini mengurangi kompleksitas pelatihan secara signifikan. Fonem yang dihasilkan tersebut kemudian dapat digunakan untuk memprediksi kata.

Salah satu tantangan dalam proses dekode fonem adalah panjang sekuens fitur neural yang jauh lebih panjang daripada sekuens fonem yang dihasilkan. Selain itu, tidak terdapat penanda waktu yang dapat secara otomatis menyelaraskan fitur neural dengan sekuens fonem yang dihasilkan. Untuk menangani tantangan tersebut, dekoder dilatih dengan fungsi *loss* bernama *connectionist temporal classification* (Graves et al., 2006). CTC merupakan algoritma yang memungkinkan jaringan untuk dilatih pada pasangan sekuens yang belum

diselaraskan (*unaligned*). Untuk setiap rentang waktu, jaringan menghasilkan distribusi probabilitas untuk setiap kelas fonem dan kelas khusus (ε) yang merepresentasikan kosong (*blank*). Kelas ε tersebut memungkinkan model untuk menghasilkan keluaran ketika tidak ada fonem yang sedang dihasilkan. Kelas tersebut juga berguna untuk memisahkan fonem yang berulang.

Hasil akhir dari tahap ini adalah matriks probabilitas fonem yang berukuran $T \times C$. Pada kasus ini, T adalah jumlah langkah waktu dan C adalah jumlah kelas (39 fonem, satu token jeda, dan satu token kosong).

II.2.3 Pemetaan Fonem ke Teks

Matriks probabilitas fonem yang dihasilkan dari *decoder* ditranslasikan menjadi teks yang koheren dengan penggunaan model bahasa yang diintegrasikan dengan algoritma pencarian. Suatu *language model* atau model bahasa adalah model statistik yang menyediakan probabilitas rangkaian kata. Umumnya, hal tersebut dilakukan dengan memprediksi probabilitas kata selanjutnya jika diberikan kata-kata sebelumnya. Model bahasa yang digunakan pada bagian ini adalah Transformer, yaitu arsitektur modern berbasis jaringan saraf buatan yang menggunakan mekanisme *self-attention* untuk mempertimbangkan seluruh rangkaian kata sebelumnya untuk memprediksi kata selanjutnya (Vaswani et al., 2017). Hal ini memungkinkan mereka untuk menangkap hubungan jangka panjang dan memberikan pemahaman yang lebih mendalam terhadap sintaksis dan semantik teks.

Untuk menemukan urutan kata yang paling mungkin dari matriks probabilitas fonem, digunakan algoritma heuristik bernama *beam search*. Alih-alih melakukan pencarian terhadap semua calon kalimat (yang bersifat mahal secara komputasi), teknik *beam search* hanya mengeksplorasi k kalimat parsial yang paling memungkinkan pada setiap langkah proses dekode.

Untuk menyatukan hasil prediksi dari dekoder neural (model akustik) dengan model bahasa, teknik yang dapat dilakukan adalah *shallow fusion* (Metzger et al.,

2023). Pada setiap langkah pencarian, skor total calon kalimat dihitung dari penjumlahan berbobot antara probabilitas kedua model.

II.2.4 Metrik Evaluasi pada Dekode Sinyal ECoG ke Teks

Terdapat beberapa metrik evaluasi yang dapat digunakan untuk mengukur kinerja dekode sinyal ECoG ke Teks. Metrik tersebut dapat mengukur aspek akurasi maupun kecepatan. Daftar metrik yang dapat digunakan terlihat pada Tabel II.1.

Tabel II.1 Metrik Evaluasi Sistem Dekode Ucapan

Metrik	**Definisi**	**Deskripsi**
*Word Error Rate (*WER*)*	$(S + D + I) / N_{kata}$	Menghitung ketepatan dalam tingkat kata. Angka S, D, dan I masing-masing merupakan jumlah substitusi, penghapusan, dan penyisipan kata yang perlu dilakukan untuk menyamakan teks dengan referensi (Metzger et al., 2023).
Character Error Rate (CER)	$(S + D + I) / N_{huruf}$	Menghitung ketepatan dalam tingkat kata. Angka S, D, dan I masing-masing merupakan jumlah substitusi, penghapusan, dan penyisipan karakter yang perlu dilakukan untuk menyamakan teks dengan referensi (Metzger et al., 2023).
Phoneme Error Rate (PER)	$(S + D + I) / N_{fonem}$	Menghitung ketepatan dalam tingkat kata. Angka S, D, dan I masing-masing merupakan jumlah substitusi, penghapusan, dan penyisipan fonem

		yang perlu dilakukan untuk menyamakan teks dengan referensi (Willett et al., 2023).
Words per Minute (WPM)	($N_{kata\ yang\ didekode}$ / T)	Menghitung kecepatan komunikasi yang disediakan oleh BCI (Metzger et al., 2023).
Real-time Factor (RTF)	($T_{pemrosesan}$ / T_{audio})	Menghitung efisiensi komputasional sistem. Nilai RTF yang kurang dari 1.0 penting agar sistem dapat memproses informasi lebih cepat daripada laju informasi baru yang datang (Seto et al., 2025).

II.3 Transformer

Arsitektur Transformer diperkenalkan oleh Vaswani et al. (2017) sebagai alternatif dari model tradisional seperti RNN. Berbeda dengan RNN yang sulit mengingat informasi secara jangka panjang, Transformer memanfaatkan mekanisme *self-attention* yang memungkinkan model untuk mengintegrasikan konteks dari keseluruhan *input* secara sekaligus. Hal ini memberikan potensi bagi Transformer untuk menangkap hubungan spasiotemporal secara lebih optimal dibandingkan RNN. Selain itu, mekanisme *self-attention* memungkinkan Transformer untuk memproses *input* secara paralel, sedangkan RNN harus memproses *input* secara satu persatu. Hal ini memungkinkan pelatihan Transformer yang lebih efisien daripada RNN.

Mekanisme *self-attention* adalah komponen yang memungkinkan model memberikan tingkat kepentingan yang berbeda pada setiap token dalam *input* relatif terhadap elemen lainnya. Pertama, setiap vektor *input* diproyeksikan secara linier menjadi tiga vektor berbeda, yaitu *query* (Q), *key* (K), dan *value* (V). Skor *attention* dihitung dengan melakukan *dot product* antara vektor Q dari satu posisi token

dengan vektor K dari seluruh posisi lainnya. Hasil ini menentukan seberapa besar perhatian yang diberikan posisi saat ini ke posisi lainnya dalam *input*. Skor tersebut dibagi dengan akar kuadrat dari dimensi vektor untuk menjaga stabilitas gradien dan diproses melalui fungsi *softmax*. Hasilnya adalah matriks bobot probabilitas yang kemudian dikalikan dengan vektor V. Posisi dengan bobot tinggi akan memberikan lebih banyak informasi ke representasi akhir pada posisi tersebut.

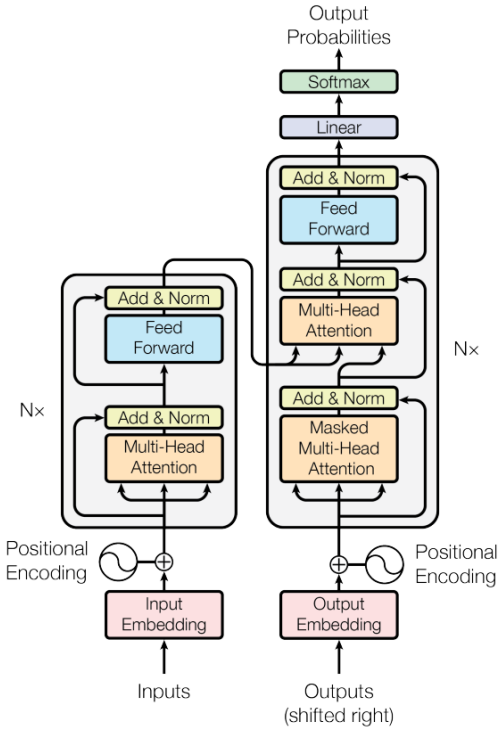

Gambar II.4 Arsitektur Transformer (Vaswani et al., 2017)

Secara *end-to-end*, arsitektur Transformer dapat dilihat pada Gambar II.4. Awalnya, Transformer memproses suatu *input* dengan mengubah *input* menjadi vektor berdimensi tinggi terlebih dahulu melalui matriks *embedding*. Setelah itu, karena Transformer tidak secara inheren memiliki informasi tentang letak token relatif terhadap token lainnya, *positional encoding* ditambahkan ke vektor *embedding* agar model dapat membedakan token yang sama pada posisi berbeda. Vektor yang telah memiliki informasi posisi masuk ke lapisan *multi-head attention* (MHA) yang melakukan operasi *self-attention* secara paralel untuk menangkap berbagai jenis hubungan antar token dalam urutan secara bersamaan. Setiap *head* mempelajari aspek hubungan yang berbeda dengan menggunakan proyeksi Q, K, dan V yang

berbeda. Setelah itu, *residual connection* dan normalisasi (*add & norm*) masing-masing digunakan untuk mempertahankan informasi awal suatu *token* sebelum *attention* dan untuk menjaga kestabilan distribusi nilai aktivasi. Keluaran dari lapisan MHA diproses oleh jaringan saraf *fully-connected* untuk memperdalam representasi fitur yang telah diekstraksi. Hasil dari *fully-connected* akan diproses kembali melalui lapisan linier dan *softmax* untuk mendapat prediksi akhir.

Transformer, pada awalnya, seperti yang dijelaskan oleh Vaswani et al. (2017), terdiri dari bagian *encoder* dan *decoder*. Bagian *encoder* berfungsi untuk memproses *input* sehingga menghasilkan representasi matematis darinya. Bagian *decoder* menghasilkan urutan *output* secara autoregresif dan menggunakan *masked self-attention* untuk mencegahnya dari melihat masa depan. Kedua komponen terhubung oleh mekanisme *cross-attention*. Pada mekanisme ini, *decoder* menggunakan *memory* dari *encoder* untuk melakukan penyelarasan antara urutan *output* yang sedang dihasilkan dengan informasi penting dari urutan *input*.

II.4 Foundation Model

Foundation Model (FM) adalah model yang dilatih dengan skala data yang sangat luas (umumnya menggunakan metode pembelajaran mandiri) sehingga dapat diadaptasi ke berbagai macam tugas hilir (*downstream tasks*) (Bommasani et al., 2021). Umumnya, Foundation Model memanfaatkan Transformer dalam arsitekturnya karena kemampuannya dalam menangkap dependensi jangka panjang. Terdapat beberapa sifat yang wajib dimiliki oleh FM. FM perlu mampu untuk menangkap distribusi data yang kompleks (*expressivity*), mengelola jumlah data dan parameter yang sangat besar secara efisien (*scalability*), menghubungkan berbagai jenis modalitas (*multimodality*), menyimpan pengetahuan dalam jangka waktu panjang (*memory capacity*), dan melakukan generalisasi ke konteks dan tugas baru (*compositionality*) (Bommasani et al., 2021). Sifat-sifat tersebut memungkinkan FM untuk memanfaatkan pengetahuan mendalamnya yang diperoleh dari triliunan token data latih untuk melakukan generalisasi pada modalitas baru.

II.4.1 Varian Arsitektur Foundation Model

Variasi arsitektur FM secara umum dapat dikategorikan berdasarkan konfigurasi blok Transformer dan tujuan pelatihannya. Arsitektur *encoder-only*, seperti BERT dan RoBERTa, dirancang utamanya untuk tugas pemahaman bahasa (*natural language understanding*) melalui mekanisme *masked language modeling* (MLM). Dalam mekanisme MLM, sebagian token dalam urutan *input* disembunyikan (*masking*) dan model dilatih untuk memprediksi kembali token tersebut dengan mempertimbangkan konteks kata-kata di sekitarnya (Devlin et al., 2019). Arsitektur ini sangat efektif untuk menangkap hubungan struktural yang mendalam, tetapi kurang optimal dalam menghasilkan urutan teks yang panjang dan mengalir.

Terdapat juga arsitektur *encoder-decoder* seperti T5 dan BART. Bagian *encoder* berfungsi mengekstraksi representasi kontekstual dari *input*, sementara bagian *decoder* memanfaatkan representasi tersebut melalui mekanisme *cross-attention* untuk menghasilkan teks target secara bertahap.(Raffel et al., 2020). Meskipun arsitektur ini unggul dalam tugas *sequence-to-sequence* seperti translasi, keberadaan dua blok terpisah menciptakan kompleksitas tambahan dalam penyelarasan modalitas baru serta potensi adanya hambatan informasi (*information bottleneck*) pada bagian *cross-attention*.

Terakhir, ada arsitektur *decoder-only* yang telah menjadi paradigma umum untuk model generatif skala besar seperti seri GPT, LLaMA, Qwen, dan Gemma. Model dalam kategori ini berfokus pada pembangkitan teks melalui pemodelan bahasa autoregresif, yaitu memprediksi token selanjutnya berdasarkan urutan prediksi token sebelumnya. Kemampuan ini membuatnya cocok untuk tugas generatif, seperti mendekode kalimat dari sinyal ECoG.

Terdapat berbagai varian model *decoder-only* yang masing-masing memiliki perbedaan teknis dalam komponen internalnya.

- **LLaMA:** LLaMA merupakan keluarga model bahasa *open source* yang dikembangkan oleh Meta AI (Touvron et al., 2023). LlaMA meningkatkan ekspresivitas model dengan fungsi aktivasi SwiGLU dan stabilitas

menggunakan *root mean square layer normalization* (RMSNorm). LLaMA memanfaatkan *rotary positional embeddings* (RoPE) yang menyuntikkan informasi posisi melalui rotasi vektor untuk mempertahankan dependensi temporal dari suatu *input* sekuensial.

- **Qwen:** Qwen adalah seri *large language models* yang dikembangkan oleh Alibaba Cloud dan dirancang untuk memiliki kemampuan pemrosesan bahasa yang kuat serta fleksibilitas multimodal (Bai et al., 2023). Qwen dikembangkan dengan fokus penyelarasan multimodal sejak awal tahap pemrosesan. Arsitektur ini mengintegrasikan fitur sensorik sebagai bagian dari *hidden state* melalui lapisan *adapter* khusus untuk memetakan modalitas baru ke representasi linguistik model.

- **Gemma:** Gemma merupakan keluarga model yang dibangun oleh Google DeepMind (Gemma Team, 2024). Gemma dioptimasi untuk efisiensi memori melalui *weight tying* yang menggunakan satu matriks bobot tunggal untuk lapisan *input* dan *output* untuk membuang redundansi parameter. Selain itu, Gemma juga menggunakan teknik *grouped query attention* (GQA) yang mengelompokkan beberapa *query head* untuk *key* dan *value* yang sama agar mengurangi beban memori.

II.4.2 Adaptasi Foundation Model untuk Modalitas Baru

Untuk mengintegrasikan jenis *modality* baru ke Foundation Model yang umumnya berbasis teks, diperlukan sebuah mekanisme penyelarasan (*alignment*). Terdapat berbagai variasi metode penyelarasan yang dapat digunakan dan masing-masing memiliki karakteristik yang berbeda sebagaimana dirangkum dalam Tabel II.2.

Tabel II.2 Perbandingan metode penyelarasan modalitas

Metode	Referensi	Cara Kerja

Matriks proyeksi linier	Liu et al., 2023	Mengalikan fitur *input* dengan matriks bobot (*W*) untuk mengubah dimensi fitur modalitas agar sesuai dengan dimensi *embedding* FM
Adapter MLP	Bai et al., 2023	Menggunakan beberapa lapisan *fully-connected* dengan fungsi aktivasi *nonlinier* untuk menangkap hubungan fitur yang lebih kompleks
Q-Former	Li et al., 2023	Menggunakan arsitektur Transformer kecil yang berisi *learnable queries* untuk mengekstraksi informasi paling relevan dari *input*
Cross-Attention	Alayrac et al., 2022	Menyuntikkan informasi modalitas baru langsung ke dalam lapisan-lapisan Transformer FM melalui mekanisme *attention* tambahan
Tokenisasi Diskrit	Oord et al., 2017	Menggunakan model untuk mengelompokkan pola sinyal otak menjadi ID *token* tertentu.

Setiap metode memiliki *trade-off* antara efisiensi komputasi dan kapasitas representasi model. Matriks proyeksi linier merupakan metode paling efisien karena hanya melibatkan satu operasi perkalian matriks, tetapi terbatas untuk menangkap hubungan yang nonlinier. Adapter MLP mampu memodelkan hubungan fitur yang lebih dalam dibandingkan dengan proyeksi linier melalui fungsi aktivasi nonlinier, namun memiliki beban komputasi lebih tinggi. Q-Former efektif dalam mereduksi *input* yang besar menjadi *embedding* ringkas, namun meningkatkan waktu pelatihan dan inferensi karena menggunakan Transformer. Cross-Attention memiliki cara kerja yang berbeda dengan menyuntikkan informasi di berbagai lapisan FM secara langsung, namun memerlukan modifikasi pada arsitektur FM. Terakhir, tokenisasi diskrit memungkinkan model untuk menggunakan kosakata khusus untuk sinyal otak, namun proses kuantisasi sinyal berisiko menghilangkan detail informasi mikro dari sinyal.

II.4.3 Teknik Fine-Tuning Foundation Model

Proses *fine-tuning* dilakukan untuk mengadaptasi Foundation Model terhadap tugas baru. Mengingat besarnya jumlah parameter pada FM, melakukan pelatihan ulang pada seluruh parameter model seringkali tidak praktis karena kebutuhan sumber daya komputasi yang sangat besar dan risiko degradasi pengetahuan yang sudah ada. Oleh karena itu, dikembangkan strategi *parameter-efficient fine tuning* (PEFT) yang memungkinkan adaptasi model ke tugas baru dengan hanya melatih sebagian kecil parameter. Karakteristik dari berbagai model PEFT dirangkum dalam Tabel II.3 (Ding et al., 2023).

Tabel II.3 Perbandingan strategi *fine-tuning* pada Foundation Model

Metode	**Kenaikan Latensi**	**% Parameter Dilatih**	**Kemudahan**	**Efektivitas Adaptasi**
Full-fine tuning	Tidak ada	100%	Rendah (butuh banyak GPU)	Tinggi, namun sangat berisiko *catastrophic forgetting*
Adapters	Ya (karena lapisan ekstra)	~1-3%	Menengah	Tinggi
Prompt Tuning	Tidak ada	< 0.1%	Rendah (tidak stabil)	Rendah
LoRA	Tidak ada	~0.1-1%	Tinggi dan Stabil	Sangat tinggi, hampir setara dengan *full-finetuning*

Meskipun memberikan efektivitas yang tinggi, metode *full-fine tuning* sangat memerlukan ketersediaan perangkat keras yang tinggi untuk menyimpan gradien seluruh parameter model. Terdapat juga risiko *catastrophic forgetting*, yaitu ketika model kehilangan kemampuan linguistik generiknya karena seluruh bobotnya dimodifikasi. Metode *adapter* merupakan metode pelatihan yang lebih efisien, namun menyisipkan lapisan fisik yang menyebabkan kenaikan latensi saat inferensi. Strategi *prompt tuning* hanya melatih vektor *embedding* tambahan pada

bagian *input* tanpa mengubah parameter model. Meskipun efisien, metode ini seringkali tidak stabil, terutama untuk tugas kompleks. Terakhir, LoRA bekerja dengan melatih matriks *low-rank* pada beberapa lapisan, lalu menggabungkan hasil matriks ke bobot asli setelah pelatihan. Metode ini memiliki efektivitas yang hampir setara dengan *full-fine tuning*, namun dengan kebutuhan parameter yang sangat kecil dan tanpa menyebabkan kenaikan latensi.

II.4.4 Optimasi Kecepatan Foundation Model

Implementasi Foundation Model pada sistem *neuroprosthesis* bicara memerlukan kinerja yang tinggi dengan latensi minimal agar komunikasi dapat berlangsung secara alami. Mengingat besarnya parameter model, diperlukan teknik optimasi setelah pelatihan untuk mempercepat fase inferensi tanpa mengurangi akurasi secara drastis. Berikut merupakan metode optimasi yang umum dilakukan.

- **Kuantisasi:** Kuantisasi atau *quantization* bekerja dengan mengonversi nilai bobot yang berpresisi tinggi, seperti *floating point 16-bit*, ke presisi yang lebih rendah, seperti *4-bit* atau *8-bit*. Teknik ini mengurangi penggunaan memori dan mempercepat operasi matematika, namun dapat sedikit menurunkan akurasi model.

- **Pemangkasan:** Pemangkasan (*pruning*) dilakukan dengan mengidentifikasi dan menghapuskan bobot dalam matriks yang memiliki nilai mendekati nol atau berkontribusi minimal terhadap *output*. Hal ini membuat jumlah operasi perkalian berkurang secara signifikan, namun diperlukan *hardware* khusus untuk memberikan kenaikan kecepatan yang signifikan.

- **KV *Caching*:** Teknik KV *caching* dilakukan dengan menyimpan vektor K dan V dari token-token sebelumnya di dalam memori agar tidak perlu dihitung ulang pada setiap langkah pembangkitan kata baru.

II.5 Penelitian Terkait

Saat ini penelitian dalam sistem *neuroprosthesis* bicara telah mengalami perkembangan. Willett et al. (2023) telah mengimplementasi sistem *neuroprosthesis* bicara dua tahap dengan RNN sebagai modul dekode fonem dan model bahasa trigram. Sistem ini mampu mendapatkan WER sebesar 17.4% dan kecepatan 62 kata per menit. Setelah itu, Seto et al. (2025) mengembangkan sistem tersebut dengan fokus pada model bahasa. Dengan menggantikan model trigram dengan Transformer, khususnya LLaMA 2, ia berhasil menurunkan WER menjadi 16.9%. Namun, hingga saat ini, modul dekode fonem dalam sistem tersebut masih mengandalkan arsitektur berbasis RNN dan belum ada penelitian yang memanfaatkan Transformer sebagai alternatifnya yang lebih mampu menangkap dependensi jangka panjang.

Dari sisi penggunaan Foundation Model, paradigma ini sebenarnya telah terbukti sangat sukses pada berbagai modalitas, seperti gambar, bahasa, dan suara. Akan tetapi, pemanfaatan FM dalam domain sinyal otak masih sangat terbatas. Sebagian besar riset terkait Foundation Model untuk BCI saat ini difokuskan pada sinyal EEG yang bersifat noninvasif. Selain itu, fokus penelitian tersebut umumnya tidak memanfaatkan FM berbasis teks untuk *downstream tasks*, tetapi membangun FM yang dilatih khusus dengan sinyal otak, seperti LaBraM dan CBraMod (Jiang et al., 2024; Wang et al., 2025). Oleh karena itu, penggunaan Foundation Model untuk mendekode kalimat dari sinyal ECoG secara *end-to-end* masih menjadi celah penelitian.

Berdasarkan penelitian terkait tersebut, terdapat dua celah utama yang diangkat dalam penelitian ini. Pertama, belum ada penggunaan arsitektur Transformer sebagai pengganti RNN untuk memetakan sinyal neural ECoG secara langsung menjadi probabilitas fonem. Kedua, belum ada sistem yang memanfaatkan Foundation Model untuk melakukan dekode kalimat dari sinyal ECoG secara *end-to-end*.

BAB III

ANALISIS MASALAH DAN RANCANGAN SOLUSI

Bab ini membahas tentang permasalahan yang dapat muncul selama penelitian serta usulan solusinya.

III.1 Analisis Masalah dan Solusi

Penelitian ini bertujuan untuk membangun sistem *neuroprosthesis* bicara dengan arsitektur dua tahap dan E2E berbasis Foundation Model, lalu membandingkan kinerja kedua pendekatan. Agar tujuan dapat tercapai, terdapat beberapa tantangan dan ketidakpastian yang perlu ditangani.

1. Pemilihan Arsitektur Foundation Model

   Setiap model FM memiliki perbedaan dari sisi arsitektur, ukuran, dan kemampuan pemrosesan linguistik. Masalah utama yang dihadapi adalah menentukan model yang tidak hanya mampu melakukan dekode secara efektif, tetapi juga memproses sinyal dalam waktu yang wajar. Berbagai jenis FM akan dilatih dan diuji untuk menentukan model terbaik. Model utama yang dipilih adalah LLaMA, Qwen, dan Gemma karena ketiganya merupakan varian yang paling sering dipakai untuk berbagai tugas, dikembangkan oleh organisasi terbesar saat ini, serta memiliki dukungan komunitas yang paling banyak. Untuk setiap model, akan dicoba variasi ukuran berbeda-beda sehingga dapat ditentukan model yang memiliki keseimbangan terbaik antara akurasi dan kecepatan.

2. Adaptasi Model terhadap Jenis Input Baru

   FM mampu memproses berbagai jenis modalitas, seperti teks, suara, bahkan gambar, namun belum dapat memproses sinyal ECoG. Perlu ditentukan pendekatan paling optimal untuk mengubah sinyal ECoG menjadi bentuk yang dapat dipahami model. Mengingat kompleksitas dan ukuran FM yang besar,

perlu juga ditentukan metode pelatihan efisien yang dapat mengajarkan model tentang cara memproses sinyal ECoG.

Tabel II.2 memaparkan beberapa alternatif agar FM mampu menerima ECoG sebagai *input*. Dari beberapa alternatif yang ada, dipilih matriks proyeksi linier karena efisiensi komputasi dan jumlah parameter tambahan yang minimal, tetapi alternatif lain mungkin dicoba jika pendekatan ini kurang efektif. Modul ini mengubah dimensi dari sinyal kontinu ECoG menjadi serangkaian vektor yang dapat diterima oleh ruang *embedding* FM.

Tabel II.3 memberikan alternatif untuk melakukan *fine-tuning* pada FM agar mampu memproses sinyal ECoG secara efektif (Ding et al., 2023). Dari alternatif yang ada, LoRA dipilih karena mampu melakukan adaptasi model besar tanpa menambah latensi inferensi.

3. Latensi Inferensi dan Beban Komputasi

   Idealnya, sistem *neuroprosthesis* bicara mampu bekerja secara *real-time* agar komunikasi bersifat alami. Namun, arsitektur Foundation Model memiliki beban komputasi dan latensi inferensi yang besar. Tantangannya adalah merancang arsitektur yang mampu mempertahankan latensi inferensi dalam batas wajar tanpa mengorbankan akurasi. Teknik seperti *pruning* parameter saat inferensi dan kuantisasi bobot menjadi bentuk 4 bit atau 8 bit dapat mengurangi ukuran dan beban komputasi.

III.2 Gambaran Umum Solusi

Gambar 3.1 memperlihatkan alur pemrosesan sistem *neuroprosthesis* bicara untuk arsitektur dua tahap dan E2E. Keduanya dimulai dari *input* berupa fitur neural yang berasal dari aktivitas otak partisipan T12 yang direkam oleh Willett et al. (2023). Sinyal ECoG direkam melalui empat *array* subdural yang masing-masing memiliki 64 elektroda. Dataset ini mencakup berbagai variabel yang diselaraskan per *time step* (20 ms), seperti daya *spike band* (*spikePow*) dan *threshold crossings* (*tx1* hingga *tx4*), serta fitur audio, seperti *envelope* audio dan MFCC.

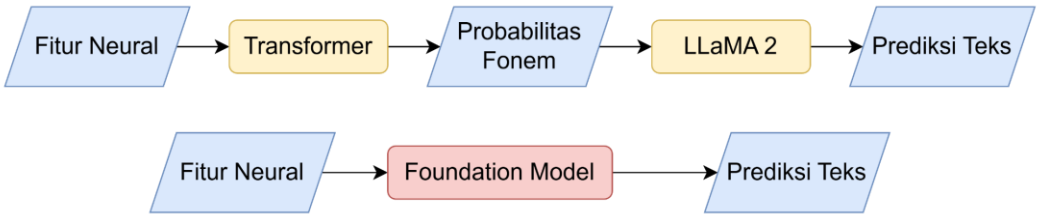

Gambar III.1 Alur sistem *neuroprosthesis* bicara dengan arsitektur dua tahap (atas) dan E2E (bawah)

Di diagram atas Gambar 3.1, kotak berwarna kuning merepresentasikan alur pemrosesan pada arsitektur dua tahap. Pada langkah pertama, digunakan Transformer untuk memetakan fitur neural menjadi probabilitas fonem dengan *connectionist temporal classification* sebagai fungsi *loss*. Setelah itu, model bahasa LLaMA 2 digunakan untuk mengubah fonem menjadi teks (Seto et al., 2025). Teks dihasilkan melalui algoritma *beam search* dengan *shallow fusion* yang menggabungkan skor akustik probabilitas fonem dan skor linguistik model bahasa (Seto et al., 2025).

Di diagram bawah Gambar 3.1, kotak berwarna merah merepresentasikan modul yang baru akan dikembangkan pada penelitian ini. Seperti penjelasan sebelumnya, berbagai variasi tipe dan ukuran FM akan dilatih untuk mengetahui jenis FM yang terbaik. Modul akan dibuat mampu memproses sinyal ECoG melalui matriks proyeksi fitur dan diadaptasi untuk dapat memproses sinyal ECoG dengan LoRA.

Setelah pendekatan *baseline* dan Foundation Model sudah dilatih, kinerja *baseline* dan setiap variasi Foundation Model akan dievaluasi. WER dan CER digunakan untuk mengevaluasi ketepatan dekode, sedangkan RTF dan WPM digunakan untuk mengevaluasi kecepatan.

Implementasi dan eksperimen akan dilakukan menggunakan *framework* Python berbasis PyTorch. Pustaka penting lainnya meliputi Hugging Face Transformers dan PEFT untuk memfasilitasi penggunaan FM dan penerapan LoRA. Pelatihan dan inferensi akan dilakukan pada infrastruktur yang memiliki GPU berkinerja tinggi.

BAB IV

RENCANA PELAKSANAAN

Bagian rencana pelaksanaan membahas tentang jadwal pengerjaan tugas akhir, risiko yang mungkin dihadapi, dan rencana mitigasinya.

IV.1 Jadwal

Rincian jadwal pelaksanaan tugas akhir dapat dilihat pada Tabel IV-1.

Tabel IV-1 Gantt Chart Pelaksanaan Tugas Akhir

Kegiatan	**Jan**				**Feb**				**Mar**				**Apr**				**Mei**			
	1	**2**	**3**	**4**	**1**	**2**	**3**	**4**	**1**	**2**	**3**	**4**	**1**	**2**	**3**	**4**	**1**	**2**	**3**	**4**
Persiapan lingkungan pengerjaan																				
Pra-pemrosesan data																				
Implementasi arsitektur dua tahap																				
Implementasi arsitektur *end-to-end*																				
Eksperimentasi dan perbaikan																				
Penulisan laporan tugas akhir																				
Seminar hasil tugas akhir																				
Sidang tugas akhir																				

IV.2 Risiko

Dalam mengerjakan tugas akhir, terdapat beberapa risiko yang mungkin dihadapi selama pengembangan. Karena risiko ini dapat memengaruhi kelancaran penelitian dan kualitas hasil, rencana mitigasi perlu disusun untuk mengurangi dampaknya. Berikut merupakan risiko yang mungkin terjadi serta rencana mitigasinya.

1. Beban komputasi tinggi

   Mekanisme *self-attention* yang dimiliki oleh Transformer pada modul dekode fonem dan Foundation Model memiliki kompleksitas kuadratik. Pelatihan dan inferensi untuk model berbasis Transformer akan memakan biaya komputasi yang sangat tinggi, terutama jika menggunakan perangkat keras yang terbatas seperti komputer lokal. Untuk memitigasi hal ini, pelatihan dan inferensi akan dilakukan dalam lingkungan dengan kemampuan komputasi tinggi, seperti *cloud server*.

2. Kendala pada *server* ketika pelatihan

   Arsitektur berbasis Transformer memiliki waktu pelatihan yang relatif lama. Jika terdapat kendala pada *server* yang mengakibatkan koneksi terputus atau berhentinya pelatihan secara tiba-tiba, proses pelatihan juga akan berhenti dan banyak waktu terbuang secara sia-sia. Prosedur *checkpointing* dapat dilakukan untuk menyimpan bobot model yang sedang dilatih secara berkala agar kemajuan pelatihan tetap ada meskipun mengalami kendala.

3. Latensi inferensi melebihi batas *real-time*

   Selain waktu pelatihan yang lama, waktu inferensi yang dimiliki Transformer relatif lama dibandingkan jenis model lainnya. Jika waktu tersebut terlalu tinggi, kegunaan model akan berkurang secara drastis karena tidak praktis untuk dipakai sehari-hari. Untuk menghadapi hal ini, dilakukan teknik *quantization* pada saat inferensi agar operasi matematika yang dilakukan saat inferensi berjalan lebih cepat.

4. Kegagalan dalam memetakan sinyal ECoG ke ruang *embedding* FM

Risiko ini terjadi ketika teknik adaptasi *modality* tidak mampu mengekstraksi fitur yang bermakna dari sinyal otak untuk dipetakan ke representasi FM. Kegagalan pemetaan sinyal ECoG menyebabkan FM hanya menerima *noise* sehingga proses *fine-tuning* tidak akan konvergen. Berbagai variasi arsitektur dan lapisan proyeksi fitur dapat dieksperimentasi untuk menemukan metode terbaik dalam mentranslasi sinyal ECoG ke ruang *embedding* FM.

5. Hasil eksperimen tidak menunjukkan perbedaan signifikan dengan *baseline*

   Risiko ini muncul ketika kedua arsitektur yang diusulkan tidak memberikan nilai *word error rate* (WER) yang lebih rendah dibandingkan dengan arsitektur *baseline* oleh Seto et al. (2025). Jika hal ini terjadi, analisis kesalahan lain, seperti analisis kualitatif, dapat dilakukan. Analisis kualitatif dilakukan dengan memeriksa apakah arsitektur yang diusulkan memberikan hasil dekode yang lebih masuk akal secara semantik (salah mentranslasi kata, tetapi masih sesuai dengan konteks kalimat) meskipun memiliki metrik kuantitatif yang tidak berbeda jauh dengan *baseline*.

DAFTAR PUSTAKA

Alayrac, J. B., et al. (2022). Flamingo: a visual language model for few-shot learning. Advances in Neural Information Processing Systems, 35, 23716-23736.

Bai, J., Bai, S., Yang, S., Wang, S., Tan, S., Lin, J., ... & Zhou, J. (2023). Qwen-VL: A versatile vision-language model for understanding, localization, text reading, and beyond. arXiv preprint arXiv:2308.12966.

Beukelman, D. R., Fager, S., Ball, L., & Dietz, A. (2007). AAC for adults with acquired neurological conditions: A review. Augmentative and Alternative Communication, 23(3), 230-242.

Bommasani, R. et al. (2021). On the opportunities and risks of foundation models. arXiv preprint arXiv:2108.07258.

Ding, N., Qin, Y., Yang, G., Wei, F., Yang, Z., Su, Y., ... & Sun, M. (2023). Parameter-efficient fine-tuning of large-scale pre-trained language models: A benchmark. Nature Machine Intelligence, 5(3), 220-235.

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers) (pp. 4171-4186). Association for Computational Linguistics.

Gemma Team, Google. (2024). Gemma: Open models based on Gemini research and technology. arXiv preprint arXiv:2403.08295

Graves, A., Fernández, S., Gomez, F., & Schmidhuber, J. (2006). Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural

networks. Proceedings of the 23rd International Conference on Machine Learning, 369-376.

Hannun, Y., et al. (2014). Deep Speech: Scaling up end-to-end speech recognition. arXiv preprint arXiv:1412.5567.

Indefrey, P. (2011). The spatial and temporal signatures of word production components: A critical review. Language and Cognitive Processes, 26(9), 1349-1376.

Jiang, W.-B., Zhao, L.-M., & Lu, B.-L. (2024). Large Brain Model for Learning Generic Representations with Tremendous EEG Data in BCI. In The Twelfth International Conference on Learning Representations *(ICLR 2024)*.

Li, J., Li, D., Savarese, S., & Hoi, S. (2023). BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. International Conference on Machine Learning (pp. 19730-19742). PMLR.

Lialin, V., Deshpande, O., & Rumshisky, A. (2023). Scaling Down to Scale Up: A Guide to Parameter-Efficient Fine-Tuning. arXiv preprint arXiv:2303.15647.

Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). Visual instruction tuning. Advances in Neural Information Processing Systems*,* 36.

Luo, A., et al. (2024). Stability of speech-related ECoG signals in an individual with ALS. Journal of Neural Engineering.

Metzger, S. L., Littlejohn, K. T., Silva, A. B., Moses, D. A., Seaton, M. P., Wang, R.,... & Chang, E. F. (2023). A high-performance neuroprosthesis for speech decoding and avatar control. Nature, 620(7976), 1037-1046.

Michel, C. M., & Murray, M. M. (2011). Towards the utilization of EEG as a brain imaging tool. NeuroImage, 61(2), 371-385.

Moses, D. A., Metzger, S. L., Liu, J. R., Anumanchipalli, G. K., Makin, J. G., Sun, P. F.,... & Chang, E. F. (2021). Neuroprosthesis for decoding speech in a paralyzed person with anarthria. New England Journal of Medicine, 385(3), 217-227.

Oord, A. V. D., Vinyals, O., & Kavukcuoglu, K. (2017). Neural discrete representation learning. Advances in neural information processing systems, 30.

Rainey, S., Maslen, H., Mégevand, P., Arnal, L. H., Fourneret, E., & Yvert, B. (2019). Neuroprosthetic speech: The ethical significance of accuracy, control and pragmatics. Cambridge Quarterly of Healthcare Ethics, 28(4), 617-630.

Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., ... & Liu, P. J. (2020). Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of Machine Learning Research, 21(140), 1-67.

Schalk, G., & Leuthardt, E. C. (2011). Brain-computer interfaces using electrocorticographic signals. IEEE Reviews in Biomedical Engineering, 4, 140-154.

Seto, B. (2025). Implementasi dan Perbandingan Model Bahasa Berbasis N-Gram dan Transformer pada Sistem Neuroprosthesis Bicara. Institut Teknologi Bandung.

Shih, J. J., Krusienski, D. J., & Wolpaw, J. R. (2012). Brain-computer interfaces in medicine. Mayo Clinic Proceedings, 87(3), 268-279.

Silva, A. B. et al. (2024). The speech neuroprosthesis. Nature Reviews Neuroscience.

Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M. A., Lacroix, T., ... & Lample, G. (2023). Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N.,... & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30.

Wang, J., Zhao, S., Luo, Z., Zhou, Y., Jiang, H., Li, S., Li, T., & Pan, G. (2025). CBraMod: A Criss-Cross Brain Foundation Model for EEG Decoding. In The Thirteenth International Conference on Learning Representations (ICLR 2025).

Willett, F. R., Kunz, E. M., Fan, C., Avansino, D. T., Wilson, G. H., Choi, E. Y.,... & Henderson, J. M. (2023). A high-performance speech neuroprosthesis. Nature, 620(7976), 1031-1036.

Willett, F. R., et al. (2025). Decoding inner speech from the motor cortex in a person with paralysis. Cell.