



Institut Teknologi Bandung

IF4092 Tugas Akhir 2

Muhammad Neo Cicero Koda (13522108)

Dosen Pembimbing:

Dessi Puji Lestari, S.T, M.Eng., Ph.D.,

Prof. Dr.-Ing. Sakriani Watiasri Sakti, S.T., M.Sc.

Pembangunan Model Neuroprosthesis Bicara dengan Arsitektur Dua Tahap dan *End-to-End* Berbasis Foundation Model

Neuroprosthesis bicara sebagai metode alternatif komunikasi



Jutaan individu di dunia menderita gangguan neurologis seperti ALS (amyotrophic lateral sclerosis) dan stroke batang otak. Gangguan tersebut menghambat kemampuan mereka untuk berkomunikasi melalui ucapan.


Urgensi Neuroprosthesis Bicara

Keterbatasan teknologi komunikasi alternatif lain:

- **Eye tracking:** Menggunakan mata untuk mengeja huruf
- **P300 speller:** Menggunakan sinyal EEG untuk mengeja huruf
- Keduanya kurang intuitif, lambat, dan melelahkan.


Sistem neuroprosthesis bicara:

- Teknologi yang mentranslasikan aktivitas otak menjadi teks/ucapan
- Lebih mudah dioperasikan, cepat, dan intuitif




Neuroprosthesis bicara pada penderita ALS

Alur kerja sistem neuroprosthesis bicara



Dari Willett et al. (2023): *Attempted speech* → fitur neural → RNN → probabilitas fonem → model bahasa → kalimat decode

Penelitian sistem neuroprosthesis bicara saat ini



Pipeline sistem neuroprosthesis bicara dua tahap

Penelitian Sebelumnya

Willett et al. (2023):

- *Pipeline* awal. Dekoder fonem GRU, model bahasa 5-gram. WER = 17,4%.

Seto et al. (2025):

- Menambahkan **rescoring** menggunakan LLaMA 2. WER = 16,9%.

Bottleneck Saat Ini

- Modul dekode fonem saat ini memiliki **PER = 19,2%**.
- Kinerja model bahasa **dibatasi** oleh kualitas **probabilitas fonem** yang dihasilkan.
- Sisi model bahasa sudah dioptimasi, tahap selanjutnya adalah **mengoptimalkan dekode fonem**.
- Ganti GRU dengan arsitektur lebih canggih (**model berbasis Transformer**).

Meningkatkan kinerja dekode dengan model berbasis Transformer




GRU dan Kekurangannya

- Jaringan saraf bergerbang yang menyimpan informasi masa lalu melalui *hidden state*.
- *Hidden state* menjadi *bottleneck* karena perlu menyimpan seluruh informasi masa lalu dalam ukuran tetap.
- Tidak mampu merepresentasikan hubungan spasial.

Keunggulan Transformer

- Mengintegrasikan konteks keseluruhan input melalui *self-attention* tanpa *bottleneck hidden state*.
- *Attention* dapat menangkap hubungan spasial antarelektroda.
- Varian Conformer terbukti efektif untuk pemrosesan ucapan.



Arsitektur *transformer* sebagai alternatif RNN


Pendekatan arsitektur lain: *end-to-end*

Keterbatasan Arsitektur Dua Tahap

- Dekoder fonem dan model bahasa dilatih terpisah dengan sasaran *output* masing-masing.
- Kesalahan pada tahap dekode fonem diteruskan ke tahap berikutnya dan tidak dapat dipulihkan (*error propagation*).

Pendekatan End-to-End (E2E)

- Memetakan fitur neural langsung menjadi teks dalam satu model yang dioptimasi bersama (*joint optimization*).
- Berpotensi mengurangi *error propagation* karena tidak ada *bottleneck* representasi probabilitas fonem.
- **Tantangan:** Pelatihan *from scratch* sinyal neural sulit dilakukan (keterbatasan data).



Pipeline sistem neuroprosthesis bicara dua tahap (kiri) dan *end-to-end* (kanan)

Alternatif *end-to-end* menggunakan Foundation Model

Foundation Model (FM): Model (umumnya berbasis Transformer) yang dilatih dengan **skala data yang sangat besar dan bervariasi** sehingga dapat **diadaptasi ke berbagai *downstream tasks***.

Karakteristik Foundation Model

- **Multimodality:** Menghubungkan berbagai jenis modalitas.
- **Expressivity:** Menangkap dan merepresentasikan informasi dari *input* secara bermakna.
- **Compositionality:** Melakukan generalisasi ke tugas dan konteks baru.



Contoh Foundation Model

Varian Arsitektur FM

- **Encoder-only:** Untuk tugas *natural language understanding* (BERT, RoBERTa).
- **Encoder-Decoder:** Untuk tugas *sequence-to-sequence* (T5, BART).
- **Decoder-only:** Untuk tugas generatif yang bersifat autoregresif (Qwen, LLaMA).

Rumusan masalah, tujuan, dan batasan penelitian

Rumusan Masalah	Tujuan
• Bagaimana merancang dan mengimplementasikan arsitektur dua tahap berbasis Transformer sebagai dekoder fonem untuk sistem <i>neuroprosthesis</i> bicara? • Bagaimana arsitektur <i>end-to-end</i> (E2E) berbasis Foundation Model untuk sistem <i>neuroprosthesis</i> bicara? • Bagaimana perbandingan kinerja antara arsitektur dua tahap dan arsitektur <i>end-to-end</i> berbasis Foundation Model untuk sistem <i>neuroprosthesis</i> bicara?	• Merancang dan mengimplementasikan arsitektur dua tahap berbasis Transformer sebagai dekoder fonem dalam sistem <i>neuroprosthesis</i> bicara. • Mengimplementasikan arsitektur <i>end-to-end</i> berbasis Foundation Model untuk sistem <i>neuroprosthesis</i> bicara. • Menganalisis perbandingan kinerja antara kedua arsitektur. • Ukuran keberhasilan: Kinerja sistem yang meningkat dari penelitian Seto et al. (2025)
• Batasan: Sistem dirancang menggunakan data dari Willett et al. (2023) dan bersifat <i>subject-dependent</i>.	

Penelitian terkait



Segi *Neuroprosthesis* Bicara

- **Willett et al. (2023)**: Arsitektur dua tahap dengan RNN untuk dekode fonem, *n-gram* untuk model bahasa. **WER = 17.4%**.
- **Seto et al. (2025)**: Mengganti *n-gram* dari arsitektur Willett et al. (2023) menjadi Transformer. **WER = 16.9%**.
- Dekode fonem masih menggunakan RNN dan arsitektur masih bersifat dua tahap.

Segi Penggunaan Foundation Model dalam BCI

- Mayoritas masih fokus untuk ***brain computer interface (BCI)* berbasis EEG** (elektroensefalografi) yang bersifat noninvasif.
- Membangun FM yang dilatih khusus dengan sinyal otak (cth: LaBraM, CBraMod).
- Tidak memanfaatkan FM berbasis teks/audio untuk *downstream tasks* (Jiang et al., 2024; Wang et al., 2025).

Celah Penelitian

- Belum ada penggunaan arsitektur Transformer untuk memetakan sinyal neural menjadi probabilitas fonem dalam sistem *neuroprosthesis* bicara.
- Belum ada sistem yang memanfaatkan Foundation Model untuk melakukan dekode kalimat secara *end-to-end* dalam sistem *neuroprosthesis* bicara.

Masalah yang perlu ditangani



Analisis Masalah dan Solusi


Masalah	Deskripsi	Solusi
Pemilihan varian Transformer (dua tahap)	Memilih varian Transformer dari segi arsitektur (Transformer murni, Conformer, pemanfaatan <i>spatial attention</i>) dan konfigurasi hiperparameter.	Bereksperimen dengan ketiga varian Transformer dan melakukan <i>hyperparameter tuning</i> .
Pemilihan arsitektur Foundation Model	Memilih model yang dapat mendekode secara akurat sekaligus memiliki kecepatan dan ukuran yang wajar.	Melakukan eksperimentasi berbagai variasi FM , seperti LLaMA, Qwen, dan Whisper.
Adaptasi model terhadap <i>modality</i> baru	Cara mengadaptasi sinyal neural menjadi bentuk yang dapat diterima FM dan melatih FM untuk memproses sinyal secara efisien.	Teknik adaptasi menyesuaikan arsitektur FM yang dipakai, pelatihan menggunakan LoRA.
Latensi inferensi dan beban komputasi	Mempertahankan latensi inferensi model agar dalam batas wajar tanpa mengorbankan akurasi.	Memilih varian arsitektur yang sesuai.

Data yang digunakan




Deskripsi Data Sinyal Otak

- Sinyal berasal dari **satu partisipan** (T12) dengan **ALS**.
- Partisipan melakukan ***attempted speech*** saat komputer memberi isyarat, perekaman dihentikan ketika ia menekan tombol.
- Direkam dengan susunan mikroelektroda intrakortikal di area **6v** dan **44**, total 256 kanal, **hanya 128 kanal area 6v** dipakai.
- Tiap kanal menghasilkan dua fitur per ***bin 20 ms***: ***threshold crossings*** (ambang $-3,5 \times \text{RMS}$) dan ***spike band power***.
- Setiap bin $\rightarrow$ vektor fitur berdimensi 256 (128 *threshold crossings* + 128 *spike band power*).
- Terdapat 8800 *trial* latih dan 880 *trial* uji.
- Contoh: *we don't listen to the radio at work at all*




Ilustrasi data rekaman

Praproses dan ekstraksi fitur



Alur praproses dan ekstraksi fitur


Rancangan arsitektur dua tahap



Alur arsitektur dua tahap

- Untuk Tahap 1, model dapat berupa berbagai varian berbasis Transformer (Transformer, Conformer, etc.).
- Pelatihan dilakukan dengan *loss* CTC, *optimizer* Adam, ukuran *batch* 32, *learning rate* dijadwalkan secara *cosine* dari 0,04 → 0,004 dengan 1000 langkah *warmup* hingga 150k langkah.
- Untuk Tahap 2, *rescoring* dihitung melalui rumus $skor_f(W) = s_{ak} \cdot \log p_{ak}(W) + \alpha \cdot \log p_{neur}(W) + \beta \cdot N_{kata}(W)$

Rancangan arsitektur *end-to-end* (E2E)



Arsitektur *decoder-only* bergaya LLaVA (kiri) dan *encoder-decoder cross attention* (kanan)


Detil Arsitektur

- Keduanya memiliki **tiga** komponen, **encoder Conformer**, proyektor, dan **dekoder FM**.
- Gaya LLaVA:** Token ECoG dikonkatenasi dengan teks.
- Cross attention:** Informasi ECoG diakses melalui *cross attention*.
- Tradeoff:** LLaVA lebih sederhana, tetapi rawan **text shortcut**. *Cross attention* lebih memaksa pemakaian ECoG.

Pelatihan *end-to-end*

Detil Pelatihan E2E

- Pelatihan terdiri dari dua tahap:
 - **Pre-training encoder:** Conformer dilatih sendiri terlebih dahulu untuk memprediksi karakter dengan CTC.
 - **Pelatihan E2E:** Bagian *encoder Conformer* diinisialisasi dari hasil pelatihan CTC. Proyektor dan *encoder* dilatih dengan LR kecil dan FM dilatih dengan LoRA.
- LoRA dipilih karena mampu melakukan pelatihan yang efektif meskipun hanya sebagian parameter dilatih dan tidak menambah latensi.
- LoRA diterapkan pada modul *attention* (q, k, v, o), *cross attention*, *feed forward* menggunakan *rank* 16, *alpha* 32, dan *dropout* 0.1.
- Pelatihan E2E berlangsung selama 15k langkah dengan 500 langkah *warmup*. Ukuran *batch* sebesar 16.



Lingkungan pengembangan



Komponen	Spesifikasi
Prosesor	16 vCPU (host AMD EPYC)
RAM	62 GB
GPU	NVIDIA GeForce RTX 4090, 24 GB GDDR6X, Ada Lovelace, 16.384 CUDA core
Penyimpanan	200 GB
Sistem Operasi	Ubuntu 22.04 LTS
Lingkungan virtual	Python venv (PyTorch CUDA 12 + TensorFlow 2.15)

Keterangan Tambahan

- Pelatihan dan evaluasi berjalan di GPU *cloud* RunPod. RTX 4090 dipilih karena ketersediaaan, biaya sewa wajar, dan memiliki memori 24 GB yang cukup untuk pelatihan FM dengan LoRA.
- Eksperimen terkait E2E dan *rescoring* memakai PyTorch (transformers, peft), dekode fonem dan dekode WFST memakai TensorFlow, metrik kesalahan dihitung dengan jiwer.

Eksperimen evaluasi dekoder fonem



Dekoder Fonem	Konfigurasi	PER
GRU	1024 unit, 5 lapisan searah	0.1597
Transformer murni	d=512, 4 lapisan, 8 <i>head</i> , FFN 2048	0.2444
Conformer biasa	d=512, 4 lapisan, 8 <i>head</i> , FFN 2048, kernel 31	0.1477
Conformer + <i>spatial attention</i>	Conformer biasa + <i>spatial attention</i> (dim 64, 4 <i>head</i>)	0.1428

Analisis dan Pembahasan

- **Tujuan:** Membandingkan empat dekoder fonem dalam segi PER.
- Kedua varian Conformer mengalahkan GRU, sedangkan Transformer murni justru terburuk.
- *Spatial attention* yang menangkap dependensi antarelektroda memiliki pengaruh positif.
- Conformer + *spatial attention* (0,1428) juga mengalahkan dekoder GRU Seto (0,192).

Eksperimen evaluasi arsitektur dua tahap dan E2E (akurasi)

Arsitektur	WER	CER
Dua tahap (GRU + 5-gram)	0.1828	0.1327
Dua tahap (Transformer + 5-gram)	0.2927	0.2094
Dua tahap (Conformer + 5-gram)	0.1858	0.1253
Dua tahap (GRU + 5-gram + LLaMA-2 7B)	0.1638	0.1194
Dua tahap (Conformer + 5-gram + LLaMA-2 7B)	0.1556	0.1127
E2E Qwen (gaya LLaVA)	0.2537	0.2413
E2E Whisper-medium.en	0.1760	0.1508
E2E Whisper-large-v3	0.1716	0.1428
E2E Cohere Transcribe	0.1776	0.1523
E2E Canary-Qwen	0.2384	0.2115
E2E Granite-Speech	0.2337	0.2097

Analisis dan Pembahasan

- **Tujuan:** Membandingkan arsitektur dua tahap vs. E2E dan variannya dalam segi akurasi.
- **Dua tahap Conformer + 5-gram + LLaMA-2 7B** mencapai **WER terendah (0,1556)** dan mengalahkan Willett (~0,174) serta Seto (~0,169).
- **Tanpa *rescoring***, semua varian dua tahap kalah dengan varian E2E Whisper-large-v3.
- Mekanisme *cross-attention* mengungguli FM yang bergaya LLaVA.

Eksperimen evaluasi arsitektur (penyimpanan dan kecepatan)

Arsitektur	#Param	Penyimpanan Total	RTF	WPM
Dua tahap (GRU + 5-gram)	53.6 jt	44.3 GB (TLG.fst 44.1 GB)	0.0155	4.556
Dua tahap (Transformer + 5-gram)	16,8 jt	44.2 GB (TLG.fst 44.1 GB)	0.0044	6.573
Dua tahap (Conformer + 5-gram)	28.5 jt	44.2 GB (TLG.fst 44.1 GB)	0.0069	10.307
Dua tahap (GRU + 5-gram + LLaMA-2 7B)	6.79 M	57.8 GB (TLG.fst 44.1 GB)	0.0756	935
Dua tahap (Conformer + 5-gram + LLaMA-2 7B)	6.77 M	57.7 GB (TLG.fst 44.1 GB)	0.043	1.65
E2E Qwen (gaya LLaVA)	0.86 M	2.1 GB (FM 1.77 GB)	0.071	895
E2E Whisper-medium.en	0.80 M	2.0 GB (FM 1.54 GB)	0.0455	1.394
E2E Whisper-large-v3	1.57 M	3.6 GB (FM 3.09 GB)	0.0742	857
E2E Cohere Transcribe	2.0 M	4.5 GB (FM 4.13 GB)	0.0206	3.091
E2E Canary-Qwen	4.2 M	9.9 GB (<i>encoder</i> 5.12 GB)	0.3207	503
E2E Granite-Speech	2.0 M	5.3 GB (FM 4.87 GB)	0.0672	943

Analisis dan Pembahasan

- Penyimpanan E2E **2,0–9,9 GB** vs. dua tahap **44,2–57,8 GB**.
- Beban dua tahap hampir seluruhnya dari berkas **TLG.fst 44,1 GB** (ditambah LLaMA-2 7B pada varian *rescoring*).
- Dua tahap Conformer + LLaMA unggul tipis di akurasi, tetapi butuh 57,7 GB, sedangkan Whisper-large hanya butuh 3,6 GB dengan akurasi kompetitif.

Analisis *coverage n-best* kedua arsitektur




Dekoder	Coverage	Oracle WER	Rata-rata jumlah <i>n-best</i>
Conformer + spatial attention	58.00%	0.1018	32.6
GRU	68.30%	0.0796	48.3

Analisis dan Pembahasan

- Dalam lebih dari **40% ujaran**, transkrip benar tidak muncul di daftar *n-best* sehingga tidak terpulihkan oleh *rescorer* mana pun.
- PER Conformer lebih baik (0.1428 vs. 0.1597), namun WER GRU lebih rendah daripada Conformer pada kasus tanpa *rescoring* (0.1828 vs. 0.1858). Sebabnya adalah **distribusi fonem Conformer lebih tajam** (entropi 0,0950 nats vs GRU 0,1448 nats) → *beam search* memangkas lebih agresif → jalur yang benar lebih sering hilang.

Pengaruh panjang ujaran terhadap WER



Analisis dan Pembahasan

- WER kedua arsitektur menurun seiring ujaran lebih panjang.
- E2E Whisper-large-v3 unggul di hampir semua panjang kata, kecuali ujaran tepat **5 kata**.
- Model *5-gram* hanya dapat melihat 4 kata ke belakang, Whisper memiliki jangkauan konteks yang jauh lebih lebar.

Analisis kesalahan



	Dua tahap benar	Dua tahap salah
E2E benar	175 (29.2%)	71 (11.8%)
E2E salah	66 (11.0%)	288 (48.0%)

Analisis dan Pembahasan

- E2E Whisper-large-v3 dengan Conformer + 5-gram + LLaMA-2-7B dibandingkan.
- 22,8% ujaran benar di satu arsitektur, tetapi salah di yang lain (***best-of-two* WER = 0,1249**).
- Potensi *ensembling* untuk penelitian lanjut.

Kesimpulan dan saran



Kesimpulan

- Arsitektur dua tahap berbasis Transformer berhasil diimplementasikan dan mengalahkan Seto et al. (2025). Dekoder Conformer + *spatial attention* mencapai PER 0,1428 (vs. PER 0,1920 Seto), Sistem mencapai WER 0,1556 (vs. 0,169 Seto).
- Arsitektur E2E berbasis FM berhasil. diimplementasikan. Whisper-large-v3 mencapai WER 0,1716 dan mengalahkan semua dua tahap tanpa *rescoring* neural serta memiliki penyimpanan jauh lebih kecil (3,6 GB vs 40+ GB).
- *
 - Analisis perbandingan keduanya telah dilakukan dari sisi akurasi, efisiensi, dan keterbatasan.

Saran

- Menambahkan data latih ECoG lintassubjek.
- Pemanfaatan *ensembling* antara arsitektur E2E dan dua tahap.'
- Pengembangan *neuroprosthesis* bicara yang *speaker-independent*.
- Perluasan kosakata dan pengujian arsitektur pada dataset lain.

Terima kasih...

Apakah ada pertanyaan?



Institut Teknologi Bandung

IF4092 Tugas Akhir 2

**Pembangunan Model Neuroprosthesis Bicara dengan
Arsitektur Dua Tahap dan *End-to-End* Berbasis
*Foundation Model***

Muhammad Neo Cicero Koda

Dosen Pembimbing:
Dessi Puji Lestari, S.T, M.Eng., Ph.D.,
Prof. Dr.-Ing. Sakriani Watiasri Sakti, S.T., M.Sc.