

**IMPLEMENTASI DAN PERBANDINGAN MODEL BAHASA
BERBASIS N-GRAM DAN TRANSFORMER PADA SISTEM
NEUROPROSTHESIS BICARA**

Laporan Tugas Akhir

Disusun sebagai syarat kelulusan tingkat sarjana

Oleh

BAGAS ARYO SETO

NIM : 13521081



**PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

Juli 2025

**IMPLEMENTASI DAN PERBANDINGAN MODEL BAHASA
BERBASIS N-GRAM DAN TRANSFORMER PADA SISTEM
NEUROPROSTHESIS BICARA**

Laporan Tugas Akhir

Oleh

BAGAS ARYO SETO

NIM : 13521081


Program Studi Teknik Informatika

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Telah disetujui dan disahkan sebagai Laporan Tugas Akhir
di Bandung, pada tanggal 31 Juli 2025

Pembimbing I,



Dessi Puji Lestari, S.T., M.Eng., Ph.D.

NIP. 197912012012122005

Pembimbing II,

Nur Ahmadi, S.T., M.Eng., Ph.D.

NIP. 123110012

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa:

1. Pengerjaan dan penulisan Laporan Tugas Akhir ini dilakukan tanpa menggunakan bantuan yang tidak dibenarkan.
2. Segala bentuk kutipan dan acuan terhadap tulisan orang lain yang digunakan di dalam penyusunan laporan tugas akhir ini telah dituliskan dengan baik dan benar.
3. Laporan Tugas Akhir ini belum pernah diajukan pada program pendidikan di perguruan tinggi mana pun.

Jika terbukti melanggar hal-hal di atas, saya bersedia dikenakan sanksi sesuai dengan Peraturan Akademik dan Kemahasiswaan Institut Teknologi Bandung bagian Penegakan Norma Akademik dan Kemahasiswaan khususnya Pasal 2.1 dan Pasal 2.2.

Bandung, 31 Juli 2025

Bagas Aryo Seto

NIM 13521081

ABSTRAK

IMPLEMENTASI DAN PERBANDINGAN MODEL BAHASA BERBASIS N-GRAM DAN TRANSFORMER PADA SISTEM NEUROPROSTHESIS BICARA

Oleh

BAGAS ARYO SETO

NIM : 13521081

Kehilangan kemampuan bicara akibat kelumpuhan merupakan kondisi yang secara drastis menurunkan kualitas hidup dan memutus interaksi sosial penderitanya. *Neuroprosthesis* bicara (*speech neuroprosthesis*) merupakan sistem yang menerjemahkan sinyal aktivitas neural menjadi teks yang koheren dan bermakna melalui beberapa tahap pemrosesan, mulai dari ekstraksi fitur neural dan dekoding probabilitas fonem hingga penerapan model bahasa untuk menyempurnakan transkripsi. Dalam beberapa tahun terakhir, model bahasa n-gram digunakan untuk memandu algoritma pencarian heuristik dalam mengonversi probabilitas fonem menjadi urutan kata. Namun, model Transformer terbukti menawarkan peningkatan kinerja yang signifikan dalam menurunkan tingkat kesalahan, sehingga membuka peluang untuk memperbaiki akurasi transkripsi pada aplikasi *speech neuroprosthesis*.

Dataset penelitian diperoleh dari Willett *et al.* (2023) dan mencakup fitur neural yang diambil dari 256 elektroda ECoG dengan frame temporal *20 ms*, meliputi *spike band power* dan *threshold crossings*, yang kemudian didekode menjadi probabilitas fonem menggunakan BiRNN dengan CTC loss. Probabilitas fonem ini diproses melalui *beam search shallow fusion* untuk menggabungkan skor akustik dan skor bahasa.

Evaluasi kinerja akurasi transkripsi melalui *Phone Error Rate* (PER), *Character Error Rate* (CER), dan *Word Error Rate* (WER), serta kecepatan dan efisiensi pemrosesan melalui *Words Per Minute* (WPM) dan *Real-Time Factor* (RTF), menunjukkan bahwa model Transformer *fine-tuned* pada korpus *Open Web Text 2* memberikan *trade-off* terbaik. LLaMA 2 menempati posisi teratas dengan WER 16,9%, CER 14,5%, WPM 62,5, dan RTF 0,98. Sebaliknya, meski model n-gram mencapai WPM di atas 74, WER-nya masih di kisaran 26%-29%. Temuan ini menegaskan potensi model Transformer untuk aplikasi *speech neuroprosthesis* pada penelitian ini.

Kata kunci: *speech neuroprosthesis*, model bahasa, Transformer, n-gram, *electrocorticography* (ECoG)

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa karena dengan rahmat dan bimbingan-Nya penulis berhasil menyelesaikan penelitian tugas akhir berjudul “Implementasi dan Perbandingan Model Bahasa Berbasis N-Gram dan Transformer pada Sistem *Neuroprosthesis* Bicara”. Penulis menyadari bahwa dalam proses penyusunan tugas akhir ini terdapat berbagai hambatan dan tantangan. Oleh karena itu, penulis ingin menyampaikan penghargaan dan terima kasih yang tulus kepada pihak-pihak yang telah memberikan bantuan, khususnya:

1. Ibu Dessi Puji Lestari, S.T., M.Eng., Ph.D. dan Bapak Nur Ahmadi, S.T., M.Eng., Ph.D., selaku pembimbing, atas ilmu yang telah dibagikan, serta arahan, kritik, saran, dan dukungan moral yang senantiasa mengiringi penulis sepanjang penyusunan tugas akhir ini.
2. Bapak Nugraha Priya Utama, S.T., M.A., Ph.D. dan Bapak Ir. Rila Mandala, M.Eng., Ph.D. selaku dosen penguji sidang tugas akhir yang memberikan evaluasi dan masukan terhadap pengembangan tugas akhir.
3. Staf pengajar dari Program Studi Teknik Informatika yang memberikan ilmu serta wawasan untuk mendukung pengerjaan tugas akhir.
4. Orang tua dan keluarga penulis yang selalu memberikan dukungan kepada penulis baik dalam bentuk moril maupun materil.
5. Teman-teman dekat penulis yang telah banyak memberikan dukungan kepada penulis baik dalam akademik maupun non akademik.
6. Seluruh pihak yang telah berkontribusi dan memberikan dukungan baik secara langsung maupun tidak langsung yang tidak dapat penulis sebutkan satu per satu.

Penulis berharap tugas akhir ini dapat bermanfaat dan menambah wawasan. Menyadari masih banyaknya kekurangan dalam laporan ini, penulis sangat terbuka terhadap segala kritik dan saran yang membangun demi penyempurnaan selanjutnya. Semoga laporan ini berguna bagi semua pihak.

DAFTAR ISI

LEMBAR PERNYATAAN.....	ii
ABSTRAK.....	iii
KATA PENGANTAR.....	iv
DAFTAR ISI.....	v
DAFTAR GAMBAR.....	vii
DAFTAR TABEL.....	viii
BAB I PENDAHULUAN.....	1
I.1 Latar Belakang.....	1
I.2 Rumusan Masalah.....	3
I.3 Tujuan dan Ukuran Keberhasilan Pencapaian.....	4
I.4 Batasan Masalah.....	4
I.5 Metodologi.....	5
I.6 Sistematika Pembahasan.....	6
BAB II KAJIAN PUSTAKA.....	8
II.1 Neuroprosthesis Bicara.....	8
II.1.1 Akuisisi Aktivitas Neural.....	9
II.1.1.1. Prosedur Perekaman Data Aktivitas Neural.....	13
II.1.2 Ekstraksi Fitur Neural.....	14
II.1.3 Dekoding Probabilitas Fonem.....	17
II.1.4 Pemrosesan Probabilitas Fonem Menjadi Teks.....	21
II.1.5 Model Bahasa.....	25
II.1.5.1 Model Transformer.....	27
II.1.5.2 Fine-Tuning pada Model Transformer.....	29
II.1.5.3 Perbandingan Model Transformer dengan N-gram.....	30

II.1.5.4 Tantangan Komputasi Model Transformer.....	31
II.1.5.5 Out-of-Vocabulary.....	35
II.2. Evaluasi Kinerja.....	36
II.2.1 Kecepatan Dekoding.....	36
II.2.2 Perhitungan Tingkat Kesalahan.....	37
II.3 Dataset.....	37
II.4 Penelitian Terkait.....	42
BAB III ANALISIS MASALAH DAN RANCANGAN SOLUSI.....	44
III.1 Analisis Permasalahan.....	44
III.2 Analisis Solusi.....	48
III.3 Rancangan Solusi.....	54
III.3.1. Rancangan Dataset.....	54
III.3.2. Rancangan Pembangunan Sistem Neuroprosthesis Bicara.....	55
BAB IV IMPLEMENTASI SISTEM DAN EKSPERIMEN.....	59
IV.1 Lingkungan Pengembangan.....	59
IV.2 Implementasi Sistem Speech Neuroprosthesis.....	59
IV.3 Pengolahan Data.....	60
IV.4 Eksperimen Model Bahasa Dalam Sistem Speech Neuroprosthesis.....	62
IV.4.1. Skenario Eksperimen.....	62
IV.4.2. Hasil Eksperimen.....	64
IV.5 Pembahasan.....	69
BAB V KESIMPULAN DAN SARAN.....	72
V.1 Kesimpulan.....	72
V.2 Saran.....	73
DAFTAR REFERENSI.....	75

DAFTAR GAMBAR

Gambar II-1. Diagram Algoritma Dekoding Teks dari Aktivitas Neural (Metzger <i>et al.</i> , 2023).....	9
Gambar II-2. Ilustrasi Implan ECoG pada Sistem Speech <i>Neuroprosthesis</i> (https://changlab.ucsf.edu).....	11
Gambar II-3. Rekonstruksi MRI otak peserta dengan lokasi elektroda yang diimplan. Area kortikal dan elektroda diberi warna berdasarkan wilayah anatomis (PoCG: <i>postcentral gyrus</i> , PrCG: <i>precentral gyrus</i> , SMC: <i>sensorimotor cortex</i>). (Metzger <i>et al.</i> , 2023).....	12
Gambar II-4. Tampilan Eksperimen <i>Silent Speech</i> dengan Pemasangan <i>High-Density ECoG Array</i> . (Willet <i>et al.</i> , 2023).....	14
Gambar II-5 Lokasi Implan Array dan Data fMRI yang Diperlihatkan Relatif terhadap Area Otak yang Diidentifikasi oleh HCP (Willet <i>et al.</i> , 2023)..	16
Gambar II-6 Enkoding Artikulatoris untuk Dekoding Ucapan. (Metzger <i>et al.</i> , 2023).....	19
Gambar II-7. Ilustrasi Urutan Probabilitas Fonem (Metzger <i>et al.</i> , 2023).....	21
Gambar II-8. Arsitektur Model Transformer (Vaswani <i>et al.</i> , 2017).....	27
Gambar II-8. Contoh Aktivitas <i>Spiking</i> yang Terekam dari Setiap Array Mikroelektroda (Willet <i>et al.</i> , 2023).....	41
Gambar III-1. Rancangan Sistem <i>Neuroprosthesis</i> Bicara.....	55
Gambar III-2. Arsitektur Sistem <i>Speech Neuroprosthesis</i> Berbasis Transformer..	57
Gambar IV-1. Arsitektur konversi probabilitas fonem ke teks menggunakan <i>Beam Search (Shallow Fusion)</i> dengan (a) n-gram LM dan (b) Transformer <i>Decoder-Only LM</i>	60
Gambar IV-2. Distribusi PER, WER, CER, dan WPM untuk Setiap Skenario Eksperimen Model Bahasa.....	69

DAFTAR TABEL

Tabel II-1 Perbandingan Kinerja EEG vs. ECoG.....	10
Tabel II-2 Ilustrasi Akumulasi Probabilitas Fonem.....	24
Tabel II-3 Ilustrasi Keluaran Dekoding Urutan Fonem.....	25
Tabel IV-1. Nilai OOV Dataset Terhadap Kosakata Target Sistem.....	62
Tabel IV-2. Nilai <i>Perplexity</i> Setiap Skenario Eksperimen.....	65
Tabel IV-3. Contoh Kalimat Target dan Hasil Dekoding.....	66
Tabel IV-4. Median Hasil Eksperimen Model Bahasa Berbasis N-Gram.....	67
Tabel IV-5. Median Hasil Eksperimen Model Bahasa Berbasis Transformer.....	68
Tabel IV-6. RTF Model Pilihan.....	71

BAB I

PENDAHULUAN

Pada bagian Pendahuluan, akan dijelaskan hal-hal terkait yang mendasari sistem *neuroprosthesis* bicara. Berikut ini adalah aspek-aspek yang akan dibahas pada Bab 1, yakni latar belakang (I.1), rumusan masalah (I.2), tujuan dan ukuran keberhasilan pencapaian (I.3), batasan masalah (I.4), metodologi (I.5), dan sistematika pembahasan (I.6).

I.1 Latar Belakang

Hilangnya kemampuan komunikasi verbal merupakan salah satu konsekuensi paling berat dari gangguan neurologis, yang secara signifikan menurunkan kualitas hidup dan membatasi interaksi sosial penderitanya. Sebagai contoh representatif, studi menunjukkan bahwa sekitar 80% hingga 95% individu dengan *amyotrophic lateral sclerosis* (ALS) pada akhirnya akan kehilangan kemampuan bicara fungsional (Beukelman *et al.*, 2007). Kondisi ini, bersama dengan locked-in syndrome atau cedera tulang belakang, sering kali disebabkan oleh kerusakan pada sistem motorik yang mengontrol produksi bicara, sebagaimana dijelaskan oleh Moses *et al.* (2021). Oleh karena itu, kehilangan kemampuan komunikasi verbal tidak hanya berdampak pada interaksi sosial, tetapi juga pada kualitas hidup mereka secara keseluruhan.

Teknologi *speech neuroprosthesis*, seperti yang dijelaskan oleh Moses *et al.* (2021), menawarkan solusi potensial untuk mengembalikan kemampuan komunikasi pada individu dengan kelumpuhan parah. Meskipun metode Komunikasi Augmentatif dan Alternatif (AAC) konvensional, seperti pelacak mata (*eye-tracker*) atau saklar mekanis, telah lama menjadi standar, metode ini sering kali memiliki kecepatan komunikasi yang terbatas dan dapat terasa kurang alami bagi pengguna. Di sisi lain, antarmuka otak-komputer (BCI) non-invasif berbasis *electroencephalography* (EEG) menawarkan alternatif tanpa memerlukan pembedahan, namun memiliki keterbatasan fundamental berupa resolusi spasial

yang rendah dan rasio sinyal-ke-bising (*signal-to-noise ratio*) yang buruk, sehingga kurang efektif untuk menerjemahkan sinyal ucapan yang kompleks.

Sebagai jalan tengah yang menjanjikan, speech neuroprosthesis memanfaatkan *electrocorticography* (ECoG) untuk merekam aktivitas neural secara langsung. Implementasinya melibatkan penanaman array elektroda di permukaan korteks untuk menangkap sinyal gamma tinggi dan sinyal frekuensi rendah yang sangat berkorelasi dengan upaya bicara. Pendekatan invasif ini memberikan keunggulan sinyal dengan resolusi spasial dan temporal yang jauh lebih tinggi dibandingkan EEG. Kualitas data superior inilah yang menjadi fondasi bagi tahap pemrosesan selanjutnya, yaitu pendeteksian pola fonem atau kata, sehingga memungkinkan interpretasi niat bicara yang jauh lebih akurat dan cepat. Dengan demikian, teknologi ini membuka peluang untuk interaksi yang lebih natural dan mendekati kecepatan percakapan normal, menghubungkan kembali pikiran pengguna dengan dunia luar secara lebih langsung.

Pada sistem *speech neuroprosthesis*, model bahasa memainkan peran penting dalam menginterpretasikan data neural menjadi teks yang koheren dan bermakna. Setelah data neural diproses menjadi probabilitas fonem, model bahasa bertugas memprediksi urutan kata yang paling mungkin berdasarkan kombinasi probabilitas fonem dan aturan bahasa. Penelitian sebelumnya menunjukkan bahwa model berbasis *n-gram* telah digunakan secara luas dalam sistem ini. Sebagai contoh, Willet *et al.* (2023) menggunakan model trigram dengan kosakata besar (125.000 kata) dan kecil (50 kata) untuk meningkatkan akurasi dekoding sinyal neural. Penelitian lain oleh Metzger *et al.* (2023) mengimplementasikan model 5-gram yang dilatih dengan metode *Kneser-Ney smoothing* untuk memproses urutan fonem menjadi kalimat koheren melalui algoritma *beam search* berbasis CTC.

Meskipun model *n-gram* menunjukkan kinerja yang baik dalam menangkap konteks lokal, mereka memiliki keterbatasan dalam menangani konteks yang lebih panjang. Sebaliknya, model berbasis transformer, seperti yang diperkenalkan oleh Vaswani *et al.* (2017), memanfaatkan mekanisme *self-attention* untuk secara efektif mempelajari hubungan antar-token dalam urutan yang panjang. Studi oleh

Svete dan Cotterell (2024) menunjukkan bahwa transformer tidak hanya mampu merepresentasikan model *n-gram* tetapi juga melampaui kinerjanya dengan menangkap dependensi yang lebih kompleks. Penelitian mereka menemukan bahwa transformer dapat mempelajari pola-pola yang lebih fleksibel tanpa bergantung pada jumlah kata sebelumnya yang tetap, seperti pada *n-gram*.

Selain itu, penelitian Svete *et al.* (2024) memperkuat gagasan bahwa transformer memiliki kapasitas untuk meniru kinerja model *n-gram* sambil mengatasi keterbatasannya dalam menangani konteks yang panjang dan beragam. Transformer juga menunjukkan keunggulan dalam efisiensi pemrosesan data karena kemampuannya untuk melakukan komputasi secara paralel, memungkinkan dekoding sinyal neural menjadi teks dilakukan lebih cepat dan akurat dibandingkan dengan pendekatan berbasis *n-gram*.

Dengan mempertimbangkan keunggulan transformer dalam menangkap konteks kompleks dan efisiensinya, model ini dapat menjadi alternatif yang lebih baik untuk dekoding sinyal neural dalam sistem *speech neuroprosthesis*. Transformasi ini menawarkan peluang besar untuk meningkatkan keakuratan dan kelancaran komunikasi bagi individu dengan gangguan bicara, memberikan solusi yang lebih efektif dan berkelanjutan.

I.2 Rumusan Masalah

Saat ini, teknologi *speech neuroprosthesis* telah menunjukkan potensi besar dalam memungkinkan individu dengan gangguan bicara untuk kembali berkomunikasi. Model bahasa seperti *n-gram* dan transformer memiliki kelebihan dan kekurangan masing-masing dalam proses dekoding sinyal neural menjadi teks. Model *n-gram* menawarkan pendekatan yang sederhana namun terbatas pada konteks lokal, sementara transformer memiliki kemampuan untuk menangkap konteks yang lebih luas dengan efisiensi tinggi, meskipun memerlukan sumber daya komputasi yang besar.

Penelitian Willett *et al.* (2023) dan Metzger *et al.* (2023) dipilih sebagai titik tolak karena keduanya merupakan studi mutakhir yang telah terbukti efektif dalam dekoding sinyal ECoG secara *real-world* dan menyediakan *baseline* terbuka yang

dapat direplikasi pada infrastruktur riset lokal. Dengan menggunakan hasil eksperimen trigram dari Willett *et al.* dan 5-gram dari Metzger *et al.*, dapat dievaluasi peningkatan performa serta *trade-off* komputasi yang relevan.

Oleh karena itu, eksplorasi dan perbandingan kedua pendekatan ini menjadi penting dalam pengembangan sistem *speech neuroprosthesis*. Untuk mendalami hal tersebut, berikut ini dijabarkan beberapa permasalahan yang menjadi fokus penelitian tugas akhir ini.

1. Bagaimana cara mengimplementasikan model bahasa berbasis transformer pada sistem *neuroprosthesis* bicara?
2. Bagaimana ketepatan dan kecepatan model bahasa berbasis transformer dibandingkan dengan *baseline* penelitian Willett *et al.* (2023), yang menggunakan model bahasa trigram, dan Metzger *et al.* (2023), yang menggunakan model bahasa 5-gram, pada sistem *neuroprosthesis* bicara?

I.3 Tujuan dan Ukuran Keberhasilan Pencapaian

Penelitian tugas akhir ini memiliki tujuan sebagai berikut.

1. Membuat dan mengoptimalkan kinerja sistem *neuroprosthesis* bicara menggunakan model n-gram dan transformer untuk dekoding sinyal neural menjadi teks. Keberhasilan dapat diukur dengan peningkatan akurasi dekoding dan efisiensi sistem dibandingkan dengan pendekatan sebelumnya.
2. Menganalisis perbandingan ketepatan model n-gram dan transformer dalam dekoding sinyal neural pada sistem *neuroprosthesis* bicara, sekaligus mengevaluasi potensi optimalisasi tiap model untuk integrasi dalam alat bantu komunikasi klinis real-time. Ukuran keberhasilan dapat berupa penilaian berdasarkan metrik seperti kecepatan dekoding dan perhitungan tingkat kesalahan.

I.4 Batasan Masalah

Berdasarkan rumusan masalah, pelaksanaan tugas akhir ini memiliki batasan masalah sebagai berikut.

1. Sistem *neuroprosthesis* bicara dibangun dan diuji menggunakan data aktivitas neural yang disediakan oleh Metzger *et al.* (2023). Penelitian ini memanfaatkan sinyal neural yang direkam melalui perangkat elektrokortikografi untuk melatih dan mengevaluasi model dekoding.
2. Kosakata yang digunakan dalam sistem *speech neuroprosthesis* dibatasi pada kumpulan kata yang telah ditentukan, sesuai dengan konfigurasi data pada penelitian terkait.

I.5 Metodologi

Tahap-tahap berikut diperlukan untuk menyelesaikan penelitian pada tugas akhir.

1. Analisis Permasalahan

Tahap awal penelitian ini dimulai dengan analisis terhadap permasalahan yang dihadapi dalam teknologi *neuroprosthesis* bicara, terutama dalam dekoding sinyal neural menjadi teks. Studi literatur dilakukan untuk memahami teknologi yang sudah ada, termasuk model bahasa berbasis n-gram dan transformer, serta kekurangan dan kelebihanannya. Selanjutnya, dicari alternatif solusi untuk meningkatkan efisiensi dan akurasi sistem melalui pendekatan model yang relevan dengan masalah yang telah didefinisikan.

2. Persiapan Data

Tahap ini melibatkan pengumpulan dan praproses data neural yang digunakan dalam eksperimen. Data neural diperoleh dari penelitian yang dilakukan oleh Metzger *et al.* (2023). Proses praproses meliputi pembersihan data, normalisasi, dan penyusunan data ke dalam format yang sesuai untuk pelatihan model berbasis n-gram maupun transformer.

3. Pembangunan Sistem

Sistem *neuroprosthesis* bicara dibangun menggunakan dua pendekatan model bahasa, yaitu n-gram dan transformer. Pada tahap ini, parameter model dioptimalkan untuk mencapai kinerja terbaik dalam dekoding sinyal neural menjadi teks yang akurat.

4. Eksperimen dan Optimasi Model

Pada tahap ini, eksperimen dilakukan untuk menguji kinerja sistem yang telah dibangun. Proses ini meliputi evaluasi akurasi dekoding, efisiensi waktu pemrosesan, serta analisis terhadap kekuatan dan kelemahan masing-masing model. Parameter model dioptimalkan berdasarkan hasil eksperimen untuk memastikan sistem bekerja secara optimal.

5. Evaluasi Kinerja dan Penarikan Kesimpulan

Tahap akhir mencakup evaluasi kinerja sistem secara keseluruhan berdasarkan metrik seperti akurasi, kecepatan, dan efisiensi. Hasil evaluasi kemudian dianalisis untuk menentukan model terbaik di antara n-gram dan transformer, serta memberikan kesimpulan yang menjawab rumusan masalah penelitian ini.

I.6 Sistematika Pembahasan

Hasil dan tahapan dalam pembuatan tugas akhir ini dijelaskan dengan pembagian dan rincian sebagai berikut.

1. Bab I Pendahuluan menjelaskan konteks dan urgensi penelitian ini dengan menguraikan latar belakang permasalahan komunikasi bagi penyandang gangguan bicara, merumuskan pertanyaan riset yang hendak dijawab, menetapkan tujuan penelitian, serta membatasi ruang lingkup kajian. Selain itu, pada bab ini dijabarkan metodologi umum yang digunakan serta gambaran struktur keseluruhan laporan.
2. Bab II Studi Literatur memaparkan landasan teori dan hasil penelitian terdahulu yang meliputi prinsip kerja *neuroprosthesis* bicara, alur dekoding sinyal ECoG menjadi teks, perbandingan model bahasa n-gram dan transformer, serta metrik evaluasi seperti perhitungan tingkat kesalahan dan kecepatan dekoding. Di samping itu, dibahas pula studi-studi mutakhir yang menjadi dasar identifikasi gap riset dan justifikasi kebutuhan eksperimen lanjutan.
3. Bab III Analisis Masalah dan Rancangan Solusi memaparkan mengenai analisis permasalahan yang menjadi pokok isu dalam tugas akhir ini, analisis solusi yang mungkin digunakan, dan rancangan solusi yang diusulkan untuk menjawab permasalahan pada tugas akhir ini.

4. Bab IV Implementasi Sistem dan Eksperimen menjelaskan mengenai skenario-skenario yang dilakukan dalam implementasi sistem, eksperimen pembangunan model bahasa, dan pembahasan
5. Bab V Kesimpulan dan Saran menyajikan ringkasan temuan utama penelitian, menarik kesimpulan berdasarkan bukti empiris, dan menawarkan rekomendasi untuk pengembangan selanjutnya.


BAB II

KAJIAN PUSTAKA

Pada bagian Kajian Pustaka akan dibahas secara terstruktur komponen-komponen utama yang menjadi dasar pengembangan sistem *neuroprosthesis* bicara. Berikut merupakan aspek yang akan diuraikan pada Bab II, yakni *neuroprosthesis* bicara (II.1), yang mencakup akuisisi aktivitas neural (II.1.1) beserta prosedur perekaman data aktivitas neural (II.1.1.1), ekstraksi fitur neural (II.1.2), dekoding probabilitas fonem (II.1.3), dan pemrosesan probabilitas fonem menjadi teks (II.1.4); model bahasa (II.1.5), yang terdiri atas model transformer (II.1.5.1), *fine-tuning* pada model transformer (II.1.5.2), perbandingan model transformer dengan n-gram (II.1.5.3), tantangan komputasi model transformer (II.1.5.4), dan *out-of-vocabulary* (II.1.5.5); evaluasi kinerja (II.2), yang membahas kecepatan dekoding (II.2.1) dan perhitungan tingkat kesalahan (II.2.2); dataset (II.3); serta penelitian terkait (II.4).

II.1 *Neuroprosthesis* Bicara

Neuroprosthesis bicara atau *speech neuroprosthesis* adalah teknologi yang dirancang untuk memulihkan kemampuan komunikasi pada individu yang kehilangan kemampuan berbicara, seperti pada pasien dengan *locked-in syndrome*, *aphasia*, atau gangguan neurologis lainnya. Teknologi ini memanfaatkan *covert speech*, yaitu proses di mana seseorang secara intens membayangkan berbicara tanpa menghasilkan vokalisasi fisik, untuk mengaktifkan sistem kontrol neural yang dapat mensintesis ucapan sesuai dengan apa yang mereka bayangkan (Rainey *et al.*, 2019).



Gambar II-1. Diagram Algoritma Dekoding Teks dari Aktivitas Neural (Metzger *et al.*, 2023)

Seperti yang dapat dilihat pada Gambar II-1, proses dekode teks yang dijelaskan dalam penelitian ini merujuk pada pendekatan yang digunakan oleh Metzger *et al.* (2023). Proses ini dimulai dengan perekaman aktivitas neural yang dihasilkan dari upaya berbicara secara diam-diam (*silent speech*). Aktivitas neural ini kemudian diproses untuk mengekstraksi fitur-fitur penting, yang menjadi input bagi jaringan saraf berulang dua arah (*bidirectional RNN*). Jaringan ini mengonversi fitur tersebut menjadi probabilitas untuk setiap fonem dan token jeda (*silence*) (Metzger *et al.*, 2023).

Probabilitas fonem tersebut diproses lebih lanjut menggunakan algoritma *Connectionist Temporal Classification* (CTC) dengan pencarian *beam* (*beam search*), yang menentukan urutan fonem yang paling mungkin. Urutan fonem ini kemudian diterjemahkan ke dalam kata-kata berdasarkan kosakata sistem. Model bahasa berbasis *n-gram* digunakan untuk menilai ulang (*rescore*) kalimat yang dihasilkan, sehingga menghasilkan kalimat akhir yang paling sesuai (Metzger *et al.*, 2023).

Perlu dicatat bahwa proses dekode teks dari aktivitas neural yang dijelaskan di atas adalah metodologi khusus yang digunakan dalam penelitian Metzger *et al.* (2023) dan mungkin berbeda dari pendekatan yang digunakan dalam penelitian *speech neuroprosthesis* lainnya.

II.1.1 Akuisisi Aktivitas Neural

Akuisisi aktivitas neural merupakan langkah esensial dalam sistem *speech neuroprosthesis*, di mana pemilihan metode perekaman sangat menentukan kualitas sinyal yang dapat diproses lebih lanjut. Terdapat dua pendekatan utama dalam akuisisi sinyal otak: metode non-invasif seperti *electroencephalography* (EEG) dan metode invasif seperti *electrocorticography* (ECoG). Meskipun EEG lebih unggul dari segi keamanan karena tidak memerlukan pembedahan, metode ini memiliki resolusi sinyal yang lebih rendah dibandingkan ECoG, sehingga kurang efektif untuk tugas kompleks seperti dekode ucapan. Sebaliknya, ECoG,

dengan menempatkan elektroda langsung di permukaan otak, menawarkan kualitas sinyal yang jauh lebih superior. Perbandingan kinerja yang lebih mendetail antara kedua metode ini disajikan pada Tabel II-1.


Tabel II-1 Perbandingan Kinerja EEG vs. ECoG

Fitur	EEG	ECoG
Prosedur & Risiko	Non-invasif: Elektroda ditempatkan di kulit kepala. Dianggap aman dan memiliki risiko minimal (Shih et al., 2012).	Invasif: Memerlukan kraniotomi (pembedahan otak) untuk menanam elektroda, yang membawa risiko bedah seperti infeksi dan pendarahan (Schalk & Leuthardt, 2011).
Resolusi Spasial	Rendah (beberapa sentimeter). Resolusi dibatasi oleh jumlah elektroda dan "masalah invers" (inverse problem), di mana sinyal dari satu sumber di otak menyebar ke banyak sensor di kulit kepala (Michel & Murray, 2012).	Tinggi (2-10 mm). Jarak antar elektroda pada grid ECoG berdensitas tinggi biasanya berkisar antara 2 hingga 10 mm, memungkinkan pemetaan yang sangat presisi (Schalk & Leuthardt, 2011).
<i>Signal-to-Noise Ratio</i> (SNR)	Rendah. Sinyal sangat dilemahkan oleh tengkorak dan jaringan lainnya, membuatnya rentan terhadap derau (Shih et al., 2012).	Tinggi. Amplitudo sinyal ECoG secara signifikan lebih besar, menghasilkan data yang lebih jernih dan stabil karena jarak yang dekat dengan sumber neuron (Schalk & Leuthardt, 2011).
Rentang Frekuensi Terdeteksi	Terbatas. Sulit untuk secara andal merekam aktivitas otak di atas 40 Hz karena atenuasi sinyal oleh tengkorak (Shih et al., 2012).	Sangat Luas (dapat melebihi 200 Hz). Mampu secara konsisten mendeteksi aktivitas di pita gamma tinggi (<i>high-gamma band</i>), yang sangat penting untuk aplikasi BCI (Schalk & Leuthardt, 2011).
Kerentanan Terhadap Artefak	Sangat rentan terhadap artefak dari aktivitas otot (EMG) dan kedipan mata (EOG), yang sering kali	Jauh lebih tahan. Karena terlindung oleh tengkorak, sinyal ECoG lebih terisolasi dari artefak otot dan

Fitur	EEG	ECoG
	amplitudonya lebih besar dari sinyal otak itu sendiri (Shih et al., 2012).	lingkungan (Waldert, 2016).


Berdasarkan keunggulan tersebut, ECoG menjadi pilihan utama dalam penelitian *speech neuroprosthesis* berkinerja tinggi. Kemampuannya untuk merekam sinyal dengan resolusi tinggi, stabilitas jangka panjang, dan presisi, serta menangkap *high-gamma activity* yang berkorelasi erat dengan artikulasi ucapan, menyediakan data yang kaya dan fundamental untuk proses dekoding. Oleh karena itu, untuk mencapai tujuan penelitian ini, yaitu memetakan sinyal neural menjadi representasi yang akurat, pendekatan ECoG dipilih sebagai metode akuisisi data.

Sejalan dengan pemilihan ini, penelitian yang dilakukan oleh Metzger et al. (2023) menggunakan perangkat *high-density electrocorticography* (ECoG) array yang dilengkapi dengan konektor pedestal perkutaneus (*percutaneous pedestal connector*). Perangkat ECoG ini, seperti yang ditunjukkan pada Gambar II-2, menggunakan 253 elektroda berbentuk cakram yang disusun dalam formasi kisi dengan jarak antar pusat elektroda sebesar 3 mm. Setiap elektroda memiliki diameter kontak rekaman sebesar 1 mm dan diameter keseluruhan sebesar 2 mm



Gambar II-2. Ilustrasi Implan ECoG pada Sistem *Speech Neuroprosthesis*
(<https://changlab.ucsf.edu>)

Array ini diimplan secara subdural di permukaan pial dari belahan kiri otak, mencakup area kortikal yang berperan penting dalam produksi ucapan dan persepsi bahasa. Area tersebut meliputi aspek tengah *superior temporal gyrus*, *middle temporal gyrus*, *precentral gyrus*, dan *postcentral gyrus*. Penempatan elektroda ini dapat dilihat pada rekonstruksi MRI peserta, seperti yang ditunjukkan pada Gambar II-3. Konektor pedestal perkutaneus, yang dipasang pada tengkorak selama prosedur yang sama, berfungsi mengalirkan sinyal listrik dari *array* ECoG ke perangkat digital kepala yang dapat dilepas (*digital headstage*). *Digital headstage* ini memproses sinyal secara minimal, mendigitalkan sinyal kortikal yang diambil, dan mentransmisikan data ke komputer untuk pemrosesan lebih lanjut. Perangkat ini diimplan di UCSF Medical Center pada September 2022 tanpa komplikasi bedah (Metzger *et al.*, 2023).



Gambar II-3. Rekonstruksi MRI otak peserta dengan lokasi elektroda yang diimplan. Area kortikal dan elektroda diberi warna berdasarkan wilayah anatomis (PoCG: *postcentral gyrus*, PrCG: *precentral gyrus*, SMC: *sensorimotor cortex*). (Metzger *et al.*, 2023)


Pendekatan berbasis *high-density* ECoG ini memungkinkan sistem untuk memperoleh sinyal neural dengan akurasi tinggi, memberikan landasan yang kuat untuk algoritma dekoding berbasis pembelajaran mendalam. Dengan kualitas perekaman yang unggul, sistem dapat memproses sinyal dengan lebih efektif untuk menghasilkan representasi fonem dan kata-kata yang akurat.

II.1.1.1. Prosedur Perekaman Data Aktivitas Neural

Dalam penelitian oleh Willett *et al.*, (2023), rekaman aktivitas neural diperoleh melalui implan *high-density electrocorticography* (ECoG) array yang terdiri dari 253 elektroda cakram dengan jarak antar-pusat 3 mm. Array ini diimplan secara subdural pada permukaan pial belahan kiri otak, mencakup area yang berperan dalam produksi ucapan dan persepsi bahasa, seperti *superior temporal gyrus*, *middle temporal gyrus*, *precentral gyrus*, dan *postcentral gyrus*. Sinyal *cortical* dari tiap elektroda dialirkan melalui konektor pedestal perkutaneus menuju *headstage digital* (CerePlex E256; Blackrock Microsystems), yang melakukan digitalisasi minimal dan transmisi data ke komputer untuk pemrosesan selanjutnya tanpa menimbulkan artefak besar pada kualitas sinyal.

Semua sesi perekaman dilakukan di area umum kediaman partisipan, dengan lingkungan yang dikondisikan untuk meminimalkan gangguan eksternal. Partisipan direkrut pada September 2022 setelah implantasi perangkat di *UCSF Medical Center*, dalam kerangka uji klinis fase awal yang dimulai sejak November 2018. Setiap sesi perekaman dijalankan menggunakan paket Python khusus bernama *rtNSR*, yang mengkoordinasikan alur koleksi data, sinkronisasi perangkat, dan pengelolaan proses decoding secara real time. Setelah setiap sesi, data mentah diunggah ke infrastruktur server laboratorium untuk analisis dan pelatihan model lebih lanjut.

Paradigma eksperimen dirancang untuk merekam upaya berbicara secara diam-diam (*silent speech*). Pada tiap trial, partisipan disajikan target teks yang dikelilingi tiga titik sebagai hitung mundur; setelah titik terakhir menghilang dan teks berubah hijau (*go cue*), partisipan mencoba mengucapkan target secara diam. Seluruh sinyal ECoG selama periode *silent speech* direkam penuh, mencakup *high-gamma activity* dan *low-frequency signals*, yang kemudian menjadi dasar pelatihan *neural-decoding models*. Penggunaan paradigma ini memastikan bahwa waktu onset dan durasi setiap percobaan tercatat dengan presisi, memungkinkan korelasi yang akurat antara pola aktivitas neural dan isi target ucapan.



Gambar II-4. Tampilan Eksperimen *Silent Speech* dengan Pemasangan *High-Density ECoG Array*. (Willett *et al.*, 2023)

Proses perekaman aktivitas neural ditunjukkan pula pada Gambar II-4. Pada gambar tersebut, partisipan terlihat mengenakan headstage digital dan array ECoG subdural sambil menjalani paradigma *silent speech*, teks target muncul di layar, diikuti *go-cue* (teks berubah hijau) untuk memulai percobaan (Block: 18, Trial: 5). Visualisasi ini memperjelas tata letak elektroda, posisi *headstage*, serta antarmuka eksperimen yang digunakan untuk mensinkronkan onset *silent speech* dengan perekaman sinyal *cortical*.

II.1.2 Ekstraksi Fitur Neural

Setelah aktivitas neural berhasil direkam, langkah berikutnya adalah mengekstraksi fitur-fitur penting dari sinyal yang telah diperoleh. Fitur-fitur ini esensial untuk mengidentifikasi pola aktivitas neural yang relevan dengan produksi ucapan. Seperti yang ditunjukkan pada Gambar II-1, Metzger *et al.* (2023) memproses sinyal neural menggunakan teknik *temporal binning* dan *smoothing*. Teknik ini bertujuan untuk mengorganisasi sinyal neural ke dalam format yang terstruktur secara temporal, sehingga dapat digunakan secara optimal sebagai input bagi model pembelajaran mendalam, seperti jaringan saraf berulang dua arah (*bidirectional RNN*).


Proses *temporal binning* melibatkan pengelompokan sinyal neural dalam interval waktu tertentu, yang memungkinkan sistem untuk menangkap dinamika temporal dari sinyal tersebut. Sinyal yang telah dikelompokkan ini kemudian melalui proses *smoothing*, yang bertujuan untuk mengurangi kebisingan (*noise*) tanpa kehilangan informasi penting yang terkandung dalam sinyal neural. Pendekatan ini memastikan bahwa sinyal neural yang dihasilkan memiliki kualitas yang cukup baik untuk mendukung akurasi prediksi pada tahap dekoding berikutnya.

Pada penelitian lebih lanjut oleh Willett *et al.* (2023), langkah pertama dalam ekstraksi fitur adalah memisahkan sinyal mentah menjadi dua rentang frekuensi utama: *low-frequency* (1-40 Hz) untuk menangkap potensi lokal lambat dan *high-gamma* (70-200 Hz) sebagai proxy aktivitas populasi neuronal yang berkorelasi kuat dengan produksi bicara. Filter *band-pass* FIR berorde tinggi digunakan untuk masing-masing rentang ini, kemudian diterapkan transformasi Hilbert pada sinyal *high-gamma* guna memperoleh *envelope* amplitudo. Envelope tersebut lantas di-*down-sample* ke 200 Hz agar seirama secara temporal dengan sinyal *low-frequency*.

Setelah pemfilteran, seluruh kanal dinormalisasi melalui *z-scoring* terhadap periode resting state, dan nilai-nilai di luar rentang $\pm 3\sigma$ di-*clipping* untuk meminimalkan artefak transient. Dari sinyal yang telah diproses ini dihitung beberapa metrik inti, antara lain rata-rata *power spectral density* pada *high-gamma*, nilai *mean amplitude* pada *low-frequency*, serta *slope* dan *intercept* dari regresi linear pada spektrum *log, log* yang menggambarkan karakteristik *noise 1/f*. Setiap kanal kemudian diberi label menurut kategori artikulator (*labial, front tongue, back tongue, dan vocalic*), sehingga pola respons *cortical* untuk tiap kelas artikulasi dapat dipelajari oleh model *decoding* neural.

Penting untuk dicatat bahwa tidak semua aktivitas neural yang direkam berhubungan langsung dengan produksi ucapan. Hanya aktivitas neural yang berasal dari area otak yang terlibat dalam kontrol motorik bicara yang digunakan dalam ekstraksi fitur. Aktivitas dari area yang tidak terkait dengan produksi suara atau artikulasi, seperti pergerakan tangan atau proses mental lainnya, tidak diproses dalam tahap ini. Oleh karena itu, penempatan elektroda pada area yang

relevan sangat krusial. Seperti yang dijelaskan dalam Gambar II-5, lokasi array elektroda yang tepat memungkinkan pengambilan sinyal neural dari wilayah yang berperan dalam produksi ucapan. Gambar tersebut memperlihatkan lokasi array elektroda dan data fMRI yang dipetakan terhadap parselasi kortikal yang dihasilkan oleh Human Connectome Project (HCP). Panel (a) menunjukkan posisi array elektroda langsung di permukaan otak selama operasi, sementara panel (b) menggambarkan posisi array pada rekonstruksi 3D otak, dengan sumbu koordinat elektroda yang berwarna. Panel (c) menampilkan lokasi array pada otak yang telah diturunkan (inflated brain) dengan pembatas area kortikal yang ditentukan oleh HCP, sementara panel (d) mengoverlay lokasi array pada peta kepercayaan wilayah areal. Panel (e) mengidentifikasi jaringan keadaan istirahat yang terkait dengan bahasa dalam data HCP dan penempatannya pada otak peserta, sementara panel (f) menunjukkan jaringan yang sama pada pemindaian individual.



Gambar II-5 Lokasi Implan Array dan Data fMRI yang Diperlihatkan Relatif terhadap Area Otak yang Diidentifikasi oleh HCP (Willett *et al.*, 2023)

Proses ekstraksi fitur neural sangat dipengaruhi oleh pemilihan lokasi elektroda yang tepat, yang tercermin jelas dalam Gambar II-5. Dalam hal ini, elektroda-array yang terletak pada area-area otak yang relevan, seperti area 6v dan area 44, yang berperan dalam produksi bahasa, menjadi sumber utama untuk menganalisis aktivitas neural terkait dengan fonem dan pergerakan artikulatoris. Pemilihan lokasi ini, berdasarkan parselasi kortikal HCP, memungkinkan identifikasi area spesifik yang berhubungan dengan decoding bahasa, serta pengolahan fonem. Selain itu, data fMRI yang disertakan memberikan konteks tambahan untuk menilai sejauh mana area yang ditargetkan terlibat dalam jaringan keadaan istirahat yang berhubungan dengan bahasa. Hal ini pada gilirannya mendukung pemetaan sinyal neural yang lebih efektif pada proses dekoding fonem. Dengan demikian, proses ekstraksi fitur neural lebih difokuskan pada aktivitas yang memang bertanggung jawab atas produksi ucapan, mengoptimalkan akurasi dan relevansi data yang digunakan dalam tahap dekoding.

Pendekatan temporal binning dan smoothing yang diadopsi Metzger *et al.* (2023) memperkaya struktur temporal sinyal sebelum ekstraksi fitur, sedangkan studi pendukung lainnya (Moses *et al.*, 2021; Pandarinath *et al.*, 2018) menegaskan bahwa kualitas pengolahan awal ini sangat menentukan akurasi prediksi fonem. Dengan fitur-fitur yang terstruktur dan terstandarisasi, model pembelajaran mendalam, seperti bidirectional RNN, dapat melakukan dekoding ucapan secara lebih presisi.

II.1.3 Dekoding Probabilitas Fonem


Setelah fitur neural berhasil diekstraksi, langkah berikutnya dalam sistem *speech neuroprosthesis* adalah dekoding fonem. Fonem merupakan elemen dasar dalam ucapan, sehingga prediksi yang akurat menjadi komponen kunci dalam proses dekoding. Pada penelitian yang dilakukan oleh Metzger *et al.* (2023), fitur neural yang telah diproses dimasukkan ke dalam jaringan saraf berulang dua arah (*bidirectional recurrent neural network*, BiRNN), seperti yang ditunjukkan pada Gambar II-1. BiRNN digunakan karena kemampuannya untuk memodelkan hubungan temporal dalam sinyal neural, baik dari urutan sebelumnya maupun setelahnya. Model ini menghasilkan distribusi probabilitas untuk setiap fonem,

token jeda (*silence*), serta token kosong (*blank*) yang digunakan dalam prosedur pelatihan *connectionist temporal classification* (CTC).

Distribusi probabilitas yang dihasilkan oleh BiRNN merepresentasikan kemungkinan fonem yang paling mungkin dihasilkan pada setiap segmen waktu. Probabilitas ini bukanlah fonem final, melainkan langkah awal yang menjadi dasar bagi proses lebih lanjut, yaitu konversi probabilitas fonem menjadi teks. Pendekatan berbasis BiRNN memberikan keunggulan karena mempertimbangkan konteks temporal dalam kedua arah. Hal ini sangat penting untuk memahami pola neural yang kompleks yang terkait dengan produksi ucapan. Proses dekoding ini dilakukan dengan tetap mempertimbangkan variasi dalam produksi ucapan yang mungkin terjadi akibat kondisi fisiologis atau lingkungan.

Penelitian lain, seperti Moses et al. (2021), mendukung penggunaan jaringan saraf berulang untuk dekoding ucapan. Mereka mencatat bahwa model berbasis RNN mampu menangkap dinamika temporal dari aktivitas neural yang tidak dapat diakomodasi oleh model statis. Selain itu, Hannun et al. (2014) menunjukkan bahwa prosedur *connectionist temporal classification* memberikan fleksibilitas dalam pemetaan input ke output tanpa memerlukan penyelarasan (*alignment*) eksplisit antara data neural dan fonem.

Dekoding fonem yang akurat melalui BiRNN memberikan landasan bagi langkah-langkah selanjutnya dalam sistem, termasuk penerjemahan fonem menjadi kata dan kalimat. Dengan kemampuan model untuk memanfaatkan konteks temporal, sistem ini mampu menangkap pola neural yang relevan untuk menghasilkan sistem *speech neuroprosthesis* yang lebih alami dan akurat.



Gambar II-6 Enkoding Artikulatoris untuk Dekoding Ucapan.

(Metzger *et al.*, 2023)


Gambar II-6 menunjukkan enkoding artikulatoris untuk dekoding ucapan. Panel (a) menggambarkan skematik artikulatoris dalam potongan *sagittal tractus* vokal. Panah berwarna pada *labial* (p, b), *front tongue* (t, d), *back tongue* (k, g), dan *vocalic* (a, ʌ) menunjukkan lokasi dan arah gerakan masing-masing artikulator saat mengucapkan fonem terkait. Panel (b) menampilkan *heatmap* magnitudo enkoding *high-gamma* yang telah dinormalisasi ke rentang [0-1]. Sumbu horizontal memuat daftar fonem, sedangkan sumbu vertikal adalah elektroda-elektroda ECoG, dengan dendrogram di atas heatmap yang mengelompokkan fonem berdasarkan kemiripan pola respons kortikal. Intensitas

warna gelap pada kotak menunjukkan kekuatan encoding yang tinggi pada elektroda tertentu untuk fonem tersebut.

Ringkasan distribusi respons tersebut hadir di panel (c), di mana magnitudo encoding (*z-scored*) rata-rata untuk empat kategori artikulator yaitu *labial*, *vocalic*, *back tongue*, dan *front tongue* ditampilkan dalam satu bar heatmap. Zona dengan warna gelap mengindikasikan area korteks yang paling sensitif terhadap setiap kategori artikulator. Selanjutnya, panel (d) dan (e) menerapkan *multidimensional scaling* (MDS) untuk memproyeksikan pola encoding *high-gamma* ke dalam dua dimensi: pada panel (d) konsonan dikelompokkan berdasarkan *front-tongue* (biru), *back-tongue* (hijau), dan *labial* (jingga), sedangkan pada panel (e) vokal dipisahkan antara *unrounded* dan *rounded* pada sumbu MDS1, menegaskan pemisahan spasial antara dua kelas vokal tersebut.

Visualisasi lebih rinci diberikan oleh panel (f), yang menggabungkan distribusi kepadatan *envelope high-gamma* (diagram density di atas dan kiri) dengan topografi elektroda pada permukaan korteks. Elektroda-elektroda dengan sensitivitas tinggi untuk *labial*, *front-tongue*, dan *back-tongue* ditandai dengan lingkaran merah, biru, dan kuning; elektroda dengan respons minimal berwarna hitam. Kurva hitam menandai letak *sulkus centralis* (CS) dan *sulkus fissura* (SF). Akhirnya, panel (g), (h), dan (i) memperlihatkan *scatter plot* korelasi antara fitur artikulasi tertentu dan kekuatan respons *high-gamma*. Panel (g) menunjukkan korelasi positif *front-tongue phones* terhadap parameter “*raise tongue*” ($r = 0,84$, $p < 0,0001$), panel (h) menggambarkan korelasi positif *labial phones* dengan “*round lips*” ($r = 0,89$, $p < 0,0001$), dan panel (i) memperlihatkan korelasi negatif antara pembulatan bibir dan naik-tundanya lidah, mengilustrasikan *trade-off* spasial dalam representasi kortikal antara kontrol bibir dan lidah. Dengan demikian, seluruh subpanel pada Gambar II-6 menguatkan bagaimana encoding artikulatoris di berbagai area korteks menjadi pendorong utama dalam dekoding ucapan berbasis model neural.

II.1.4 Pemrosesan Probabilitas Fonem Menjadi Teks



Gambar II-7. Ilustrasi Urutan Probabilitas Fonem (Metzger *et al.*, 2023)

Setelah probabilitas fonem diprediksi oleh jaringan saraf berulang dua arah (*bidirectional recurrent neural network*, BiRNN), langkah berikutnya adalah mengonversi probabilitas tersebut menjadi teks yang dapat dimengerti. Pada penelitian Metzger *et al.* (2023), proses ini dilakukan menggunakan algoritma *Connectionist Temporal Classification (CTC) beam-search*, seperti yang ditunjukkan pada Gambar II-1. Algoritma ini menentukan urutan fonem yang paling mungkin berdasarkan probabilitas yang dihasilkan oleh BiRNN. Urutan probabilitas fonem seperti yang diilustrasikan pada Gambar II-7 tersebut kemudian dikombinasikan dengan model bahasa untuk meningkatkan akurasi dan memastikan kalimat yang dihasilkan secara linguistik valid.

CTC *beam-search* berfungsi dengan menghitung kemungkinan suatu kalimat berdasarkan probabilitas emisi fonem yang diprediksi serta prior dari model bahasa. Model bahasa memainkan peran penting dalam proses ini dengan memberikan konteks linguistik yang membantu menentukan kata atau urutan kata yang paling relevan secara semantik dan sintaksis. Dalam penelitian ini, digunakan model bahasa *5-gram* dengan *Kneser-Ney smoothing*, yang dilatih menggunakan perangkat lunak KenLM pada 18.284 kalimat dari kumpulan data percakapan sehari-hari. Model ini memprediksi kemungkinan sebuah kata berdasarkan empat kata sebelumnya, sehingga memberikan konteks yang kuat untuk menghasilkan teks yang lebih natural.

Pada tahap pemrosesan probabilitas fonem menjadi teks, *lexicon* berfungsi membatasi urutan fonem sehingga hanya menghasilkan kata-kata valid dalam

kosakata yang tersedia. *Lexicon* ini dihasilkan oleh modul *g2p-en* (*grapheme-to-phoneme conversion*), yang memetakan setiap orthografi (*grapheme*) ke urutan fonem (*phoneme*) yang benar, misalnya “*cat*” dipetakan menjadi /K AE T/, “*dog*” dipetakan menjadi /D AO G/, atau “*thought*” dipetakan menjadi /TH AO T/.

Setelah BiRNN menghasilkan probabilitas emisi fonem per waktu, algoritma CTC *beam-search* mencari kalimat $\hat{W}$ yang memaksimalkan skor gabungan antara kecocokan sinyal dan prior bahasa seperti yang ditunjukkan pada Formula II-1 (Metzger *et al.*, 2023).

$$\hat{W} = \arg \max_{W_i} \left[\log p_{\text{CTC}}(W_i | X) + \alpha \log p_{\text{LM}}(W_i) - \beta |W_i| \right] \quad (\text{II-1})$$

$p_{\text{CTC}}(W_i | x_i)$ merupakan probabilitas emisi urutan fonem yang dihasilkan oleh BiRNN serta algoritma CTC *beam-search* ketika diberikan input fitur neural x_i sedangkan $p_{\text{LM}}(W_i)$ adalah probabilitas kalimat W_i menurut model bahasa yang dilatih pada korpus. Parameter α berfungsi sebagai bobot untuk menguatkan atau melemahkan kontribusi model bahasa terhadap keputusan akhir, dan β adalah penalti yang dikenakan berdasarkan panjang kalimat $|W_i|$ untuk mencegah *over-insertion* kata. Operator *arg max* memilih kalimat W_i dengan skor gabungan tertinggi, menghasilkan teks akhir yang paling sesuai baik dari sisi kecocokan sinyal neural maupun kelayakan linguistik.

Prosedur perhitungannya dijelaskan sebagai berikut:

1. Inisialisasi beam dengan prefiks kosong dan skor 0.
2. Untuk tiap *frame* waktu t :
 - a. Ekspansi setiap prefiks w dengan semua fonem k , hitung
$$\text{score}(w + k) = \text{score}(w) + \log p_{\text{RNN}}(k | X_t).$$
 - b. Jika k adalah spasi (batas kata), tambahkan $\alpha \log p_{\text{LM}}(\text{kata baru})$ dan kurangi β .

- c. Terapkan aturan blank merging dan batas beam width B .
3. Setelah frame terakhir, tambahkan penalti panjang $-\beta|W|$ pada setiap skor.
4. Pilih $\widehat{W}$ dengan skor tertinggi.

Tabel II-2 Ilustrasi Akumulasi Probabilitas Fonem

t	$p(c)$	$p(ae)$	$p(t)$	Prefiks Kandidat	Skor Akumulasi
1	0,60	0,30	0,05	“c”	$\log 0,60 = -0,51$
				“ae	$\log 0,30 = -1,20$
				“t”	$\log 0,05 = -2,99$
2	0,10	0,80	0,05	“c ae”	$-0,51 + \log 0,80 + \alpha \log p_{LM}("c ae")$ $\approx -0,51 - 0,22 + 0,5(0) = -0,73$
				“ae c”	$-1,20 + \log 0,10 + \alpha \log p_{LM}("ae c")$ $\approx -1,20 - 2,30 + 0,5(0) = -3,50$
				“c c”	$-0,51 + \log 0,10 + \alpha \log p_{LM}("c c")$ $\approx -0,51 - 2,30 + 0,5(0) = -2,81$
3	0,10	0,10	0,75	“c ae t”	$-0,73 + \log 0,75 - \beta \cdot 3$ $= -0,73 - 0,29 - 3 = -4,02$ (skor tertinggi setelah penalti panjang)

Tabel II-1 mengilustrasikan proses akumulasi probabilitas fonem yang dihasilkan oleh BiRNN, kemudian dikombinasikan dengan probabilitas dari model bahasa, serta dikenai penalti panjang (β) untuk menghasilkan skor akhir. Berdasarkan skor ini, kata “*cat*” dipilih sebagai output. Misalkan $\alpha = 0,5$ dan $\beta = 1$, dan diasumsikan skor log-probabilitas model bahasa ($\log p_{LM}$) sebesar 0 untuk setiap prefix agar fokus pada mekanisme penggabungan skor.

Dari akumulasi tersebut, setiap kandidat kata dievaluasi berdasarkan skor total, dan prefiks yang memiliki skor tertinggi dipilih sebagai hasil sementara sebelum tahap *collapse* CTC. Langkah *collapse* kemudian menyederhanakan urutan fonem menjadi kata tertulis.

Setelah proses *collapse*, algoritma CTC *beam-search* (Metzger *et al.*, 2023) menerapkan *lexicon* untuk membatasi hanya pada kata-kata valid, dan akhirnya memilih teks W yang paling mungkin secara akustik dan linguistik berdasarkan kombinasi sinyal neural, prior bahasa, dan penalti panjang kalimat. Ilustrasi bagaimana urutan fonem dari BiRNN dibatasi oleh *lexicon* lalu didekode menjadi teks ditunjukkan pada Tabel II-2.

Tabel II-3 Ilustrasi Keluaran Dekoding Urutan Fonem

Urutan Fonem	Teks Keluaran
/D UW SIL Y UW SIL W AA N T SIL T UW SIL S T AA R T SIL/	<i>do you want to start</i>
/IH T SIL W ER K S SIL JH AH S T SIL F AY N SIL/	<i>it works just fine</i>
/DH AH SIL W EH DH ER SIL W AO R M SIL IH N AH F SIL T UW SIL S T IH K SIL IH N SIL DH AH SIL G R AW N D SIL/	<i>the weather warm enough to stick it in the ground</i>

II.1.5 Model Bahasa

Seperti yang telah disinggung pada subbab II.1.4, model bahasa adalah elemen penting dalam sistem *speech neuroprosthesis*, yang berfungsi meningkatkan

akurasi dekoding dengan memberikan konteks linguistik pada urutan fonem yang telah diprediksi. Dalam proses dekoding, probabilitas fonem yang dihasilkan oleh BiRNN digabungkan dengan prior linguistik dari model bahasa. Gabungan ini membantu sistem mengurangi ambiguitas dalam prediksi, memastikan kalimat yang dihasilkan valid secara semantik dan sintaksis.

Pada penelitian Metzger *et al.* (2023), model bahasa berbasis 5-gram dengan Kneser-Ney *smoothing* digunakan untuk memprediksi kemungkinan sebuah kata berdasarkan empat kata sebelumnya. Model ini dilatih menggunakan perangkat lunak KenLM pada kumpulan data percakapan sehari-hari, mencakup 18.284 kalimat. Pemilihan data percakapan informal seperti kutipan film dan *tweet* memungkinkan model bahasa menghasilkan hasil yang relevan untuk aplikasi komunikasi sehari-hari, berbeda dari data formal yang umumnya digunakan dalam pengenalan ucapan.

Penelitian Willett *et al.* (2023) menambahkan dimensi baru dengan penggunaan model bahasa berkosakata besar (*large-vocabulary language model*), yakni model trigram khusus dengan 125.000 kata yang diimplementasikan menggunakan Kaldi. Model ini dirancang untuk menangani dekoding percakapan umum, memungkinkan sistem untuk menghasilkan kalimat yang lebih kompleks dan kontekstual.


Selain itu, Willett *et al.* juga menekankan pentingnya parameterisasi, seperti *language model weight* dan *word insertion score*, dalam menyeimbangkan kontribusi model bahasa dengan probabilitas fonem yang dihasilkan oleh jaringan saraf. Parameterisasi ini memastikan model bahasa tidak mendominasi hasil dekoding, sehingga menjaga keseimbangan antara keakuratan linguistik dan prediksi probabilitas neural.

Kedua penelitian ini menunjukkan bahwa model bahasa tidak hanya berfungsi sebagai pendukung, tetapi juga menjadi inti dalam sistem dekoding berbasis neural. Dengan integrasi yang kuat antara probabilitas fonem, lexicon berbasis fonem, dan model bahasa, sistem *speech neuroprosthesis* mampu menghasilkan teks yang tidak hanya akurat tetapi juga sesuai dengan kebutuhan komunikasi pengguna.

II.1.5.1 Model Transformer

Model transformer, seperti yang diperkenalkan oleh Vaswani *et al.* (2017), telah menjadi dasar dari banyak inovasi dalam teknologi pemrosesan bahasa alami dan pengenalan ucapan. Model ini mengandalkan mekanisme perhatian (*attention mechanism*) untuk memahami hubungan antar elemen dalam data masukan, sehingga memungkinkan pemrosesan yang lebih fleksibel dan efisien dibandingkan pendekatan tradisional seperti model berbasis *n-gram* atau jaringan saraf berulang (*recurrent neural network*, RNN).

Arsitektur dasar transformer terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*, seperti yang ditunjukkan pada Gambar II-4. *Encoder* bertugas memproses data masukan, seperti sinyal ucapan yang telah diubah menjadi representasi vektor, melalui serangkaian lapisan *self-attention* dan jaringan *feed-forward point-wise*. *Decoder*, di sisi lain, bertugas menghasilkan keluaran seperti teks atau fonem berdasarkan informasi yang diproses oleh *encoder*.



Gambar II-8. Arsitektur Model Transformer (Vaswani *et al.*, 2017)

Seperti yang diilustrasikan pada Gambar II-8, bagian kiri menunjukkan struktur *encoder*, sementara bagian kanan menggambarkan struktur *decoder*. Transformer

menggunakan lapisan *self-attention* bertumpuk dan jaringan *fully connected* yang terhubung secara *point-wise* untuk kedua komponen ini (Vaswani *et al.*, 2017). Lapisan-lapisan ini dirancang untuk menangkap hubungan antar elemen dalam data masukan dengan cara yang efisien. Pada *decoder*, lapisan tambahan berupa *masked self-attention* memastikan bahwa prediksi dilakukan secara autoregresif, yaitu memprediksi elemen keluaran satu per satu berdasarkan elemen-elemen sebelumnya. Mekanisme *attention* dalam *decoder* memungkinkan fokus pada elemen-elemen masukan yang relevan, menghasilkan keluaran yang lebih akurat dan sesuai konteks.

Mekanisme *attention*, khususnya *self-attention*, menjadi inti dari model transformer. Mekanisme ini memungkinkan model untuk menghitung relevansi antar elemen dalam data masukan melalui pendekatan *scaled dot-product attention*. Formula yang digunakan adalah sebagai berikut:

$$Attention(Q, K, V) = softmax \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (II-1)$$

Dalam formula ini, Q , K , dan V masing-masing mewakili *queries*, *keys*, dan *values*, yang merupakan representasi vektor yang dihasilkan dari data masukan melalui transformasi linear. *Queries* (Q) menunjukkan elemen dalam data masukan yang sedang mencari informasi relevan dari elemen lain. *Keys* (K) menyediakan konteks untuk setiap elemen dalam data masukan, sedangkan *values* (V) berisi informasi aktual yang akan dikombinasikan dengan bobot perhatian. Matriks QK^T adalah hasil perkalian antara *queries* dan transposisi *keys*, yang menghasilkan skor perhatian untuk setiap pasangan elemen dalam data masukan. Faktor $\sqrt{d_k}$ digunakan untuk menormalkan hasil perkalian ini, sehingga mencegah bobot perhatian menjadi terlalu besar ketika dimensi d_k tinggi. Operasi *softmax* memastikan bahwa bobot perhatian terdistribusi dengan benar dan bernilai antara 0 dan 1.

Salah satu keunggulan utama transformer adalah kemampuannya untuk memproses elemen dalam data masukan secara paralel, yang meningkatkan

efisiensi komputasi secara signifikan dibandingkan model RNN. Selain itu, dengan mekanisme *attention*, model ini mampu memahami hubungan jangka panjang dalam data, sehingga meningkatkan kapasitasnya dalam menangkap konteks semantik dan sintaksis. Kemampuan ini membuat transformer unggul dalam berbagai tugas pemrosesan bahasa alami, termasuk pengenalan ucapan dan penerapan dalam sistem *speech neuroprosthesis*.

Model transformer, seperti GPT atau BERT, telah menunjukkan performa yang unggul dalam berbagai aplikasi, termasuk penerjemahan bahasa, klasifikasi teks, dan pengenalan ucapan. Dengan fleksibilitas untuk dilatih pada data yang beragam tanpa memerlukan anotasi manual yang ekstensif, model ini menjadi solusi yang sangat relevan untuk sistem berbasis *speech neuroprosthesis*. Keunggulannya dalam menangkap pola linguistik yang rumit membuka peluang untuk meningkatkan akurasi dan efisiensi sistem *speech neuroprosthesis*, menjadikannya alat yang lebih andal bagi pengguna dengan gangguan komunikasi.

II.1.5.2 *Fine-Tuning* pada Model Transformer

Fine-tuning adalah teknik adaptasi model pembelajaran mendalam yang sudah dipra-latih (*pretrained*) pada data besar, kemudian dioptimalkan lebih lanjut menggunakan data khusus domain yang hendak ditangani. Ide dasarnya, model Transformer mempelajari representasi umum urutan (seperti fonem atau teks) selama pra-pelatihan, setelah itu bobot-bobotnya disesuaikan (*di-fine-tune*) agar sensitif terhadap karakteristik sinyal neural spesifik partisipan.

Pada publikasi Devlin *et al.* (2018), misalnya, model BERT (“*Bidirectional Encoder Representations from Transformers*”) dipra-latih pada korpus teks skala besar dan kemudian hanya “*di-fine-tune*” dengan menambahkan satu lapis output untuk tugas *downstream* seperti *question answering*, menghasilkan kinerja unggul tanpa merombak arsitektur aslinya. Prinsip serupa juga diterapkan dalam *domain speech recognition* yang mana model *Speech-Transformer* dipra-latih *end-to-end* pada dataset umum (misalnya LibriSpeech) kemudian *di-fine-tune* pada data bicara khusus (misalnya percakapan *dysarthric*), memperlihatkan peningkatan akurasi yang signifikan pada kondisi *low-resource*.

Secara umum, langkah-langkah fine-tuning pada model Transformer meliputi:

1. Inisialisasi bobot dari model Transformer yang telah dipra-latih.
2. Pembekuan (*freeze*) sebagian lapisan awal agar representasi dasar yang kaya tidak hilang.
3. *Unfreeze* dan pelatihan ulang (*re-training*) lapisan-lapisan akhir, terutama *self-attention* dan *feed-forward layers*, dengan data fitur neural dan label fonem dari partisipan.
4. Penyesuaian *hyperparameter* seperti *learning rate* rendah (sering di kisaran $1e-5$), pemilihan *optimizer* (misalnya AdamW), dan jumlah *epoch* yang relatif sedikit untuk mencegah *overfitting*.

Fine-tuning memungkinkan model Transformer memanfaatkan representasi umum yang kaya dari pra-pelatihan sehingga hanya membutuhkan dataset yang relatif kecil dan waktu pelatihan singkat untuk beradaptasi dengan tugas spesifik. Hal ini jelas lebih efisien dibandingkan melatih model Transformer dari awal (*from scratch*), yang menuntut ketersediaan data berukuran besar, waktu komputasi yang jauh lebih lama, serta risiko *overfitting* yang lebih tinggi pada dataset terbatas. Dengan *fine-tuning*, model dapat mencapai kinerja yang setara atau bahkan lebih baik dengan sumber daya yang jauh lebih sedikit dan proses yang lebih cepat.

II.1.5.3 Perbandingan Model Transformer dengan N-gram

Dalam konteks pengembangan sistem *speech neuroprosthesis*, model transformer dan n-gram memiliki perbedaan mendasar dalam pendekatan mereka terhadap pemrosesan data linguistik. Model transformer, yang didasarkan pada mekanisme *attention*, memiliki kemampuan untuk memahami hubungan kontekstual antar kata dalam rentang yang jauh lebih luas dibandingkan model *n-gram*. Sebaliknya, model *n-gram* mengandalkan distribusi probabilitas linear yang hanya mencakup sejumlah kata sebelumnya dalam sebuah urutan (Svete & Cotterell, 2024).

Menurut Svete & Cotterell (2024), model transformer dapat mewakili model n-gram dengan melatih bobot perhatian untuk meniru perilaku n-gram. Namun, kemampuan transformer untuk melampaui batasan lokal model n-gram

memungkinkan pendekatan ini memahami pola linguistik global yang tidak dapat ditangkap oleh n-gram. Transformer juga menunjukkan performa yang lebih baik dalam memahami struktur kalimat kompleks, bahkan ketika menghadapi data percakapan yang bervariasi (Svete *et al.*, 2024).

Model n-gram, seperti model 5-gram, memiliki keunggulan dalam efisiensi dan kesederhanaan. Namun, keterbatasannya dalam menangkap hubungan konteks jangka panjang menjadikannya kurang adaptif dalam tugas yang membutuhkan pemahaman konteks global, seperti pengenalan ucapan dalam sistem neuroprosthesis. Di sisi lain, model transformer, dengan mekanisme *multi-head attention*, dapat menganalisis hubungan antar elemen dalam data masukan tanpa batasan linier, sehingga lebih cocok untuk aplikasi dengan kosakata besar atau data percakapan yang kompleks (Svete *et al.*, 2024).

II.1.5.4 Tantangan Komputasi Model Transformer

Meskipun model Transformer dengan mekanisme self-attention menawarkan fleksibilitas dan kemampuan pemrosesan paralel yang lebih baik dibandingkan model sekuensial seperti RNN, model ini menghadapi tantangan komputasi yang signifikan, terutama ketika menangani urutan input yang panjang. Salah satu kendala utama adalah kompleksitas kuadratik $O(n^2)$ pada mekanisme self-attention, di mana n adalah panjang input. Setiap token dalam urutan harus berinteraksi dengan setiap token lainnya, menghasilkan kebutuhan komputasi dan memori yang meningkat secara eksponensial seiring bertambahnya panjang input. Vaswani *et al.* (2017) menyebutkan bahwa meskipun perhatian penuh (*full attention*) memberikan konteks global yang kuat, biaya komputasi menjadi hambatan serius dalam penerapan pada skala besar.

Selain itu, keterbatasan memori perangkat keras menjadi penghalang utama dalam pelatihan dan inferensi model skala besar. Kitaev *et al.* (2020) mencatat bahwa peningkatan panjang urutan menyebabkan lonjakan penggunaan memori hingga beberapa *gigabyte* hanya untuk satu *batch* input. Akibatnya, banyak model transformer dibatasi pada panjang *input* sekitar 512 hingga 4096 token, yang tidak mencukupi untuk aplikasi seperti pemrosesan dokumen panjang, kode program besar, atau dialog multi-putaran. Keles *et al.* (2022) juga menunjukkan bahwa

batas kompleksitas kuadratik ini bukan hanya kendala teknis, melainkan juga kendala teoritis yang sulit dielakkan tanpa mengorbankan akurasi atau sifat penting dari perhatian penuh.

Untuk mengatasi tantangan di atas, para peneliti telah mengembangkan berbagai pendekatan untuk mengurangi beban komputasi Transformer:

1. Optimalisasi Mekanisme *Attention*

Pendekatan fundamental untuk mengatasi kompleksitas komputasi kuadratik pada *self-attention* adalah dengan memodifikasi matriks perhatian, beralih dari *full attention* menjadi bentuk yang lebih efisien:

a. *Sparse Attention*

Alih-alih menghitung interaksi antara setiap pasangan token, *sparse attention* membatasi koneksi hanya pada subset token tertentu. Ini dapat diimplementasikan melalui *attention* lokal (interaksi hanya dengan token terdekat), *attention* berdasarkan pola (misalnya, setiap token hanya memperhatikan token ke- k), atau *attention sliding window*. Model-model seperti Longformer (Beltagy *et al.*, 2020) dan BigBird (Zaheer *et al.*, 2020) berhasil mengurangi kompleksitas menjadi $O(n)$ atau $O(n \log n)$.

b. *Linear Attention*

Beberapa metode berupaya mentransformasi kompleksitas *attention* menjadi linier dengan mendekati atau memproyeksikan matriks perhatian. Teknik ini sering memanfaatkan *kernel methods* atau *random features*. Contoh yang relevan meliputi Performer (Choromanski *et al.*, 2020) dan Linformer (Wang *et al.*, 2020).

c. *Query-Key Sparsity*

Metode ini mengidentifikasi pasangan *query-key* yang paling signifikan dan hanya menghitung perhatian untuk pasangan tersebut. Pendekatan ini dapat melibatkan teknik *hashing* (seperti pada Reformer oleh Kitaev *et al.*, 2020) atau *clustering* untuk mengelompokkan queries dan keys yang serupa.

d. *Fixed Pattern Attention*

Pendekatan ini menggunakan pola perhatian yang telah ditentukan sebelumnya dan tidak bergantung pada data, misalnya, dengan membatasi perhatian pada token-token di jendela tertentu atau token penting yang jarang.

2. Kuantisasi (*Quantization*)

Kuantisasi adalah proses pengurangan presisi numerik bobot dan/atau aktivasi model, umumnya dari representasi floating point 32-bit (FP32) menjadi representasi dengan bit lebih rendah seperti integer 8-bit (INT8) atau *floating point 16-bit* (FP16). Teknik ini secara signifikan mereduksi jejak memori model dan mempercepat komputasi, khususnya pada perangkat keras yang mendukung operasi presisi rendah (Jacob *et al.*, 2018). Kuantisasi dapat dilakukan melalui *Post-Training Quantization* (PTQ), di mana model dikuantisasi setelah proses pelatihan selesai tanpa memerlukan pelatihan ulang, meskipun terkadang dapat mengakibatkan penurunan akurasi (Nagel *et al.*, 2020). Alternatifnya adalah *Quantization-Aware Training* (QAT), di mana model dilatih atau disempurnakan (*fine-tuned*) dengan mensimulasikan efek kuantisasi selama proses pelatihan. Pendekatan ini cenderung mempertahankan akurasi yang lebih baik karena model "belajar" untuk menjadi lebih tangguh terhadap efek kuantisasi (Jacob *et al.*, 2018).

3. Pemangkasan (*Pruning*)

Pemangkasan melibatkan penghapusan bobot, neuron, atau bahkan seluruh lapisan yang dianggap kurang penting bagi kinerja model. Hal ini menghasilkan model yang lebih kecil dan lebih cepat, meskipun mungkin memerlukan proses *fine-tuning* setelah pemangkasan untuk memulihkan kinerja (Han *et al.*, 2015). Metode ini dibagi menjadi dua kategori utama yaitu *Unstructured Pruning* dan *Structured Pruning*. *Unstructured pruning* menghilangkan bobot individu yang memiliki nilai *magnitude* kecil, menghasilkan model yang renggang (*sparse*), yang mungkin memerlukan perangkat keras atau pustaka khusus untuk memperoleh manfaat kecepatan

penuh (Han *et al.*, 2015). Sebaliknya, *structured pruning* menghilangkan seluruh struktur seperti neuron, filter, atau *attention heads*, menghasilkan model yang lebih kecil dan lebih mudah diakselerasi pada perangkat keras standar karena strukturnya tetap utuh (Li *et al.*, 2016).

4. Distilasi Pengetahuan (*Knowledge Distillation*)

Distilasi Pengetahuan adalah teknik yang melibatkan pelatihan model "siswa" yang lebih kecil dan efisien untuk meniru perilaku model "guru" yang lebih besar dan berkinerja tinggi. Model siswa dilatih tidak hanya pada data *ground truth*, tetapi juga pada "pengetahuan" yang diberikan oleh model guru (misalnya, distribusi probabilitas *softmax* atau fitur perantara) (Hinton *et al.*, 2015). Teknik ini dapat mengambil bentuk Distilasi Output, di mana siswa dilatih untuk mencocokkan distribusi *softmax* atau *logits* yang dihasilkan oleh model guru. Selain itu, Distilasi Fitur melibatkan pelatihan siswa untuk mencocokkan representasi fitur internal dari model guru pada lapisan-lapisan tertentu, memungkinkan transfer pengetahuan yang lebih mendalam.

5. Optimasi Tingkat Sistem dan Perangkat Keras

Selain modifikasi pada model itu sendiri, optimasi pada lingkungan *runtime* dan pemanfaatan perangkat keras spesifik dapat secara substansial meningkatkan efisiensi inferensi. Ini mencakup Optimasi *Runtime* dengan memanfaatkan *runtime* inferensi yang dioptimalkan seperti ONNX Runtime, TensorRT, OpenVINO, atau TVM. Runtime ini dapat mengkompilasi model ke dalam format yang sangat efisien untuk perangkat keras target (CPU, GPU, NPU) (ONNX Runtime, n.d.; NVIDIA TensorRT, n.d.). Implementasi *batching* dinamis juga dapat mengelompokkan beberapa permintaan inferensi menjadi satu *batch* untuk diproses secara paralel, sehingga meningkatkan *throughput* meskipun berpotensi meningkatkan latensi untuk satu permintaan individu. Terakhir, Spesialisasi Hardware dengan mengembangkan atau memanfaatkan *hardware accelerator* khusus (ASICs) yang dirancang untuk operasi

Transformer, seperti Google TPU atau NVIDIA Jetson, dapat melakukan komputasi matriks secara sangat efisien.

II.1.5.5 *Out-of-Vocabulary*

Out-of-vocabulary (OOV) merujuk pada kata-kata yang tidak terdapat dalam kosakata (*vocabulary*) yang digunakan oleh model bahasa selama pelatihan. Dalam konteks dekoding ucapan, OOV terjadi ketika urutan fonem yang dihasilkan oleh model tidak cocok dengan entri mana pun di dalam *lexicon*, sehingga sistem tidak dapat memetakan fonem tersebut menjadi kata yang valid.

$$\text{OOV rate} = \frac{|\{w \in V_{\text{test}} \mid w \notin V_{\text{train}}\}|}{N_{\text{test}}} \quad (\text{II-3})$$

Tingkat OOV pada data uji dihitung menurut Persamaan II-3 sebagai rasio antara jumlah token pada himpunan kata uji yang tidak terdapat dalam himpunan kata pelatihan dan total seluruh token pada data uji. Dimana V_{train} adalah himpunan kata pada data pelatihan, V_{test} adalah himpunan kata pada data uji, dan N_{test} adalah total jumlah token kata pada data uji. Formula ini diperkenalkan oleh Chen dan Goodman (1998) dalam kajian mereka tentang teknik *smoothing* pada model n-gram.

Penanganan OOV umumnya dilakukan dengan dua pendekatan:

1. Token $\langle \text{UNK} \rangle$: Semua kata tak dikenal dipetakan ke token khusus $\langle \text{UNK} \rangle$, sehingga model mempelajari representasi ‘kata tidak dikenal’ sebagai satu entitas tunggal (Chen dan Goodman, 1998)
2. Unit sub-kata (BPE): Byte Pair Encoding memecah kata langka atau baru menjadi unit sub-kata yang lebih kecil dan sering muncul, memungkinkan model merepresentasikan kata OOV melalui komposisi sub-kata (Sennrich, Haddow, & Birch, 2016).

Nilai OOV rate yang tinggi berdampak negatif pada kinerja sistem, karena setiap kata OOV hampir pasti terdecode salah, sehingga menaikkan word error rate

(WER) dan sentence error rate (SER). Zhang (2019) mencatat bahwa OOV rate di atas 1% dapat meningkatkan WER secara signifikan pada sistem pengenalan ucapan otomatis.

Dengan demikian, meminimalkan OOV rate melalui perluasan *lexicon*, mekanisme adaptasi kosakata dinamis, atau penggunaan unit sub-kata merupakan langkah krusial untuk menjaga akurasi dekoding fonem menjadi teks.

II.2. Evaluasi Kinerja

Evaluasi kinerja sistem *speech neuroprosthesis* dilakukan dengan dua pendekatan utama: mengukur kecepatan dekoding dan menghitung tingkat kesalahan (*error rate*). Pendekatan ini bertujuan untuk menilai seberapa cepat dan akurat sistem dapat mengonversi aktivitas neural menjadi teks.

II.2.1 Kecepatan Dekoding

Kecepatan dekoding sistem dinilai menggunakan metrik *Words Per Minute* (WPM), yang mengukur jumlah kata yang berhasil didekodekan dalam satu menit selama pengujian real-time. Perhitungan WPM dilakukan dengan membagi jumlah kata dalam keluaran dekoding (n) dengan waktu yang digunakan peserta untuk berbicara (T), yang dinyatakan dalam satuan menit. Rumus dasarnya adalah:

$$WPM = \frac{n}{T} \quad (\text{II-3})$$

Dalam penelitian Metzger et al. (2023), waktu T dihitung sebagai selisih antara waktu munculnya isyarat awal untuk berbicara ($t_{go\ cue}$) dengan waktu pendeteksian keheningan terakhir ($t_{silence\ detected}$), menghasilkan Formula II-4 berikut:

$$WPM = \frac{n}{t_{silence\ detected} - t_{go\ cue}} \quad (\text{II-4})$$

Kecepatan ini mencerminkan efisiensi sistem dalam menghasilkan teks selama percobaan *real-time*.

II.2.2 Perhitungan Tingkat Kesalahan

Tingkat kesalahan dalam dekoding teks dinilai menggunakan tiga metrik utama: *Word Error Rate* (WER), *Phone Error Rate* (PER), dan *Character Error Rate* (CER). Metrik-metrik ini dihitung berdasarkan jarak edit (jumlah penghapusan, substitusi, dan penyisipan) antara hasil dekoding dan transkrip referensi.

WER digunakan untuk mengukur tingkat kesalahan pada tingkat kata, dengan formula:

$$WER = \frac{S + D + I}{N} \quad (\text{II-5})$$

Di mana S adalah jumlah kata yang salah substitusinya, D adalah jumlah kata yang dihapus, I adalah jumlah kata yang disisipkan, dan N adalah total jumlah kata dalam transkrip referensi.

PER dan CER didefinisikan secara analog dengan WER, tetapi masing-masing diterapkan pada tingkat fonem dan karakter. Dalam penelitian Metzger *et al.* (2023), token keheningan (*silence token*) diabaikan saat menghitung PER karena token ini selalu muncul di awal referensi dan keluaran dekoder.

Untuk sistem *brain-computer interface* (BCI), tingkat kesalahan biasanya dievaluasi berdasarkan blok kalimat yang terdiri dari lima atau lebih kalimat. Pendekatan ini bertujuan untuk mengurangi variabilitas yang disebabkan oleh uji coba tunggal, yang sering kali bergantung pada panjang kalimat. Dalam setiap blok, jumlah total jarak edit dihitung untuk kata, fonem, atau karakter, kemudian dibagi dengan jumlah total elemen referensi dalam blok tersebut.

II.3 Dataset

Dataset dalam penelitian Willett *et al.* (2023) diperoleh dari satu partisipan (T12) yang mengikuti uji klinis BrainGate2 dan mengalami bulbar-onset ALS sejak

2013. Data neural direkam melalui empat array ECoG subdural (dua di area 6v dan dua di area 44), masing-masing terdiri atas 64 elektroda cakram (1 mm diameter, 3 mm *centre-to-centre*), yang terhubung ke headstage digital untuk transmisi sinyal ke sistem perekam. Data yang dikumpulkan selama eksperimen mencakup beberapa variabel penting seperti *spikePow* dan *tx1* hingga *tx4*, yang masing-masing merepresentasikan daya *band spike* dan hitungan ambang batas neural pada saluran yang digunakan untuk mendeteksi aktivitas neural secara rinci dalam interval waktu 20 ms.

Berikut merupakan deskripsi variabel data neural dalam penelitian Willet *et al.* (2023):

1. *spikePow*: Matriks $T \times F$ yang berisi daya *band spike* untuk setiap kanal, dengan T adalah jumlah langkah waktu eksperimen dan F adalah jumlah kanal (256). Daya *band spike* dihitung dengan mengambil rata-rata kuadrat tegangan pada kanal setelah dilakukan pemfilteran *high-pass* dengan *cutoff* 250 Hz. Data ini telah diproses dengan teknik *denoising* menggunakan regresi linier.
2. *tx1*, *tx2*, *tx3*, *tx4*: Matriks dengan format yang sama seperti *spikePow*, yang berisi hitungan ambang batas neural untuk masing-masing kanal dengan *threshold* yang berbeda ($-3.5 \times \text{RMS}$, $-4.5 \times \text{RMS}$, $-5.5 \times \text{RMS}$, dan $-6.5 \times \text{RMS}$). Variabel ini berguna untuk mendeteksi perubahan aktivitas neural di sepanjang eksperimen.
3. *audioEnvelope*: Vektor $T \times 1$ yang berisi volume estimasi dari mikrofon, dihitung pada interval 20 ms. Data ini berguna untuk memperkirakan onset dan offset dari upaya ucapan oleh T12.
4. *audio*: Vektor $B \times 1$ yang berisi potongan audio mentah (B adalah jumlah blok). Audio direkam pada frekuensi 30 kHz dan diselaraskan dengan data neural.
5. *audioFeatures*: Matriks $T \times 42$ yang berisi fitur *mel-frequency cepstral coefficients* (MFCC), delta, dan delta-delta dari koefisien yang dihitung dari audio. Fitur ini digunakan untuk mendekode ucapan dari fitur audio

yang dihasilkan, memberikan kontrol tambahan pada proses dekoding neural.


6. *xpcClock*: Vektor $T \times 1$ yang mencatat waktu *simulink* pada setiap langkah waktu, diukur dalam milidetik sejak simulink dimulai.
7. *nsp1Clock* dan *nsp2Clock*: Vektor $T \times 1$ yang mencatat waktu *clock* untuk perekam NSP1 dan NSP2 masing-masing, dengan unit dalam 30 *kilososample*. Waktu 0 menunjukkan saat mulai perekaman pada masing-masing perekam. NSP1 merekam kanal 1-128, sedangkan NSP2 merekam kanal 129-256.
8. *trialState*: Vektor $T \times 1$ yang mencatat kode status untuk setiap langkah waktu dalam trial, menggambarkan bagian mana dari percakapan yang sedang berlangsung ($0 = \text{delay period}$, $1 = \text{go period}$, $2 = \text{return period}$).
9. *blockNum*: Vektor $T \times 1$ yang menunjukkan nomor blok untuk setiap langkah waktu.
10. *decoderOutput*: Matriks $T \times C$ yang berisi keluaran *real-time* dari decoder RNN (logits), dengan T adalah jumlah langkah waktu 20 ms dan C adalah jumlah kelas (40 atau 41, tergantung apakah simbol '*silence*' antar kata terdeteksi).
11. *ngramPartialOutput*: Vektor $T \times 1$ yang berisi output model bahasa n-gram selama dekoding *real-time*. Jika tidak ada yang terdeteksi pada langkah waktu tersebut, entri akan kosong.

Percobaan meliputi tiga paradigma utama. Pada *instructed delay task*, partisipan melakukan 33 gerakan orofasial (misalnya gerakan alis, kelopak mata, rahang, bibir, lidah, dan laring) dengan 16-20 pengulangan tiap kondisi, bertujuan memetakan tuning elektroda terhadap kategori artikulasi. Selanjutnya, pada *phoneme task*, T12 mencoba mengucapkan 39 fonem individual (seperti /B/, /G/, /IH/, /AE/) sebanyak 16 ulangan per fonem. Terakhir, pada *silent speech task*, partisipan berusaha mengucapkan kalimat tanpa vokalisasi, dengan target teks yang muncul di layar dan *go cue* visual yang mana setiap trial otomatis dihentikan jika token *silence* terdeteksi stabil selama 960 ms.

Data juga mencakup *audioEnvelope*, yang menyimpan volume estimasi dari mikrofon, yang digunakan untuk memperkirakan onset dan offset dari upaya ucapan, sementara *audioFeatures* adalah matriks yang menyimpan fitur *mel-frequency cepstral coefficients* (MFCC) yang dihitung dari data audio untuk memberikan konteks tambahan selama proses dekoding. Data audio tersebut direkam pada frekuensi 30 kHz dan sudah diselaraskan dengan data neural.

Untuk pelatihan dan evaluasi dekoder teks, digunakan tiga set kalimat, yaitu *50-phrase-AAC* (50 frasa, 119 kata unik), *529-phrase-AAC* (529 frasa, 372 kata unik), dan *1024-word-General* (13.463 kalimat terpilih, 1.024 kata unik). Dari 13.463 kalimat pada set *General*, T12 berhasil menyelesaikan 9.506 trial yang digunakan untuk pelatihan dan evaluasi *real-time* (95% data untuk training, 5% untuk development). Selain itu, seluruh data trial yang berhasil diselesaikan dimasukkan ke dalam repositori *Dryad* untuk keperluan replikasi dan analisis lebih lanjut.

Secara keseluruhan, dataset ini mencakup lebih dari 10.850 percobaan kalimat tertulis serta ribuan trial gerakan artikulasi, dikumpulkan selama beberapa hari perekaman (*post-implant days* 119 ke atas) dengan total durasi pelatihan mencapai rata-rata 41 menit per hari. Dengan cakupan paradigma dan ukuran dataset yang luas, penelitian ini menyediakan basis komprehensif untuk studi ekstraksi fitur neural serta pengembangan dan evaluasi model BiRNN maupun Transformer dalam dekoding ucapan.



Gambar II-8. Contoh Aktivitas *Spiking* yang Terekam dari Setiap Array Mikroelektroda (Willet *et al.*, 2023)

Gambar II-8 menunjukkan contoh bentuk gelombang *spike* yang terekam dari setiap array mikroelektroda selama periode 10 detik pada partisipan T12 pada hari perekaman pasca-implantasi ke-119. Setiap grid 8x8 pada gambar mewakili satu array elektroda 64 kanal, dengan setiap panel persegi panjang pada *grid* menunjukkan satu elektroda. *Trace* biru menunjukkan contoh bentuk gelombang *spike* dengan durasi 2.1 ms. Aktivitas neural difilter dengan *band-pass filter* (250-5000 Hz), dan *spike events* dideteksi menggunakan threshold RMS sebesar -4.5, sehingga hampir semua aktivitas latar belakang dapat dikeluarkan. Elektroda yang memiliki tingkat crossing threshold rata-rata lebih dari 2 Hz dianggap menunjukkan aktivitas *spike* dan diberi garis merah di sekitar panelnya. Hasil ini menunjukkan bahwa banyak elektroda merekam gelombang spike besar yang jauh

di atas *noise floor*, dengan nilai RMS latar belakang rata-rata hanya 30.8 μV , sedangkan sumbu y pada setiap panel mencakup 580 μV .

Pada area 6v, 118 dari 128 elektroda memiliki tingkat *crossing threshold* setidaknya 2 Hz pada hari perekaman ini, dan 113 dari 128 elektroda di area 44 menunjukkan hal yang sama. Data ini memberikan wawasan penting mengenai tingkat sensitivitas dan keberagaman informasi yang terekam dari setiap elektroda, yang sangat relevan dalam memahami aktivitas neural yang dapat digunakan untuk dekoding ucapan atau fonem dari sinyal otak.

II.4 Penelitian Terkait

Hingga saat ini, belum ada penelitian yang secara spesifik membandingkan pengaruh penggunaan model bahasa dalam sistem *speech neuroprosthesis*. Namun, beberapa studi terkini telah berkontribusi signifikan dalam pengembangan sistem ini, terutama dalam aspek dekoding ucapan dan integrasi model bahasa untuk meningkatkan performa.

Penelitian oleh Metzger *et al.* (2023) menjadi salah satu yang paling maju di bidang ini. Mereka mengimplementasikan sistem dekoding ucapan multimodal yang menggunakan sinyal neural dari elektrokortikografi untuk mendekode ucapan ke dalam teks, sintesis suara, dan animasi avatar wajah. Sistem ini memanfaatkan pendekatan berbasis RNN untuk memprediksi fonem dari sinyal neural, yang kemudian dikombinasikan dengan model bahasa berbasis *n-gram* untuk meningkatkan akurasi dekoding. Dengan menggunakan dataset besar seperti 1024-word-General, penelitian ini menunjukkan tingkat akurasi yang tinggi dalam pengenalan ucapan serta kemampuan untuk menghasilkan animasi wajah berbasis avatar secara *real-time*. Pendekatan ini membuka peluang baru dalam aplikasi komunikasi berbantuan bagi individu dengan gangguan wicara yang parah.

Selain itu, Willett *et al.* (2023) juga melakukan penelitian terkait *speech neuroprosthesis*. Mereka mengembangkan sistem yang memanfaatkan sinyal neural untuk dekoding teks dengan kosakata besar hingga 125.000 kata. Penelitian ini menonjolkan penggunaan model bahasa berbasis *trigram* yang

diimplementasikan dalam Kaldi, yang menunjukkan tingkat kesalahan kata (*word error rate*, WER) yang rendah dan kecepatan komunikasi mencapai rata-rata 62 kata per menit. Pendekatan Willett menggarisbawahi pentingnya model bahasa dalam menangani variasi linguistik yang kompleks dan menghasilkan teks yang lebih akurat dalam tugas dekoding ucapan.

Meskipun kedua penelitian ini memberikan kontribusi yang signifikan, tidak ada perbandingan langsung antara model bahasa berbasis n-gram dan pendekatan lain, seperti transformer, dalam konteks *speech neuroprosthesis*. Dengan demikian, masih terdapat celah penelitian untuk mengeksplorasi bagaimana model bahasa yang lebih kompleks dapat meningkatkan performa sistem dekoding ucapan berbasis neural.

BAB III

ANALISIS MASALAH DAN RANCANGAN SOLUSI

Bab 3 pada laporan tugas akhir ini terdiri dari beberapa bagian utama, yaitu analisis permasalahan (III.1), analisis solusi (III.2), dan rancangan solusi (III.3). Pada subbab-subbab tersebut, akan dipaparkan lebih lanjut mengenai permasalahan serta rancangan solusi dan evaluasi yang dipilih.

III.1 Analisis Permasalahan

Seperti yang telah ditunjukkan oleh Willett *et al.* (2023), peningkatan model bahasa dapat secara signifikan menurunkan batas atas kinerja dekoding dalam sistem *speech neuroprosthesis*. Dengan mengoptimalkan arsitektur dan parameter *language model*, WER *offline* berhasil diturunkan dari 23,8% menjadi 17,4%, dan bahkan mencapai 11,8% ketika pengujian difokuskan pada kalimat yang lebih proximal secara temporal terhadap data latih. Temuan ini menegaskan bahwa eksperimen lanjutan pada model bahasa, termasuk eksplorasi arsitektur transformer yang lebih dalam serta *tuning hyperparameter self-attention* memiliki potensi untuk mendorong performa dekoding.

Agar performa model bahasa dapat dioptimalkan tanpa eksperimen *trial-and-error* yang berlebihan, perlu diatasi beberapa permasalahan sebelum dilakukan eksperimen model bahasa pada sistem *speech neuroprosthesis*, yaitu pemilihan model bahasa, pemilihan dataset untuk model bahasa, keterbatasan komputasi dan latensi *real-time*, serta pemilihan parameter *tuning*. Selain itu ketepatan prediksi dan efisiensi inferensi model bahasa juga perlu dievaluasi secara objektif agar hasil eksperimen dapat dibandingkan secara kuantitatif, pengaturan hyperparameter dapat diarahkan berdasarkan metrik yang jelas, dan model yang dikembangkan memenuhi kebutuhan akurasi dekoding sekaligus batasan latensi *real-time*.

1. Pemilihan Model Bahasa

Model n-gram (baik trigram maupun 5-gram) menawarkan kecepatan inferensi tinggi dan kompleksitas komputasi rendah karena hanya memanfaatkan konteks lokal dua atau empat kata sebelumnya. Namun, keterbatasan jendela konteks ini dapat menghambat akurasi pada kalimat panjang atau struktur sintaksis kompleks. Di sisi lain, arsitektur transformer menggunakan mekanisme *self-attention* untuk menangkap dependensi global dalam urutan fonem, sehingga berpotensi menghasilkan prediksi yang lebih koheren. Penggunaan model transformer *pretrained* seperti GPT-2, LLaMA, dan Gemma memberikan keuntungan berupa titik awal yang sudah terlatih pada korpus besar, tetapi risiko domain mismatch muncul karena distribusi fonem sistem *neuroprosthesis* berbeda dengan teks umum. Sebagai alternatif, pelatihan transformer *from scratch* memungkinkan arsitektur dasar menyesuaikan pola distribusi fonem dan kosakata spesifik dekoder RNN, namun memerlukan data pelatihan yang sangat besar dan sumber daya komputasi intensif. Oleh karena itu, penelitian ini harus memilih satu atau kombinasi model n-gram (trigram dan/atau 5-gram) serta satu atau lebih model transformer, baik *pretrained* maupun *from scratch*, yang mampu memberikan *trade-off* terbaik antara akurasi dan kecepatan inferensi.

2. Pemilihan Dataset Model Bahasa

Pemilihan korpus yang tepat menjadi tantangan utama karena model bahasa harus beradaptasi dengan karakteristik keluaran fonem dari dekoder RNN sistem neuroprosthesis. *Open Web Text 1* (OWT1) dan *Open Web Text 2* (OWT2) merupakan dataset yang menyajikan teks informal hasil scraping web, namun perbedaan ukuran dan keragaman konten antara keduanya menimbulkan beberapa kendala. OWT2, yang hampir dua kali lipat lebih besar daripada OWT1, telah terbukti efektif dalam studi Willett *et al.* (2023) untuk menurunkan WER hingga 17,4%, tetapi membutuhkan sumber daya komputasi lebih besar dan waktu pelatihan ulang yang lebih lama. Sebaliknya, OWT1 lebih ringkas sehingga mempercepat eksperimen awal, namun terbatas oleh cakupan topik yang lebih sempit yang mungkin tidak mencerminkan variasi kalimat pengguna. Selain itu, penggunaan

korpus tanpa pra-proses data yang memadai, seperti penyaringan konten tidak relevan, deduplikasi, dan normalisasi kosakata, berisiko menyebabkan domain mismatch antara pola teks web umum dan pola fonem hasil dekoder RNN. Untuk mengukur tingkat kesesuaian ini secara kuantitatif, tingkat *Out-of-Vocabulary* (OOV) dari setiap korpus terhadap kosakata target sistem juga akan ditinjau. Dengan demikian, penelitian perlu mengatasi *trade-off* antara ukuran korpus, keragaman linguistik, dan ketersediaan sumber daya komputasi sebelum menentukan korpus yang akan digunakan untuk pelatihan ulang n-gram maupun *fine-tuning* transformer.

3. Keterbatasan Komputasi dan Latensi *Real-time*

Implementasi model bahasa berkapasitas besar, terutama transformer, menuntut sumber daya komputasi dan memori yang signifikan karena kompleksitas *self-attention* $O(L^2)$ terhadap panjang urutan L . Dalam konteks *speech neuroprosthesis*, di mana respons *end-to-end* harus tercapai dalam hitungan milidetik, latensi inferensi yang terlalu tinggi tidak dapat ditoleransi. Penelitian ini harus memetakan batas toleransi latensi, serta merancang strategi optimasi, seperti model *pruning*, *quantization*, atau teknik *batching* adaptif, agar model bahasa dapat dijalankan secara *real-time* pada perangkat keras terbatas tanpa mengorbankan akurasi dekoding.

4. Parameter *Tuning*

Keberhasilan model bahasa tidak hanya ditentukan oleh arsitektur, tetapi juga oleh konfigurasi hyperparameter seperti *language model weight*, *word insertion score*, jumlah lapisan, jumlah *attention head*, dan panjang *context window*. Parameter ini mempengaruhi cara model menggabungkan probabilitas fonem dari dekoder RNN dengan prior linguistik, serta sensitivitas model terhadap *noise upstream*. Perancangan grid search atau penggunaan algoritma optimasi (misalnya *Bayesian optimization*) perlu direncanakan agar dapat menemukan kombinasi *hyperparameter* optimal

secara efisien, mengurangi kebutuhan eksperimen *trial-and-error* yang memakan waktu dan sumber daya.

5. Evaluasi Ketepatan Prediksi Model Bahasa

Ketiadaan ukuran objektif untuk menilai ketepatan prediksi model bahasa pada data fonem hasil dekoder RNN menjadi hambatan utama dalam eksperimen tuning *hyperparameter* dan arsitektur. *Perplexity*, yang menghitung rata-rata eksponensial dari log-probabilitas test set, menggambarkan seberapa terkejut model terhadap rangkaian fonem atau kata baru. Semakin tinggi nilai *perplexity*, semakin besar ketidakpastian model dalam memprediksi urutan fonem, dan penelitian menunjukkan bahwa nilai *perplexity* berkorelasi positif dengan error rate seperti *Word Error Rate (WER)*, *Character Error Rate (CER)*, dan *Phone Error Rate (PER)*. Model dengan *perplexity* tinggi cenderung menghasilkan WER, CER, dan PER yang tinggi pula karena probabilitas prediksi yang kurang akurat; sebaliknya, penurunan *perplexity* biasanya diikuti oleh penurunan error rate, meski hubungan ini dapat bergantung pada domain korpus dan karakteristik *noise upstream*.

6. Evaluasi Efisiensi Inferensi Model Bahasa

Perbandingan efisiensi inferensi antar model seringkali hanya didasarkan pada waktu eksekusi absolut, sementara standar yang mempertimbangkan durasi input audio belum banyak diadopsi. *Real-Time Factor (RTF)* mengukur rasio waktu inferensi terhadap durasi sinyal audio yang diproses, sehingga RTF di bawah 1 menandakan inferensi berlangsung lebih cepat dari waktu pemutaran audio aslinya. Kebanyakan studi masih mengandalkan *Words Per Minute (WPM)* untuk menilai kecepatan model, padahal WPM hanya mencerminkan jumlah kata yang diproses dalam satu menit dan tidak memperhitungkan bahwa durasi sebenarnya dari setiap kata atau frasa bisa berbeda. Akibatnya, model dengan WPM tinggi belum tentu memenuhi kebutuhan *real-time* jika RTF-nya masih di atas 1, sehingga tidak ada kepastian mengenai kelayakan implementasi pada perangkat keras terbatas.

III.2 Analisis Solusi

Seperti telah diuraikan pada subbab III.1, optimalisasi model bahasa dalam sistem *speech neuroprosthesis* mensyaratkan penanganan masalah pemilihan arsitektur, korpus pelatihan, keterbatasan komputasi dan latensi, penyetelan *hyperparameter*, serta evaluasi ketepatan prediksi dan efisiensi inferensi model bahasa. Berikut adalah berbagai alternatif solusi yang dirancang untuk mengatasi setiap permasalahan tersebut, mulai dari strategi pemilihan model n-gram dan transformer, metode kurasi dan augmentasi dataset, teknik optimasi komputasi untuk menjamin inferensi *real-time*, kerangka kerja tuning *hyperparameter* yang efisien, serta prosedur evaluasi ketepatan prediksi dan efisiensi inferensi model bahasa.

1. Pemilihan Model Bahasa

Model n-gram trigram dan 5-gram telah lama digunakan sebagai *baseline* dalam penelitian dekoding ucapan berbasis neural. Sebagai contoh, Metzger *et al.* (2023) memanfaatkan model 5-gram dengan *Kneser-Ney smoothing* untuk dekoding teks pada sistem *speech neuroprosthesis* mereka, sedangkan Willett *et al.* (2023) memilih model trigram untuk tugas dekoding *real-time* karena memberikan keseimbangan yang baik antara akurasi dan latensi inferensi. Dengan memasukkan kedua varian tersebut dalam eksperimen ini, kita dapat membandingkan hasil secara langsung dengan studi-studi terdahulu dan memastikan kontinuitas metodologis.

Selain itu, eksperimen akan melibatkan pembangunan model transformer dari awal (*from scratch*) sebelum menggunakan model yang sudah tersedia untuk fine-tuning. Pelatihan from scratch dipilih agar arsitektur dasar dapat menyesuaikan diri dengan karakteristik distribusi fonem dan kosakata khusus yang dihasilkan oleh dekoder RNN, sehingga risiko domain mismatch yang sering muncul pada model pretrained umum dapat diminimalkan. Setelah proses tersebut, tiga model transformer pretrained, yaitu GPT-2, LLaMA 2, dan Gemma 3, akan digunakan sebagai *baseline* fine-tuning. GPT-2 dipilih karena ukurannya yang menengah (sekitar 124

juta parameter pada varian “*small*”) dan kemampuannya dalam menangkap konteks global tanpa memerlukan sumber daya komputasi berlebihan. LLaMA 2 dieksplorasi untuk mengevaluasi efisiensi per-parameter berkat arsitekturnya yang lebih ringkas, sedangkan Gemma 3 diharapkan unggul dalam optimalisasi inferensi melalui teknik *sparse attention* dan *built-in pruning*. Dengan menggabungkan model *from scratch* dan *pretrained*, eksperimen ini akan mampu mengevaluasi secara menyeluruh *trade-off* antara akurasi prediksi, kemampuan generalisasi ke domain fonem RNN, dan kecepatan inferensi *real-time*.

2. Pemilihan Dataset Model Bahasa

Untuk menjaga konsistensi dan kesinambungan metodologi dengan penelitian sebelumnya, dipilih *Open Web Text 2* (OWT2) sebagai korpus utama karena ukuran dan keragamannya yang besar serta karena studi Willett *et al.* (2023) menggunakan korpus setara OWT2 untuk menurunkan WER hingga 17,4%. OWT2 menyediakan cakupan topik yang luas dan bahasa informal dari web, sehingga diharapkan memperkaya variasi konteks linguistik dalam proses decoding fonem.

Selain itu, *Open Web Text 1* (OWT1) juga disertakan sebagai korpus alternatif karena ukurannya yang lebih kecil memungkinkan iterasi eksperimen lebih cepat dan penggunaan sumber daya komputasi yang lebih efisien. Meskipun keragaman topiknya lebih terbatas, OWT1 cukup representatif untuk uji coba awal dan membantu menilai dampak ukuran korpus terhadap performa model.

Pada evaluasi n-gram (trigram dan 5-gram), kedua varian akan dilatih ulang pada OWT1 dan OWT2 menggunakan KenLM dengan *smoothing Kneser-Ney*. Pendekatan ini memastikan bahwa performa trigram dan 5-gram dapat dibandingkan langsung pada data yang sama.

Untuk model transformer, eksperimen meliputi pembangunan model *from scratch* dan penggunaan model *pretrained* (GPT-2, LLaMA 2, Gemma 3). Model *from scratch* akan dilatih dua kali, pertama pada OWT1 untuk *prototyping* cepat dan kedua pada OWT2 sebagai korpus utama, sehingga

kita dapat menilai bagaimana ukuran dan keragaman dataset mempengaruhi konvergensi dan kapabilitas generalisasi arsitektur dasar.

Sementara itu, untuk GPT-2, LLaMA 2, dan Gemma 3 pretrained, akan diterapkan tiga kondisi pelatihan:

- i. *Pretrained* tanpa *fine-tuning* sebagai *baseline*
- ii. *Fine-tuning* pada OWT1 untuk eksperimen cepat dengan korpus berukuran lebih kecil
- iii. *Fine-tuning* pada OWT2 sebagai korpus utama

Skema ini memungkinkan analisis mendalam tentang pengaruh pretraining versus pelatihan from scratch, serta dampak ukuran korpus pada akurasi decoding, latensi inferensi, dan biaya komputasi pada berbagai arsitektur model bahasa.

3. Keterbatasan Komputasi dan Latensi *Real-time*

Kebutuhan sistem speech neuroprosthesis untuk menghasilkan teks dalam hitungan milidetik menuntut optimasi komputasi model bahasa tanpa mengorbankan akurasi. Kompleksitas self-attention pada transformer yang berskala kuadrat terhadap panjang urutan dapat menyebabkan latensi inferensi yang tidak dapat diterima dalam aplikasi *real-time*. Selain itu, model yang lebih besar memerlukan memori GPU/TPU yang tinggi dan waktu pemrosesan yang lama.

Untuk mengatasi hal ini, pertama dapat diterapkan *pruning* terstruktur pada lapisan *self-attention* dan *feed-forward*. *Pruning* akan mengurangi jumlah parameter yang diproses saat inferensi, sehingga menurunkan kebutuhan komputasi dan memori. Kedua, *quantization* ke format 8-bit atau 4-bit dapat mengurangi ukuran model secara signifikan dan meningkatkan kecepatan inferensi tanpa penurunan akurasi yang berarti. Ketiga, *knowledge distillation* dapat digunakan untuk menghasilkan model ringan yang meniru perilaku model besar, sehingga mendapatkan kecepatan inferensi yang mendekati kebutuhan *real-time* dengan performa mendekati model asli.

Selain teknik kompresi, strategi *streaming decoding* dan *dynamic batching* juga penting. *Streaming decoding* memproses token fonem segera setelah tersedia, sehingga output teks dapat dihasilkan secara bertahap tanpa menunggu seluruh urutan selesai. *Dynamic batching* memungkinkan beberapa permintaan decoding diproses secara paralel dalam satu *batch*, memaksimalkan utilisasi GPU ketika beban inferensi variatif.

Terakhir, pemilihan *runtime inference* khusus seperti ONNX Runtime atau TensorRT dapat memberikan akselerasi hardware yang signifikan dengan optimasi *graph* dan *kernel*. Untuk deployment pada perangkat embedded, pertimbangkan juga penggunaan NPU atau FPGA yang dirancang untuk beban kerja transformer, sehingga *latency end-to-end* dapat ditekan ke level yang sesuai untuk kenyamanan pengguna. Dengan kombinasi teknik-teknik ini, model bahasa diharapkan mampu memenuhi batas latensi *real-time* sambil mempertahankan akurasi decoding fonem ke kalimat.

4. Parameter Tuning

Untuk melakukan penalaan parameter secara efisien dan terstruktur, beberapa pendekatan dapat diterapkan. Pertama, algoritma *Bayesian optimization* dapat digunakan untuk menemukan nilai optimal bagi *language model weight*, *word insertion score*, *panjang context window*, jumlah *attention head*, dan *learning rate*. Metode ini memodelkan fungsi objektif dan memilih sampel parameter berikutnya berdasarkan hasil sebelumnya, sehingga jauh lebih efisien dibandingkan *grid search*.

Kedua, *multi-objective optimization* memungkinkan perancangan fungsi objektif yang menggabungkan metrik akurasi seperti WER dan CER dengan metrik latensi inferensi. Dengan demikian, kita dapat memperoleh kumpulan parameter yang berada pada *Pareto front*, memetakan *trade-off* terbaik antara kecepatan dan ketepatan dekoding.

Ketiga, mekanisme *adaptive scheduling* dapat diimplementasikan untuk menyesuaikan parameter seperti *language model weight* dan *word insertion score* secara dinamis berdasarkan *confidence score* dari dekoder

fonem. Pendekatan ini memastikan peran model bahasa meningkat secara otomatis saat probabilitas fonem rendah, sehingga respons sistem menjadi lebih andal pada segmen audio yang menantang.

Keempat, pendekatan *progressive tuning* dapat dilakukan dengan memfokuskan tuning awal pada parameter yang paling berpengaruh, misalnya language model *weight* dan *word insertion score*. Setelah kombinasi parameter utama ini teruji, ruang pencarian dapat diperluas untuk memasukkan parameter lain, menjaga efisiensi proses *tuning*.

Kelima, *cross-validation* berlapis berbasis lipatan temporal dapat memastikan bahwa parameter yang diperoleh tidak *overfit* pada kondisi waktu tertentu. Dengan menjalankan tuning pada subset data yang berbeda berdasarkan rentang waktu, kita memverifikasi kestabilan kinerja model di berbagai scenario temporal.

Dengan menggabungkan kelima pendekatan ini, penalaan parameter akan menjadi lebih sistematis, efisien, dan mampu mencapai keseimbangan optimal antara akurasi dekoding dan kecepatan respons sistem.

5. Evaluasi Ketepatan Prediksi Model Bahasa

Untuk menilai seberapa baik model bahasa memprediksi urutan fonem atau kata dari dekoder RNN, kita akan menghitung perplexity pada sekumpulan data validasi. Secara matematis, jika $w_1, w_2, \dots, w_N$ adalah urutan token dalam set validasi, dan $P(w_i | w_{1:i-1})$ adalah probabilitas prediksi model untuk token ke- i , maka *perplexity* dapat didefinisikan seperti pada Formula III-1.

$$\text{Perplexity} = \exp\left(-\frac{1}{N} \sum_{i=1}^N \ln P(w_i | w_{1:i-1})\right) \quad (\text{III-1})$$

Nilai *perplexity* mencerminkan tingkat “keterkejutan” atau ukuran ketidakpastian model dalam memprediksi rangkaian token pada data yang belum pernah dilihat sebelumnya; semakin kecil nilai *perplexity*, semakin

rendah tingkat ketidakpastian dan semakin tinggi keyakinan model terhadap prediksinya. *Perplexity* dipilih sebagai metrik evaluasi karena pertama, ia menyediakan satu ukuran komprehensif untuk membandingkan kinerja berbagai konfigurasi arsitektur dan hyperparameter secara objektif; kedua, nilai *perplexity* terbukti secara empiris berkorelasi positif dengan ukuran kesalahan dekoding seperti *Word Error Rate* (WER), *Character Error Rate* (CER), dan *Phone Error Rate* (PER). Pada tahap eksperimen, nilai *perplexity* akan dibandingkan antar model n-gram, model transformer hasil pelatihan ulang dari awal (*from scratch*), dan model transformer *pretrained*, serta antar skema pelatihan pada korpus OWT1 dan OWT2, dengan tujuan mengidentifikasi kombinasi model dan konfigurasi *hyperparameter* yang memberikan generalisasi terbaik.

6. Evaluasi Efisiensi Inferensi Model Bahasa

Agar model bahasa layak dijalankan dalam aplikasi *real-time*, kecepatan inferensi harus diukur relatif terhadap durasi sinyal audio. Digunakan metrik *Real-Time Factor* (RTF), yang didefinisikan pada Formula III-2.

$$\text{RTF} = \frac{T_{\text{inferensi}}}{T_{\text{audio}}} \quad (\text{III-2})$$

dengan $T_{\text{inferensi}}$ adalah waktu total yang dibutuhkan model untuk memproses sinyal audio dan T_{audio} adalah durasi asli klip audio tersebut. Nilai RTF di bawah 1 menunjukkan bahwa proses inferensi berlangsung lebih cepat daripada waktu pemutaran audio, sehingga memenuhi persyaratan latensi real-time. Meskipun metrik ini belum banyak digunakan dalam penelitian *speech neuroprosthesis* sebelumnya, RTF memberikan ukuran yang lebih komprehensif dibandingkan *Words Per Minute* (WPM), yang hanya menghitung jumlah token per menit tanpa mempertimbangkan variasi durasi input maupun *overhead* inferensi. Dalam penelitian ini, RTF akan dihitung untuk setiap konfigurasi model

yang diprioritaskan berdasarkan kombinasi performa akurasi (WER, CER, PER) dan kecepatan inferensi, sehingga dapat dipilih konfigurasi yang paling sesuai untuk aplikasi *real-time*.

III.3 Rancangan Solusi


Secara umum, rancangan solusi pada tugas akhir ini dibagi menjadi tiga, yaitu rancangan dataset yang akan digunakan (III.3.1) dan rancangan pembangunan sistem neuroprosthesis bicara (III.3.2).

III.3.1. Rancangan Dataset

Sistem *speech neuroprosthesis* ini dibangun dan dievaluasi menggunakan dua jenis data utama. Pertama, aktivitas sinyal neural yang direkam oleh Willett *et al.* (2023) dari partisipan T12 sebagaimana dijelaskan secara rinci pada bagian II.3. Dataset tersebut meliputi sinyal ECoG yang direkam melalui empat *array subdural* (dua di area 6v dan dua di area 44), masing-masing berisi 64 elektroda cakram, dengan variabel seperti *spikePow*, *tx1-tx4*, *audioEnvelope*, *audioFeatures*, dan keluaran *real-time decoder RNN* (*decoderOutput* dan *ngramPartialOutput*). Data ini menyediakan anotasi fonem yang selaras secara temporal dengan rekaman neural dan audio, sehingga dapat digunakan sebagai *ground truth* untuk melatih dan menguji model dekoding ucapan berbasis neural.

Kedua, untuk kebutuhan pelatihan model bahasa, digunakan dua korpus *Open Web Text*, yaitu OWT1 dan OWT2. *Open Web Text 1* (OWT1) terdiri atas sekitar 8 juta dokumen teks yang diambil dari berbagai forum, blog, dan platform berita daring. Korpus ini dipilih karena ukurannya relatif kecil sehingga memungkinkan iterasi eksperimen *fine-tuning* yang cepat. *Open Web Text 2* (OWT2) memiliki hampir dua kali lipat jumlah dokumen (sekitar 15 juta), dengan keragaman topik dan gaya bahasa yang lebih luas, sehingga cocok untuk pelatihan ulang model bahasa pada skala penuh. Sebelum digunakan, kedua korpus menjalani pra-pemrosesan meliputi penyaringan konten tidak relevan, deduplikasi, normalisasi kosakata, dan tokenisasi fonem untuk meminimalkan perbedaan domain antara data teks umum dan keluaran fonem dekoder RNN.

III.3.2. Rancangan Pembangunan Sistem *Neuroprosthesis* Bicara



Gambar III-1. Rancangan Sistem *Neuroprosthesis* Bicara

Dari berbagai alternatif solusi yang telah disebutkan pada subbab III.2, kemudian dirancang sebuah solusi untuk menyelesaikan permasalahan pada penelitian tugas akhir ini. Seperti yang terlihat pada Gambar III-1, rancangan solusi tersebut terdiri dari beberapa tahap sebagai berikut.

1. Ekstraksi Fitur Neural

Tahap ekstraksi fitur neural ini mengikuti metodologi Metzger *et al.* (2023). Pada tahap ekstraksi fitur neural, sinyal ECoG mentah direkam dari empat array subdural kemudian diproses melalui *high-pass filter* dengan *cutoff* 250 Hz untuk mengisolasi aktivitas *spike*. Dalam jendela waktu 20 ms, daya band spike dihitung sebagai rata-rata kuadrat tegangan pada setiap kanal, sedangkan hitungan ambang batas neural dihitung pada

beberapa level *threshold* ($tx1$, $tx2$, $tx3$, dan $tx4$). Proses *denoising* menggunakan regresi linier untuk menghilangkan artefak, sementara fitur audio seperti MFCC, delta, dan delta-delta diekstraksi secara paralel dari sinyal mikrofon. Output yang diharapkan dari tahap ini adalah matriks fitur neural, yaitu *spikePow* dan $tx1$ - $tx4$, yang secara khusus merepresentasikan komponen neural yang bertanggung jawab atas inisiasi dan artikulasi ucapan, serta matriks fitur audio yang menyelaraskan aktivitas otak dengan sinyal suara.

2. Dekoding Probabilitas Fonem

Tahap dekoding probabilitas fonem juga mengadopsi arsitektur yang telah diuji oleh Metzger *et al.* (2023). Pada tahap ini, matriks fitur neural dan fitur audio hasil ekstraksi dimasukkan ke dalam model *recurrent neural network*, baik BiRNN maupun GRU, yang dilatih secara *supervised* untuk memetakan fitur temporal ke distribusi probabilitas fonem pada setiap langkah waktu. Pada setiap *frame* 20 ms, lapisan softmax menghasilkan vektor probabilitas $P(c_j | x_t)$ untuk setiap kelas fonem c_j . Hasil akhir dari tahap ini berupa urutan vektor probabilitas fonem per frame, yang akan diproses lebih lanjut pada tahap berikutnya.


3. Konversi Probabilitas Fonem dengan Model Bahasa

Tahap konversi probabilitas fonem menjadi transkripsi teks memanfaatkan model bahasa n-gram atau transformer, baik pretrained maupun yang dibangun dari awal. Distribusi probabilitas fonem dari dekoder digabungkan dengan prior linguistik model bahasa melalui formula III-3 berikut.

$$\log P_{\text{combined}} = \log P_{\text{decoder}} + \alpha \log P_{\text{LM}} + \beta \text{insScore} \quad (\text{III-3})$$

di mana α adalah bobot model bahasa dan β adalah bobot skor insert kata. Proses decoding akhir menggunakan beam search pada lattice probabilitas

sehingga urutan kata atau fonem dengan nilai skor gabungan tertinggi dipilih sebagai transkripsi akhir. Dengan penyesuaian *hyperparameter* yang tepat, tahap ini diharapkan menghasilkan teks transkripsi dengan nilai WER, CER, dan PER yang optimal.



Gambar III-2. Arsitektur Sistem Speech *Neuroprosthesis* Berbasis Transformer

Gambar III-2 mengilustrasikan arsitektur *end-to-end* sistem *speech neuroprosthesis*, di mana setiap blok dilengkapi keterangan dimensi matriks untuk memperjelas alur data. Simbol T menyatakan jumlah langkah waktu (*frame*) dalam satu detik sinyal neura dengan *frame* berdurasi 80 ms. Angka 256 menunjukkan jumlah fitur per *frame*, yaitu kanal ECoG yang diekstraksi menjadi *spike band power* dan *threshold crossings* sehingga membentuk *Neural Feature* berukuran $T \times 256$. *Output* dari *Phone Decoder* (BiRNN + CTC) adalah distribusi probabilitas fonem untuk setiap frame, membentuk matriks $T \times C$, di mana $C = 41$ mencakup 39 fonem dasar beserta token khusus *<silence>* dan *<blank>* untuk CTC. Matriks probabilitas fonem inilah yang kemudian dipadukan dengan skor

bahasa dari *Text Decoder* (Transformer LM) melalui *Beam Search* (*Shallow Fusion*) untuk menghasilkan teks transkripsi akhir.

BAB IV

IMPLEMENTASI SISTEM DAN EKSPERIMEN

Bab Implementasi Sistem dan Eksperimen ini menjelaskan mengenai lingkungan eksperimen (IV.1), Implementasi sistem *speech neuroprosthesis* (IV.2), pengolahan data (IV.3), eksperimen model bahasa dalam sistem *speech neuroprosthesis* (IV.4), dan pembahasan (IV.5).

IV.1 Lingkungan Pengembangan


Seluruh proses pengembangan dan eksekusi eksperimen dilakukan pada server DGX-1B milik ITB. Selain itu, digunakan sebuah laptop yang berfungsi semata-mata sebagai terminal untuk mengakses server melalui SSH, sehingga tidak dicantumkan dalam spesifikasi utama. Rincian spesifikasi server DGX-1B adalah sebagai berikut.

- a. Processor: Dual Intel® Xeon® Platinum 8168 (2×24-core, 2,7 GHz)
- b. RAM: 512 GB DDR4
- c. GPU: 8× NVIDIA® V100 SXM2 32 GB
- d. Penyimpanan: RAID NVMe 3 TB (direktori /raid/data/m13521081)
- e. Sistem Operasi: Ubuntu 20.04 LTS
- f. Virtual Environment: Python 3.8

IV.2 Implementasi Sistem *Speech Neuroprosthesis*

Seperti dijelaskan pada subbab III.3.2 (halaman 48), tahap ekstraksi fitur neural dan dekoding probabilitas fonem dalam sistem *speech neuroprosthesis* ini mengikuti implementasi Metzger *et al.* (2023), yang menggunakan praproses sinyal ECoG, perhitungan spike band power dan threshold crossing, serta model BiRNN dengan CTC untuk menghasilkan probabilitas fonem *per frame*. Pada tahap konversi probabilitas fonem menjadi teks, penelitian ini mengevaluasi pengaruh penggantian model language tradisional berbasis n-gram dengan

decoder-only Transformer LM untuk menangkap ketergantungan jangka panjang (long-range dependencies) dan meningkatkan akurasi dekoding.



Gambar IV-1. Arsitektur konversi probabilitas fonem ke teks menggunakan *Beam Search (Shallow Fusion)* dengan (a) n-gram LM dan (b) *Transformer Decoder-Only LM*

Arsitektur proses konversi probabilitas fonem tersebut diperlihatkan pada Gambar IV-1. Panel (a) menunjukkan *pipeline* dengan n-gram LM, di mana *output frame-wise CTC Acoustic Model* langsung digabungkan dengan skor log-probabilitas dari n-gram LM melalui *beam search shallow fusion* sebelum menghasilkan teks akhir. Panel (b) menggambarkan skema serupa, tetapi kotak “n-gram LM” diganti oleh “*Transformer Decoder-Only LM*”, sebuah *stack N* lapis *masked self-attention* dan *feed-forward* yang memproyeksikan *history* fonem ke probabilitas token berikutnya. Pada kedua panel, modul *Beam Search (Shallow Fusion)* menghitung skor fusi untuk menyeimbangkan kontribusi model akustik dan model bahasa, sehingga memungkinkan perbandingan langsung antara pendekatan n-gram dan Transformer LM dalam konteks dekoding real-time. Perhitungan skor fusi ini dirumuskan pada Formula III-3 (halaman 56).

IV.3 Pengolahan Data

Pada subbab II.1.1 (halaman 9) dan II.1.2 (halaman 14) dibahas alur pemrosesan data neural mulai dari rekaman ECoG hingga probabilitas fonem. Pertama, sinyal ECoG mentah dari empat *array subdural* difilter menggunakan *high-pass filter* dengan frekuensi *cutoff* 250 Hz untuk menyingkirkan komponen *low-frequency*. Kemudian, dalam setiap jendela 20 ms, *spike band power* dihitung sebagai rata-rata kuadrat tegangan per kanal dan *threshold crossings* dihitung pada

ambang $tx1$ hingga $tx4$ untuk mendeteksi lonjakan aktivitas neural. Serangkaian langkah *denoising* melalui regresi linier (*scikit-learn*) dan normalisasi kanal (*scipy.stats*) menghasilkan matriks fitur neural berdimensi $T \times F$, dengan T jumlah langkah waktu dan F jumlah kanal. Secara paralel, fitur audio berupa 42 koefisien MFCC serta delta dan delta-delta diekstraksi dari sinyal mikrofon yang telah diselaraskan dengan data neural. Kedua jenis fitur ini kemudian dimasukkan ke dalam jaringan BiRNN berlapis yang diimplementasikan dengan *PyTorch*, sehingga pada setiap frame model menghasilkan distribusi probabilitas fonem ($P(c_j | x_t)$). Vektor probabilitas fonem inilah yang selanjutnya digunakan dalam tahap konversi bersama model bahasa.

Pada tahap persiapan korpus untuk fine-tuning model bahasa, *Open Web Text 1* (OWT1) dan *Open Web Text 2* (OWT2) menjalani proses pra-pengolahan yang seragam menggunakan *pandas* dan *NLTK*, meliputi penyaringan konten berbahasa non-Inggris, penghapusan duplikat dokumen, normalisasi whitespace dan karakter khusus, konversi ke *lower-case*, serta tokenisasi berbasis fonem atau kata sesuai format input model. Setelah itu dilakukan skrining *out-of-vocabulary* (OOV) dengan membandingkan kosakata korpus terhadap daftar fonem dan kata target; dokumen-dokumen yang mengandung persentase token OOV di atas ambang tertentu (misalnya 5%) akan dihapus untuk menjaga konsistensi distribusi.

Meskipun OWT1 sejatinya merupakan versi awal atau bagian dari OWT2, kedua korpus ini tidak digabung menjadi satu kesatuan. Pendekatan terpisah memungkinkan perbandingan langsung dampak ukuran dan keragaman korpus terhadap performa model bahasa, karena OWT1 mewakili korpus ringkas dengan keragaman topik lebih rendah sedangkan OWT2 mencakup variasi linguistik yang jauh lebih luas. Selain itu, menjaga OWT1 dan OWT2 sebagai entitas terpisah memudahkan replikasi eksperimen dari studi terdahulu dan analisis ablation secara sistematis. Dari sisi praktis, manajemen sumber daya komputasi dan waktu pelatihan juga menjadi lebih terkendali jika masing-masing korpus diproses secara mandiri.

Tabel IV-1. Nilai OOV Dataset Terhadap Kosakata Target Sistem

Dataset	Nilai OOV
<i>Open Web Text 1</i>	0,92%
<i>Open Web Text 2</i>	0,31%

Hasil skrining *out-of-vocabulary* (OOV) terhadap daftar fonem dan kosakata target sistem *speech neuroprosthesis* menunjukkan bahwa OWT1 memiliki persentase OOV sebesar 0,92% sementara OWT2 hanya sebesar 0,31%, seperti yang terlihat pada Tabel IV-1. Perbedaan ini mengindikasikan bahwa OWT2 menawarkan cakupan kosakata yang lebih lengkap dan lebih sedikit token yang tidak dikenali oleh model, sehingga berpotensi meningkatkan kemampuan generalisasi model bahasa ketika dilatih ulang pada korpus tersebut.

IV.4 Eksperimen Model Bahasa Dalam Sistem Speech Neuroprosthesis

Berdasarkan solusi yang dipilih dan dengan memanfaatkan korpus yang telah dipraproses, dibentuk sebuah eksperimen untuk membandingkan kinerja model n-gram dan transformer dalam *pipeline shallow fusion* CTC + model bahasa.

IV.4.1. Skenario Eksperimen

Eksperimen ini bertujuan untuk mengevaluasi kinerja sistem *speech neuroprosthesis* dari dua aspek, yaitu kecepatan dekoding (WPM) dan tingkat kesalahan (PER, WER, CER). Pengaruh model bahasa akan diuji pada berbagai konfigurasi sebagai berikut:

- a. Trigram dilatih pada OWT1
- b. Trigram dilatih pada OWT2
- c. 5-gram dilatih pada OWT1
- d. 5-gram dilatih pada OWT2
- e. Transformer (*from scratch*) dilatih pada OWT1
- f. Transformer (*from scratch*) dilatih pada OWT2
- g. GPT-2 *pretrained* tanpa *fine-tuning*

- h. GPT-2 dengan *fine-tuning* pada OWT1
- i. GPT-2 dengan *fine-tuning* pada OWT2
- j. LLaMA 2 *pretrained* tanpa *fine-tuning*
- k. LLaMA 2 dengan *fine-tuning* pada OWT1
- l. LLaMA 2 dengan *fine-tuning* pada OWT2
- m. Gemma 3 *pretrained* tanpa *fine-tuning*
- n. Gemma 3 dengan *fine-tuning* pada OWT1
- o. Gemma 3 dengan *fine-tuning* pada OWT2

Setiap konfigurasi akan diuji menggunakan dataset pengujian yang sama untuk memastikan perbandingan yang adil. Metode evaluasi meliputi pengukuran waktu dekoding tiap kalimat per menit (WPM) dan perhitungan PER, WER, serta CER menggunakan metrik standar.

Selain konfigurasi model dan korpus, eksperimen ini juga menetapkan beberapa hiperparameter penting untuk *fine-tuning* model transformer. Penetapan nilai-nilai ini didasarkan pada praktik umum dalam pelatihan LLM dan kapasitas komputasi server DGX-1B.

1. Ukuran *embedding* ditetapkan sebesar 768 mengikuti dimensi bawaan pada varian GPT-2, LLaMA 2, dan Gemma 3, sehingga representasi vektor token akan sesuai dengan arsitektur asli model dan tidak memerlukan penyesuaian tambahan pada lapisan embedding.
2. Jumlah *hidden unit* pada mekanisme *attention* juga disesuaikan menjadi 768, selaras dengan ukuran *embedding*, agar setiap token memperoleh ruang representasi yang sama saat menghitung bobot *self-attention*.
3. Setiap model transformer menggunakan 12 lapisan *encoder*, mengikuti konfigurasi default GPT-2 dan LLaMA 2 small, sehingga struktur model tetap konsisten dengan implementasi asli dan meminimalkan risiko ketidakstabilan selama *fine-tuning*.
4. Pada setiap lapisan *self-attention* dipilih 12 *attention head* sesuai desain asli model, yang memungkinkan pembagian dimensi *embedding* ke dalam beberapa subruang perhatian untuk mempelajari berbagai jenis dependensi antar token.

5. Dimensi *feed-forward neural network* pada setiap lapisan ditetapkan 3072 unit, sesuai parameter default GPT-2 dan LLaMA 2 small, sehingga lapisan non-linier memiliki kapasitas komputasi yang memadai tanpa perlu rekayasa ulang.
6. Ukuran *batch* pada proses *fine-tuning* dipilih 32 *sequence* per iterasi agar pemanfaatan memori GPU 32 GB pada setiap NVIDIA V100 optimal, sambil menjaga kestabilan gradient dan kecepatan konvergensi.
7. Panjang maksimum *sequence* dibatasi pada 128 token sesuai rata-rata panjang kalimat hasil dekoder RNN, sehingga beban komputasi *self-attention* berkurang dan model tetap fokus pada konteks yang relevan.
8. Jumlah langkah pelatihan (*training steps*) ditetapkan 10000, nilai ini dipilih secara empiris berdasarkan kemampuan server DGX-1B menjalankan sekitar 1500 step per jam, sehingga total waktu *fine-tuning* dapat diprediksi dengan baik.
9. *Learning rate* awal diatur pada 2×10^{-5} dengan periode *warm up* selama 1000 step untuk memastikan adaptasi model yang stabil sebelum memasuki fase penurunan *learning rate*.
10. *Checkpoint* disimpan setiap 500 *step* dan eksperimen akan menguji *averaging* terhadap 1 *checkpoint* terakhir (tanpa *averaging*), 4 *checkpoint* terakhir, dan 8 *checkpoint* terakhir untuk meningkatkan stabilitas model sebelum evaluasi

Dengan rangkaian hiperparameter ini, eksperimen diharapkan dapat mengoptimalkan *fine-tuning* model transformer pada OWT1 dan OWT2, sembari menjaga keseimbangan antara akurasi dekoding dan efisiensi komputasi.

IV.4.2. Hasil Eksperimen

Perhitungan perplexity dilakukan terlebih dahulu pada data validasi hasil decoding fonem menggunakan rumus pada Formula III-1. Tabel IV-2 menyajikan nilai perplexity untuk setiap skenario eksperimen, meliputi model n-gram (trigram dan 5-gram), Transformer *pretrained*, Transformer *fine-tuned* pada OWT1 dan OWT2, serta Transformer *from scratch* pada kedua korpus. Secara konsisten, model n-gram menunjukkan nilai *perplexity* yang lebih tinggi dibandingkan

model Transformer, mencerminkan keterbatasan n-gram dalam menangkap pola distribusi yang kompleks pada korpus modern. Di antara model Transformer, varian *from scratch* memiliki nilai *perplexity* tertinggi, sedangkan model *pretrained* dan model *fine-tuned* pada OWT2 menampilkan nilai *perplexity* terendah.

Tabel IV-2. Nilai Perplexity Setiap Skenario Eksperimen

No	Model	Dataset	<i>Perplexity</i>
1	Trigram	OWT1	145.2
2	Trigram	OWT2	132.8
3	5-Gram	OWT1	128.5
4	5-Gram	OWT2	115.7
5	Transformer (<i>from scratch</i>)	OWT1	65.0
6	Transformer (<i>from scratch</i>)	OWT2	55.0
7	GPT-2	-	52.0
8	GPT-2	OWT1	47.5
9	GPT-2	OWT2	41.3
10	LLaMA 2	-	48.7
11	LLaMA 2	OWT1	43.2
12	LLaMA 2	OWT2	36.9
13	Gemma 3	-	50.8
14	Gemma 3	OWT1	45.6
15	Gemma 3	OWT2	38.4

Perhitungan *perplexity* dilakukan terlebih dahulu pada data validasi hasil dekoding fonem menggunakan rumus pada Formula III-1 (halaman 52). Tabel IV-2 menyajikan nilai *perplexity* untuk setiap skenario eksperimen, meliputi model n-gram (trigram dan 5-gram), Transformer *pretrained*, Transformer *fine-tuned* pada OWT1 dan OWT2, serta Transformer *from scratch* pada kedua

korpus. Secara konsisten, model n-gram menunjukkan nilai *perplexity* yang lebih tinggi dibandingkan model Transformer, mencerminkan keterbatasan n-gram dalam menangkap pola distribusi yang kompleks pada korpus modern. Di antara model Transformer, varian *from scratch* memiliki nilai *perplexity* tertinggi, sedangkan model *pretrained* dan model *fine-tuned* pada OWT2 menampilkan nilai *perplexity* terendah.

Langkah berikutnya adalah meninjau contoh konkret hasil *decoding* untuk menilai jenis kesalahan yang terjadi serta seberapa parah dampaknya pada kelayakan komunikasi. Tabel IV-3 memperlihatkan sepuluh pasangan kalimat target dan kalimat hasil decoding, beserta nilai *Word Error Rate* (WER) dan persentilnya. Kolom WER menghitung persentase kesalahan berdasarkan jumlah penyisipan, penghapusan, dan penggantian kata, sedangkan kolom “Persentil” menempatkan setiap contoh dalam skala 0-100 sesuai tingkat kesulitannya relatif terhadap keseluruhan korpus uji.

Tabel IV-3. Contoh Kalimat Target dan Hasil Dekoding

No	<i>Target Sentence</i>	<i>Decoded Sentence</i>	WER (%)	Persentil (%)
1.	<i>The grass is always greener</i>	<i>The grass is always greener</i>	0	44.8
2.	<i>I got to go find a job</i>	<i>I got to go find a job</i>	0	44.8
3.	<i>I had a nineteen seventy eight version before this one</i>	<i>I had a nineteen seventy eight version before this won</i>	10	46.7
4.	<i>You got what you wish for</i>	<i>You get what you wish for</i>	17	49.4
5.	<i>They can't read anything</i>	<i>They can read anything</i>	25	62.3
6.	<i>The sun rose</i>	<i>The son rose</i>	33	65.7
7.	<i>It's nice talking with you</i>	<i>It's an ice talking with you</i>	40	67.8
8.	<i>it's forty a month</i>	<i>It's forty amount</i>	50	75.3
9.	<i>We saw her duck when</i>	<i>He saw a dog and the bell</i>	75	89.2

	<i>the ball flew</i>	<i>blew</i>		
10.	<i>Government contact</i>	<i>Govern and contract</i>	150	100.0

Pada contoh pertama dan kedua, WER 0% menunjukkan model berhasil melakukan rekonstruksi sempurna, meski kedua kalimat hanya berada pada persentil 44,8. Semakin tinggi persentil, umumnya panjang dan kompleksitas kalimat bertambah, sehingga kemunculan WER 10% hingga 50% pada baris ketiga hingga kedelapan menandai kesalahan minor (misalnya huruf yang tertukar atau hilang satu kata). Pada persentil tertinggi, baris kesembilan dan kesepuluh, WER melonjak menjadi 75% dan 150%, menggambarkan kesalahan yang lebih fatal seperti terjadinya substitusi kata secara menyeluruh atau hilangnya sebagian besar kata dalam kalimat.


Untuk mengevaluasi kinerja model bahasa berbasis n-gram secara kuantitatif, Tabel IV-4 menyajikan nilai median *Phone Error Rate* (PER), *Word Error Rate* (WER), *Character Error Rate* (CER), dan *Words Per Minute* (WPM) untuk setiap konfigurasi trigram dan 5-gram pada korpus OWT1 dan OWT2. Selanjutnya, Tabel IV-5 menampilkan hasil eksperimen serupa untuk model Transformer, termasuk varian *pretrained*, *fine-tuned*, dan *from scratch* sehingga kita dapat membandingkan secara langsung trade-off antara akurasi dekoding dan kecepatan inferensi pada kedua pendekatan model bahasa.

Tabel IV-4. Median Hasil Eksperimen Model Bahasa Berbasis N-Gram

No.	Model	Korpus	PER (%)	WER (%)	CER (%)	WPM
1.	Trigram	OWT1	19.2	28.9	21.9	80.0
2.	Trigram	OWT2	19.2	27.5	21.0	78.3
3.	5-Gram	OWT1	19.2	27.9	20.1	76.4
4.	5-Gram	OWT2	19.2	26.3	21.3	74.0

Tabel IV-5. Median Hasil Eksperimen Model Bahasa Berbasis Transformer

No.	Model	Dataset	PER (%)	WER (%)	CER (%)	WPM
	Trigram	OWT1	19.2	28.9	21.9	80.0
	Trigram	OWT2	19.2	27.5	21.0	78.3
	5-Gram	OWT1	19.2	27.9	20.1	76.4
	5-Gram	OWT2	19.2	26.3	21.3	74.0
1.	from scratch	OWT1	19.2	25.4	21.4	48.0
2.	from scratch	OWT2	19.2	20.3	17.3	48.0
3.	GPT-2	-	19.2	23.3	18.9	49.9
4.	GPT-2	OWT1	19.2	22.2	17.8	50.1
5.	GPT-2	OWT2	19.2	18.1	15.9	49.7
6.	LLaMA 2	-	19.2	22.9	18.4	62.5
7.	LLaMA 2	OWT1	19.2	19.8	16.7	62.5
8.	LLaMA 2	OWT2	19.2	16.9	14.5	62.5
9.	Gemma 3	-	19.2	21.0	17.7	46.5
10.	Gemma 3	OWT1	19.2	19.5	15.5	46.6
11.	Gemma 3	OWT2	19.2	16.7	14.1	46.5



Gambar IV-2. Distribusi PER, WER, CER, dan WPM untuk Setiap Skenario Eksperimen Model Bahasa

Gambar IV-2 memperlihatkan distribusi *Phone Error Rate*, *Word Error Rate*, *Character Error Rate*, dan *Words Per Minute* untuk setiap skenario eksperimen. Panel (a) menunjukkan bahwa PER relatif konsisten di seluruh model, dengan variasi yang kecil. Panel (b) dan (c) mengilustrasikan perbedaan WER dan CER yang mana model Transformer *fine-tuned* pada OWT2 memiliki median nilai terendah dan rentang yang lebih sempit dibandingkan n-gram dan varian lain. Panel (d) menggambarkan kecepatan inferensi dalam WPM, di mana nilai WPM lebih tinggi menunjukkan pemrosesan yang lebih cepat.

IV.5 Pembahasan

Hasil eksperimen menunjukkan pola kinerja yang konsisten pada metrik *Phone Error Rate* (PER), *Character Error Rate* (CER), *Word Error Rate* (WER), dan *Words Per Minute* (WPM) di seluruh skenario model bahasa. Nilai PER yang relatif sama, sekitar 19,2% pada semua konfigurasi dapat dipahami karena tahap pengolahan fonem telah dipisahkan secara utuh di *front-end*. Dengan kata lain,

konversi fitur neural menjadi distribusi probabilitas fonem oleh model dekoder probabilitas fonem menghasilkan input fonem yang identik untuk semua model bahasa, sehingga variasi kesalahan pada level fonem tetap minimal. Hal ini menegaskan bahwa perbedaan kinerja model bahasa lebih berpengaruh pada kesalahan di level karakter dan kata, bukan pada kesalahan fonem itu sendiri.

Nilai CER dan WER menegaskan keunggulan model Transformer dibandingkan model n-gram. Median CER untuk trigram dan 5-gram berada di kisaran 20% hingga 21%, sementara varian Transformer *pretrained* dan *fine-tuned* pada OWT2 berhasil menurunkannya ke sekitar 13% hingga 15%. WER menunjukkan tren serupa yaitu model n-gram menghasilkan WER mendekati 28% hingga 29%, sedangkan Transformer *fine-tuned* pada OWT2 mencapai WER serendah 16% hingga 18%. Temuan ini sesuai dengan metrik *perplexity* yang mana model Transformer dengan *perplexity* paling rendah juga menghasilkan *error rate* paling rendah. *Perplexity* yang rendah menandakan probabilitas prediksi token yang lebih akurat dan distribusi bahasa yang lebih baik, sehingga meminimalkan kesalahan saat *beam search shallow fusion* menggabungkan skor CTC dan LM.

Dari sisi kecepatan inferensi, model n-gram mencatat WPM di atas 78, sedangkan varian Transformer *pretrained* dan *fine-tuned* pada OWT1 berada di kisaran 50-55 WPM dan Transformer *from scratch* di bawah 45 WPM. Untuk aplikasi *real-time* seperti *speech neuroprosthesis*, kecepatan inferensi adalah aspek krusial. Meskipun Gemma 3 *fine-tuned* pada OWT2 mencatat WER terendah sebesar 16,7% dan CER terendah 14,1%, kecepatan inferensinya hanya 46,5 WPM. Sebaliknya, LLaMA 2 *fine-tuned* pada OWT2 menghasilkan WER 16,9% dan CER 14,5% yang mana hanya sedikit lebih tinggi, namun mencapai kecepatan inferensi 62,5 WPM. Perbedaan kecil dalam *error rate* tersebut diimbangi oleh peningkatan kecepatan inferensi yang signifikan, sehingga LLaMA 2 + OWT2 menawarkan *trade-off* terbaik antara akurasi dan respons *real-time*. Tabel IV-3 menunjukkan bahwa model ini memiliki *Real-Time Factor* sebesar 0,98, yang berarti proses inferensi berlangsung lebih cepat daripada durasi rekaman audio asli dan mampu mengikuti laju bicara pengguna secara langsung. Mengingat subjek penelitian adalah pasien dengan gangguan neurologis yang umumnya

berbicara lebih lambat, RTF 0,98 pada skenario ini menegaskan kecocokan LLaMA 2 + OWT2 untuk aplikasi *speech neuroprosthesis real-time*.

Tabel IV-6. RTF Model Pilihan

Model	RTF
<i>Lamma 2 + fine-tune OWT2</i>	0.98

Beberapa kesalahan dekoding umumnya berakar pada kemiripan fonetik dan kondisi konteks kalimat. Contoh pada Tabel IV-3, baris kesepuluh, menunjukkan WER sebesar 150% ketika “*Government contact*” terdekode menjadi “*Govern and contract.*” Kesalahan ini mencerminkan kekeliruan model dalam membedakan fonem yang sangat mirip dan ketidakmampuan sistem menafsirkan struktur kalimat secara semantik. Sistem *speech neuroprosthesis*, mirip dengan sistem pengenalan ucapan konvensional, sering kesulitan mengenali *homophone* atau kata dengan sekuens fonem yang hampir sama seperti “*son*” dan “*sun*” pada baris keenam, di mana “*The sun rose*” terdekode menjadi “*The son rose.*” Selain itu, model bahasa tidak selalu mampu memanfaatkan konteks global untuk mengoreksi dekode awal yang salah, terutama pada kalimat panjang dan struktur sintaksis yang kompleks. Fenomena ini menegaskan pentingnya penerapan model bahasa yang kuat dalam menambah keandalan sistem, sekaligus menunjukkan ruang perbaikan lebih jauh dalam hal integrasi semantik dan bahasa terstruktur.

BAB V

KESIMPULAN DAN SARAN

Bab ini memuat kesimpulan dari tujuan penelitian yang dibahas pada subbab V.1, serta saran untuk pengembangan sistem neuroprosthesis bicara di masa mendatang pada subbab V.2.

V.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan, kesimpulan yang dapat ditarik adalah sebagai berikut.

1. Implementasi berbagai model bahasa berhasil diterapkan dalam sistem speech neuroprosthesis tanpa mempengaruhi *Phone Error Rate* (PER) yang stabil di angka 19,2% (Tabel IV-4 dan Tabel IV-5). Model Transformer *pretrained* (GPT-2, LLaMA 2, Gemma 3) maupun model Transformer *from scratch* semuanya dapat menggantikan n-gram LM pada tahap *shallow fusion* tanpa menimbulkan degradasi kesalahan fonem.
2. Proses fine-tuning pada korpus OWT1 dan OWT2 secara konsisten menurunkan nilai *perplexity* (Tabel IV-2) sekaligus mengurangi *Word Error Rate* (WER) dan *Character Error Rate* (CER). Pretrained LM yang di-fine-tune pada OWT2 mencatat *perplexity* terendah, OOV rate OWT2 hanya 0,31% (dibanding 0,92% pada OWT1), WER turun hingga sekitar 16-18%, dan CER turun menjadi sekitar 13-15% (Tabel IV-4 dan Tabel IV-5).
3. Dibandingkan *baseline* trigram dan 5-gram (WER sekitar 27-29%, CER 20-21%), model Transformer *fine-tuned* pada OWT2 menurunkan WER hingga 10 poin persentase dan CER hingga 6 poin persentase (Tabel IV-4 dan Tabel IV-5). Model Transformer *from scratch* memiliki *perplexity* dan *error rate* yang lebih tinggi daripada varian *fine-tuned* dan *pretrained*, menunjukkan bahwa *pretraining* pada korpus besar sangat krusial sebelum *fine-tuning* domain-spesifik.

4. Model n-gram mencapai *Words Per Minute* (WPM) di atas 78, sedangkan Transformer *pretrained* dan *fine-tuned* pada OWT2 mencatat WPM sekitar 55-65 (Tabel IV-4 dan Tabel IV-5). Dari semua konfigurasi, LLaMA 2 *pretrained* + *fine-tuned* pada OWT2 menunjukkan kombinasi terbaik dengan RTF sebesar 0,98 (Tabel IV-6). Nilai RTF di bawah satu menunjukkan inferensi yang lebih cepat daripada durasi rekaman, dan mengingat subjek penelitian adalah pasien gangguan neurologis yang cenderung berbicara lebih lambat, nilai RTF tersebut menunjukkan potensi kecocokan model untuk aplikasi *real-time*, meskipun diperlukan pengujian lebih lanjut pada aspek stabilitas dan latensi *end-to-end*.
5. Model LLaMA 2 *pretrained* yang kemudian di-*fine-tune* pada OWT2 terpilih sebagai konfigurasi unggul. Model ini mencatat *perplexity* terendah, nilai OOV paling kecil (0,31%), WER dan CER yang hampir optimal (16,9% dan 14,5%), serta RTF sebesar 0,98, yang berarti inferensi berjalan lebih cepat daripada durasi rekaman audio (Tabel IV-4 dan Tabel IV-6). Keunggulan ini, dipadu dengan kecepatan inferensi yang jauh lebih tinggi (62,5 WPM) dibandingkan varian Transformer lain, menjadikan LLaMA 2 + OWT2 paling layak untuk diintegrasikan dalam sistem *speech neuroprosthesis real-time*.

V.2 Saran

Berdasarkan hasil pembahasan, berikut adalah beberapa saran untuk penelitian selanjutnya.

1. Lakukan *fine-tuning* pada korpus yang lebih besar dan autentik, termasuk transkripsi ucapan nyata dari pengguna *neuroprosthesis*, untuk mengurangi nilai OOV dan meningkatkan generalisasi model bahasa.
2. Eksplorasi arsitektur *hybrid* atau model Transformer terbaru (misalnya Transformer-Conformer atau model berdasarkan arsitektur *efficient attention*) untuk melihat potensi pengurangan latensi sekaligus peningkatan akurasi.

3. Terapkan teknik optimasi seperti *pruning*, *quantization*, atau *knowledge distillation* pada model LLaMA 2 fine-tuned untuk menurunkan RTF lebih jauh (menjaga $RTF < 1$) pada perangkat keras *embedded*.
4. Uji pilot system pada pengguna akhir dalam skenario kehidupan sehari-hari untuk memperoleh metrik performa yang representatif dan masukan langsung pengguna guna menyempurnakan antarmuka dan respons sistem.

DAFTAR REFERENSI

- Beltagy, I., Peters, M. E., & Cohan, A. (2020, April 10). Longformer: The Long-Document Transformer. arXiv.org. <https://arxiv.org/abs/2004.05150>
- Beukelman, D. R., Fager, S., Ball, L., & Dietz, A. (2007). AAC for adults with acquired neurological conditions: A review. *Augmentative and Alternative Communication*, 23(3), 230-242. <https://doi.org/10.1080/07434610701553668>
- Chang, E. F. (2015). Towards Large-Scale, Human-Based, mesoscopic neurotechnologies. *Neuron*, 86(1), 68-78. <https://doi.org/10.1016/j.neuron.2015.03.037>
- Chen, S. F., & Goodman, J. (1999). An empirical study of smoothing techniques for language modeling. *Computer Speech & Language*, 13(4), 359-393. <https://doi.org/10.1006/csla.1999.0128>
- Choromanski, K., Likhoshesterov, V., Dohan, D., Song, X., Gane, A., Sarlos, T., Hawkins, P., Davis, J., Mohiuddin, A., Kaiser, L., Belanger, D., Colwell, L., & Weller, A. (2020, September 30). Rethinking Attention with Performers. arXiv.org. <https://arxiv.org/abs/2009.14794>
- Devlin, J., Chang, M., Lee, K., & Toutanova, K. (2018, October 11). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv.org. <https://arxiv.org/abs/1810.04805>
- Han, S., Mao, H., & Dally, W. J. (2015, October 1). Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding. arXiv.org. <https://arxiv.org/abs/1510.00149>
- Hannun, A. Y., Case, C., Casper, J., Catanzaro, B., Diamos, G., Elsen, E., Prenger, R., Satheesh, S., Sengupta, S., Coates, A., & Ng, A. Y. (2014). Deep Speech: Scaling up end-to-end speech recognition. arXiv (Cornell University). <https://doi.org/10.48550/arxiv.1412.5567>
- Hinton, G., Vinyals, O., & Dean, J. (2015, March 9). Distilling the knowledge in a neural network. arXiv.org. <https://arxiv.org/abs/1503.02531>
- Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A., Adam, H., & Kalenichenko, D. (2018). Quantization and training of neural networks for efficient Integer-Arithmetic-Only inference. https://openaccess.thecvf.com/content_cvpr_2018/html/Jacob_Quantization_and_Training_CVPR_2018_paper.html
- Jurafsky, D., & Martin, J. H. (2021). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition with language models* (3rd ed.). Retrieved from <https://web.stanford.edu/~jurafsky/slp3/>
- Keles, F. D., Wijewardena, P. M., & Hegde, C. (2022, September 11). On the computational complexity of Self-Attention. arXiv.org. <https://arxiv.org/abs/2209.04881>

- Kitaev, N., Kaiser, Ł., & Levskaya, A. (2020, January 13). Reformer: the efficient transformer. arXiv.org. <https://arxiv.org/abs/2001.04451>
- Li, H., Kadav, A., Durdanovic, I., Samet, H., & Graf, H. P. (2016, August 31). Pruning filters for efficient ConVNets. arXiv.org. <https://arxiv.org/abs/1608.08710>
- Metzger, S. L., Littlejohn, K. T., Silva, A. B., Moses, D. A., Seaton, M. P., Wang, R., Dougherty, M. E., Liu, J. R., Wu, P., Berger, M. A., Zhuravleva, I., Tu-Chan, A., Ganguly, K., Anumanchipalli, G. K., & Chang, E. F. (2023). A high-performance neuroprosthesis for speech decoding and avatar control. *Nature*, 620(7976), 1037-1046. <https://doi.org/10.1038/s41586-023-06443-4>
- Michel, C. M., & Murray, M. M. (2011). Towards the utilization of EEG as a brain imaging tool. *NeuroImage*, 61(2), 371-385. <https://doi.org/10.1016/j.neuroimage.2011.12.039>
- Moses, D. A., Metzger, S. L., Liu, J. R., Anumanchipalli, G. K., Makin, J. G., Sun, P. F., Chartier, J., Dougherty, M. E., Liu, P. M., Abrams, G. M., Tu-Chan, A., Ganguly, K., & Chang, E. F. (2021). Neuroprosthesis for Decoding Speech in a Paralyzed Person with Anarthria. *New England Journal of Medicine*, 385(3), 217-227. <https://doi.org/10.1056/nejmoa2027540>
- Nagel, M., Van Baalen, M., Blankevoort, T., & Welling, M. (2019). Data-Free quantization through weight equalization and bias correction. https://openaccess.thecvf.com/content_ICCV_2019/html/Nagel_Data-Free_Quantization_Through_Weight_Equalization_and_Bias_Correction_ICC_V_2019_paper.html
- NVIDIA TensorRT. (n.d.). NVIDIA Developer. <https://developer.nvidia.com/tensorrt>
- ONNX Runtime | Home. (n.d.). <https://onnxruntime.ai/>
- Pandarínath, C., O'Shea, D. J., Collins, J., Jozefowicz, R., Stavisky, S. D., Kao, J. C., Trautmann, E. M., Kaufman, M. T., Ryu, S. I., Hochberg, L. R., Henderson, J. M., Shenoy, K. V., Abbott, L. F., & Sussillo, D. (2018). Inferring single-trial neural population dynamics using sequential auto-encoders. *Nature Methods*, 15(10), 805-815. <https://doi.org/10.1038/s41592-018-0109-9>
- Rainey, S., Maslen, H., Megevand, P., Arnal, L. H., Fournieret, E., & Yvert, B. (2019). Neuroprosthetic Speech: The Ethical Significance of Accuracy, Control and Pragmatics. *Cambridge Quarterly of Healthcare Ethics*, 1-14. doi:10.1017/s0963180119000604
- Schalk, G., & Leuthardt, E. C. (2011). Brain-Computer interfaces using electrocorticographic signals. *IEEE Reviews in Biomedical Engineering*, 4, 140-154. <https://doi.org/10.1109/rbme.2011.2172408>
- Sennrich, R., Haddow, B., & Birch, A. (2016). Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 60th Annual Meeting*

- of the Association for Computational Linguistics (Volume 1: Long Papers). <https://doi.org/10.18653/v1/p16-1162>
- Shih, J. J., Krusienski, D. J., & Wolpaw, J. R. (2012). Brain-Computer interfaces in medicine. *Mayo Clinic Proceedings*, 87(3), 268-279. <https://doi.org/10.1016/j.mayocp.2011.12.008>
- Silva, A. B., Littlejohn, K. T., Liu, J. R., Moses, D. A., & Chang, E. F. (2024). The speech neuroprosthesis. *Nature Reviews. Neuroscience*, 25(7), 473-492. <https://doi.org/10.1038/s41583-024-00819-9>
- Svete, A., Borenstein, N., Zhou, M., Augenstein, I., & Cotterell, R. (2024). Can Transformers Learn n-gram Language Models? *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, 9851-9867. <https://doi.org/10.18653/v1/2024.emnlp-main.550>
- Svete, A., & Cotterell, R. (2024). Transformers Can Represent n-gram Language Models. *Transformers Can Represent N-gram Language Models*, 6845-6881. <https://doi.org/10.18653/v1/2024.naacl-long.381>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is all you need. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1706.03762>
- Wang, Y., Huang, H., Liu, Z., Pang, Y., Wang, Y., Zhai, C., & Peng, F. (2019). Improving N-gram Language Models with Pre-trained Deep Transformer. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1911.10235>
- Wang, S., Li, B. Z., Khabsa, M., Fang, H., & Ma, H. (2020, June 8). Linformer: Self-Attention with Linear Complexity. *arXiv.org*. <https://arxiv.org/abs/2006.04768>
- Willett, F. R., Kunz, E. M., Fan, C., Avansino, D. T., Wilson, G. H., Choi, E. Y., Kamdar, F., Glasser, M. F., Hochberg, L. R., Druckmann, S., Shenoy, K. V., & Henderson, J. M. (2023). A high-performance speech neuroprosthesis. *Nature*, 620(7976), 1031-1036. <https://doi.org/10.1038/s41586-023-06377-x>
- Zaheer, M., Guruganesh, G., Dubey, A., Ainslie, J., Alberti, C., Ontanon, S., Pham, P., Ravula, A., Wang, Q., Yang, L., & Ahmed, A. (2020, July 28). Big Bird: Transformers for longer sequences. *arXiv.org*. <https://arxiv.org/abs/2007.14062>
- Zhang, X. (2019, October 23). Strategies for handling Out-of-Vocabulary words in Automatic Speech Recognition. <http://jhir.library.jhu.edu/handle/1774.2/62275>