

**PEMBANGUNAN MODEL NEUROPROSTHESIS BICARA
DENGAN ARSITEKTUR DUA TAHAP DAN *END-TO-END*
BERBASIS FOUNDATION MODEL**

Laporan Tugas Akhir

Disusun sebagai syarat kelulusan tingkat sarjana

Oleh

Muhammad Neo Cicero Koda

NIM : 13522108



**PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO & INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

Juni 2026

**PEMBANGUNAN MODEL NEUROPROSTHESIS BICARA
DENGAN ARSITEKTUR DUA TAHAP DAN *END-TO-END*
BERBASIS FOUNDATION MODEL**

Laporan Tugas Akhir

Oleh

Muhammad Neo Cicero Koda

NIM : 13522108

Program Studi Teknik Informatika


Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Telah disetujui sebagai Draft Laporan Tugas Akhir untuk menjadi syarat
mengikuti Seminar TA
di Bandung, pada tanggal 29 Mei 2026

Pembimbing I,

Pembimbing II,



Dessi Puji Lestari, S.T, M.Eng., Ph.D.

NIP. 197912012012122005

Prof. Dr.-Ing. Sakriani Sakti, S.T.,

M.Sc.

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa:

- I Pengerjaan dan penulisan Laporan Tugas Akhir ini dilakukan tanpa menggunakan bantuan yang tidak dibenarkan.
- II Segala bentuk kutipan dan acuan terhadap tulisan orang lain yang digunakan di dalam penyusunan laporan tugas akhir ini telah dituliskan dengan baik dan benar.
- III Laporan Tugas Akhir ini belum pernah diajukan pada program pendidikan di perguruan tinggi mana pun.

Jika terbukti melanggar hal-hal di atas, saya bersedia dikenakan sanksi sesuai dengan Pelanggaran Peraturan Akademik dan Kemahasiswaan Institut Teknologi Bandung khususnya Pasal 14.

Bandung, Juni 2026



Muhammad Neo Cicero Koda

NIM 13522108

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan laporan tugas akhir yang berjudul “Pembangunan Model Neuroprosthesis Bicara dengan Arsitektur Dua Tahap dan End-to-End Berbasis Foundation Model”. Penulis menyadari bahwa penyelesaian tugas akhir ini tidak terlepas dari bimbingan, dukungan, serta doa dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Ibu Dessi Puji Lestari, S.T, M.Eng., Ph.D. dan Ibu Prof. Dr.-Ing. Sakriani Sakti, S.T., M.Sc., selaku dosen pembimbing, atas segala waktu, ilmu, dan arahan yang sangat berharga selama proses pengerjaan tugas akhir ini.
2. Seluruh staf pengajar Program Studi Teknik Informatika atas bekal ilmu dan wawasan yang telah diberikan selama masa perkuliahan.
3. Orang tua serta keluarga tercinta yang tidak pernah putus memberikan doa, kasih sayang, dan dukungan baik secara moril maupun materil.
4. Teman-teman dekat dan rekan seperjuangan yang senantiasa saling membantu, mendengarkan, dan memberikan semangat.
5. Seluruh pihak yang tidak dapat disebutkan satu per satu, yang telah turut berkontribusi membantu kelancaran penyusunan tugas akhir ini.

Penulis menyadari bahwa laporan tugas akhir ini masih jauh dari kata sempurna. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang membangun demi perbaikan di masa mendatang. Akhir kata, semoga tugas akhir ini dapat memberikan manfaat dan inspirasi bagi siapapun yang membaca.

DAFTAR ISI

BAB I PENDAHULUAN.....	1
I.1 Latar Belakang.....	1
I.2 Rumusan Masalah.....	4
I.3 Tujuan dan Ukuran Keberhasilan Pencapaian.....	4
I.4 Batasan Masalah.....	5
I.5 Metodologi.....	5
I.6 Sistematika Pembahasan.....	6
BAB II KAJIAN PUSTAKA.....	8
II.1 Brain Computer Interface (BCI).....	8
II.1.1 Paradigma Komunikasi BCI.....	9
II.1.2 Metode Akuisisi Sinyal pada BCI.....	10
II.1.3 Elektrokortikografi (ECoG).....	11
II.2 Dataset Willett et al. (2023).....	13
II.3 Pemrosesan Sinyal ECoG Menjadi Teks.....	15
II.3.1 Praproses Sinyal ECoG dan Ekstraksi Fitur.....	16
II.3.2 Pemetaan Fitur ECoG Menjadi Probabilitas Fonem.....	16
II.3.3 Pemetaan Fonem ke Teks.....	18
II.3.4 Metrik Evaluasi pada Dekode Sinyal ECoG ke Teks.....	20
II.4 Model Berbasis Transformer.....	22
II.4.1 Transformer.....	22
II.4.2 Conformer.....	25
II.5 Foundation Model.....	27
II.5.1 Varian Arsitektur Foundation Model.....	28
II.5.2 Adaptasi Foundation Model untuk Modalitas Baru.....	30
II.5.3 Parameter-Efficient Fine-Tuning (PEFT) dengan LoRA.....	31
II.6 Penelitian Terkait.....	33
BAB III ANALISIS MASALAH DAN RANCANGAN SOLUSI.....	35
III.1 Analisis Masalah.....	35
III.2 Analisis Solusi.....	36
III.3 Rancangan Solusi.....	40
III.3.1 Praproses dan Ekstraksi Fitur.....	41
III.3.2 Rancangan Solusi Dua Tahap.....	42
III.3.3 Rancangan Solusi End-to-End.....	45
BAB IV	
EVALUASI.....	49
IV.1 Lingkungan Pengembangan.....	49
IV.2 Desain Eksperimen.....	50

IV.2.1 Eksperimen Dekode Fonem.....	50
IV.2.2 Eksperimen Evaluasi Arsitektur.....	51
IV.3 Hasil Eksperimen.....	52
IV.3.1 Hasil Dekode Fonem.....	52
IV.3.2 Hasil Evaluasi Arsitektur.....	53
IV.4 Analisis.....	56
IV.4.1 Perbedaan Distribusi Probabilitas Fonem pada Dekoder 5-gram.....	56
IV.4.2 Pengaruh Panjang Ujaran terhadap WER.....	57
IV.4.3 Perbandingan Kesalahan E2E dan Dua Tahap.....	58
IV.5 Pembahasan.....	58
BAB V	
KESIMPULAN DAN SARAN.....	62
V.1 Kesimpulan.....	62
V.2 Saran.....	63

DAFTAR GAMBAR

Gambar II.1 Contoh pemasangan alat BCI (https://changlab.ucsf.edu).....	9
Gambar II.2 Contoh penempatan kisi ECoG untuk sistem <i>neuroprosthesis</i> bicara (Metzger et al., 2023).....	13
Gambar II.3 Tata letak dua area kortikal pada susunan elektroda.....	14
Gambar II.4 Proses mendekode sinyal ECoG menjadi teks (Willett et al., 2023).....	15
Gambar II.4 Arsitektur Transformer (Vaswani et al., 2017).....	24
Gambar II.4 Arsitektur <i>encoder</i> Conformer (kiri) dan susunan satu blok Conformer (kanan) (Gulati et al., 2020).....	27
Gambar II.5 Struktur Low-Rank Adaptation (LoRA) (Hu et al., 2021).....	33
Gambar III.1 Perbandingan susunan blok Transformer, Conformer, dan Conformer dengan <i>spatial attention</i>	38
Gambar III.2 Alur praproses dan ekstraksi fitur dari sinyal ECoG mentah menjadi matriks fitur ternormalisasi.....	41
Gambar III.3 Alur arsitektur dua tahap dari fitur neural hingga teks akhir.....	43
Gambar III.5 Alur arsitektur <i>end-to-end</i> yang memanfaatkan Foundation Model audio melalui cross-attention.....	47
Gambar IV.1 WER setiap arsitektur untuk panjang ujaran referensi pada data uji.....	57

DAFTAR TABEL

Tabel II.1 Metrik evaluasi sistem <i>neuroprosthesis</i> bicara.....	20
Tabel II.3 Daftar Foundation Model yang digunakan beserta karakteristiknya.....	29
Tabel II.4 Perbandingan full fine-tuning dan LoRA.....	32
Tabel III.1 Daftar Foundation Model yang digunakan beserta karakteristiknya.....	38
Tabel IV.1 Spesifikasi lingkungan pengembangan.....	49
Tabel IV.2 Hasil PER empat dekoder fonem.....	52
Tabel IV.3 Hasil WER dan CER setiap arsitektur.....	53
Tabel IV.4 Jumlah parameter, ukuran penyimpanan, dan kecepatan untuk masing-masing arsitektur.....	54
Tabel IV.5 Coverage, WER <i>oracle</i> , dan ukuran rata-rata <i>n-best</i> dari <i>beam search 5-gram</i> untuk kedua dekoder pada data uji.....	56
Tabel IV.6 Tabel kebenaran E2E dan dua tahap.....	58

BAB I

PENDAHULUAN

Bab pendahuluan menjelaskan landasan dan arah penelitian sebagai dasar pengerjaan tugas akhir. Penjelasan meliputi latar belakang (I.1), rumusan masalah (I.2), tujuan dan ukuran keberhasilan pencapaian (I.3), batasan masalah (I.4), metodologi (I.5), dan sistematika pembahasan (I.6).

I.1 Latar Belakang

Komunikasi verbal adalah kemampuan mendasar manusia yang memiliki peran penting dalam interaksi sosial dan ekspresi diri. Sayangnya, jutaan individu kehilangan kemampuan tersebut akibat gangguan neurologis seperti *amyotrophic lateral sclerosis* (ALS), stroke batang otak, dan cedera sumsum tulang belakang. Gangguan tersebut membuat mereka berada dalam kondisi *locked-in*, yaitu kondisi ketika seseorang tetap memiliki fungsi kognitif, tetapi menderita *anarthria* (ketidakmampuan berbicara) dan *quadriplegia* (kelumpuhan) (Moses et al., 2021; Metzger et al., 2023). Akibatnya, keterhubungan mereka ke dunia sosial hilang dan kualitas hidup mereka berkurang secara drastis (Silva et al., 2024).

Untuk menghadapi permasalahan ini, sistem *neuroprosthesis* bicara dapat menjadi solusi dengan mendekode upaya berbicara seseorang secara langsung dari sinyal otak (Silva et al., 2024). Meskipun terdapat alternatif komunikasi lain, seperti *eye tracking*, metode tersebut kurang alami dan memiliki kecepatan yang jauh lebih rendah daripada berbicara (Willett et al., 2023). Saat ini, sistem neuroprosthesis bicara sudah mampu mendekode ucapan secara menerus pada tingkat kalimat sehingga komunikasi dapat berlangsung dengan kecepatan yang terasa seperti berbicara pada umumnya (Willett et al., 2023; Metzger et al., 2023). Namun, sistem seperti ini membutuhkan sinyal otak yang berkualitas tinggi. Metode noninvasif seperti elektroensefalografi (EEG) kurang cocok karena sinyalnya banyak terganggu derau (Shih et al., 2012). Sebaliknya, metode invasif seperti elektrokortikografi (ECoG) merekam sinyal langsung dari permukaan otak

(Metzger et al., 2023) sehingga kualitasnya jauh lebih baik dengan resolusi spasial dan rasio sinyal-terhadap-derau (SNR) yang lebih tinggi (Silva et al., 2024). Oleh karena itu, ECoG lebih cocok untuk sistem neuroprosthesis bicara tingkat kalimat.

Arsitektur *state-of-the-art* sistem neuroprosthesis bicara saat ini dikembangkan melalui dua tahap. Pada tahap pertama, sinyal mentah dari otak dikonversi menjadi probabilitas fonem oleh suatu dekoder akustik berbasis jaringan saraf. Selanjutnya, probabilitas fonem dikonversi menjadi kalimat koheren melalui *beam search* yang dibantu oleh model bahasa. Willett et al. (2023) menggunakan *bidirectional recurrent neural network* (BiRNN) sebagai dekoder fonem dan model bahasa *n-gram* untuk menghasilkan kalimat sehingga menghasilkan *word error rate* (WER) sebesar 17,4%. Seto et al. (2025) mengembangkan metode tersebut dengan mengganti model bahasa *n-gram* dengan model berbasis Transformer, khususnya LLaMA-2, sehingga WER turun menjadi 16,9%.

Meskipun menghasilkan kinerja yang cukup baik, arsitektur dua tahap tersebut memiliki dua keterbatasan utama. Pertama, modul dekode fonem masih mengandalkan arsitektur RNN yang memproses input secara sekuensial dan memiliki kemampuan terbatas dalam menangkap dependensi spasiotemporal pada sinyal ECoG yang terdiri dari banyak kanal. Seto et al. (2025) melaporkan *phoneme error rate* (PER) sebesar 19,2%. Artinya, masih terjadi satu kesalahan untuk setiap lima fonem yang didekode. Kedua, arsitektur dua tahap secara desain berisiko mengalami propagasi kesalahan (*error propagation*). Jika terjadi kesalahan pada langkah dekode fonem, kesalahan tersebut akan diteruskan ke model bahasa sehingga kemungkinan gagal merekonstruksi kalimat yang koheren meningkat (Hannun et al., 2014).

Arsitektur Transformer yang diperkenalkan oleh Vaswani et al. (2017) menjadi alternatif yang berpotensi mengatasi keterbatasan pertama. Berbeda dengan RNN yang memproses data secara sekuensial, Transformer memanfaatkan mekanisme *self-attention* yang memungkinkan model mengintegrasikan konteks dari keseluruhan input secara paralel saat memproses suatu elemen. Hal ini memberikan potensi untuk menangkap hubungan spasiotemporal jangka panjang

secara lebih efektif. Selain itu, Transformer memiliki sejumlah varian yang diadaptasi untuk domain tertentu. Untuk domain ucapan, terdapat varian Conformer (Gulati et al., 2020) yang menambahkan modul konvolusi pada Transformer agar lebih baik dalam menangkap pola lokal pada sinyal akustik.

Akan tetapi, mengganti dekoder fonem dengan Transformer saja tidak menyelesaikan masalah *error propagation*. Hal ini disebabkan oleh arsitektur yang tetap terdiri atas dua tahap dan dioptimasi secara terpisah. Sebagai alternatif, pendekatan *end-to-end* (E2E) memetakan sinyal ECoG langsung menjadi teks tanpa representasi fonem perantara. Secara struktural, pendekatan ini memberikan dua keunggulan. Pertama, seluruh sistem dioptimasi langsung terhadap tujuan akhir berupa teks. Kedua, pengetahuan akustik dan linguistik dari model terlatih dapat dimanfaatkan langsung dalam proses dekode. Membangun model E2E dari nol sulit dilakukan karena dataset ECoG yang terbatas dan kebutuhan komputasi yang besar. Solusi yang lebih praktis adalah memanfaatkan Foundation Model (FM) seperti LLaMA, Qwen, dan Whisper yang telah dilatih pada triliunan token teks atau jutaan jam audio sehingga memiliki pemahaman mendalam tentang bahasa (Bommasani et al., 2021). Pendekatan E2E berbasis FM ini juga lebih mudah diperluas seiring bertambahnya data atau modalitas baru. Oleh karena itu, pemanfaatan FM secara E2E dapat menjadi pendekatan yang menjanjikan untuk sistem *neuroprosthesis* bicara.

Berdasarkan latar belakang tersebut, tugas akhir ini membangun dan membandingkan dua paradigma sistem *neuroprosthesis* bicara pada dataset Willett et al. (2023). Paradigma pertama adalah arsitektur dua tahap yang menggantikan dekoder fonem RNN dengan model berbasis Transformer untuk menangkap dependensi jangka panjang secara lebih efektif. Paradigma kedua adalah arsitektur E2E berbasis FM yang berpotensi menghilangkan masalah *error propagation* dari arsitektur dua tahap. Hasil keduanya dianalisis untuk menjawab apakah kedua solusi tersebut dapat memberikan kinerja yang lebih baik daripada pendekatan sebelumnya. Harapannya, penelitian ini dapat memberi panduan untuk pengembangan sistem *neuroprosthesis* bicara di masa depan dan membantu

memulihkan kemampuan komunikasi bagi individu yang menderita gangguan bicara akibat kondisi neurologis.

I.2 Rumusan Masalah

Sistem *neuroprosthesis* bicara *state-of-the-art* saat ini, sebagaimana dibangun oleh Willett et al. (2023) dan Seto et al. (2025), memiliki dua kelemahan utama. Pertama, modul dekode fonem masih menggunakan arsitektur RNN yang kurang optimal dalam menangkap dependensi spasiotemporal dan jangka panjang. Sebagai alternatif, digunakan model berbasis Transformer untuk meningkatkan akurasi dekode fonem. Kedua, arsitektur dua tahap secara desain berisiko mempropagasi kesalahan dari modul dekode fonem ke modul model bahasa. Sebagai alternatif, sistem dapat diubah menjadi arsitektur E2E berbasis FM untuk menghilangkan representasi fonem perantara dan memanfaatkan pengetahuan linguistik serta akustik yang telah dipelajari FM. Untuk mengevaluasi efektivitas kedua alternatif tersebut, penelitian ini mengembangkan dan membandingkan keduanya dalam sistem *neuroprosthesis* bicara. Oleh karena itu, tugas akhir ini memiliki fokus pada permasalahan berikut.

1. Bagaimana merancang dan mengimplementasikan arsitektur dua tahap berbasis Transformer sebagai dekoder fonem untuk sistem *neuroprosthesis* bicara?
2. Bagaimana arsitektur *end-to-end* (E2E) berbasis Foundation Model untuk sistem *neuroprosthesis* bicara?
3. Bagaimana perbandingan kinerja antara arsitektur dua tahap dan arsitektur *end-to-end* berbasis Foundation Model untuk sistem *neuroprosthesis* bicara?

I.3 Tujuan dan Ukuran Keberhasilan Pencapaian

Penelitian tugas akhir ini memiliki tujuan sebagai berikut.

1. Merancang dan mengimplementasikan arsitektur dua tahap berbasis Transformer sebagai dekoder fonem dalam sistem *neuroprosthesis* bicara. Keberhasilan diukur dari kinerja sistem yang meningkat dari penelitian Seto et al. (2025).

2. Mengimplementasikan arsitektur *end-to-end* berbasis Foundation Model untuk sistem *neuroprosthesis* bicara. Keberhasilan diukur dari kinerja sistem yang meningkat dari penelitian Seto et al. (2025).
3. Menganalisis perbandingan kinerja antara arsitektur dua tahap berbasis Transformer sebagai *decoder* fonem dan arsitektur *end-to-end*. Ukuran keberhasilan berupa hasil analisis perbandingan antara kedua arsitektur.

I.4 Batasan Masalah

Pelaksanaan tugas akhir ini memiliki batasan masalah sebagai berikut.

1. Sistem *neuroprosthesis* bicara dirancang dan dievaluasi menggunakan data publik yang disediakan oleh Willett et al. (2023) dan tidak menggunakan data yang direkam sendiri.
2. Data yang digunakan berasal dari satu partisipan tunggal (T12) sehingga penelitian ini bersifat *subject-dependent*, yaitu model dilatih dan dievaluasi pada partisipan yang sama. Berdasarkan kondisi riset BCI saat ini, pola aktivitas neural sangat bervariasi antarindividu dan bergantung pada lokasi penempatan elektroda sehingga model dari satu partisipan belum dapat langsung dipakai pada partisipan lain (Willett et al., 2023; Silva et al., 2024)..
3. Kosakata yang digunakan terbatas pada daftar kata yang tersedia dalam dataset.

I.5 Metodologi

Metodologi penelitian ini akan mengadopsi alur kerja CRISP-DM. Berikut merupakan tahap-tahap yang dilalui untuk menyelesaikan penelitian pada tugas akhir.

1. Persiapan Data

Dilakukan praproses pada dataset Willett et al. (2023). Hal ini meliputi penggunaan fitur *spike band power* dan *threshold crossings* per *bin* (jangka waktu pendek) 20 milidetik, normalisasi *z-score* per sesi, serta konversi ke format yang dapat diterima oleh model.

2. Perancangan dan Optimasi Arsitektur Dua Tahap dan End-to-End

Pada tahap ini, arsitektur dua tahap dan E2E akan dirancang. Untuk arsitektur dua tahap, metode yang dipaparkan oleh Seto et al. (2025) akan ditiru, namun modul dekode fonem diganti dengan model berbasis Transformer. Untuk arsitektur E2E, beberapa jenis Foundation Model akan dipilih. Setelah itu, modul proyeksi fitur akan dirancang dan dilatih untuk memetakan sinyal ECoG ke ruang *embedding* Foundation Model. Optimasi dilakukan dengan melakukan *fine-tuning* kepada sebagian parameter model agar dapat memproses sinyal otak dengan lebih baik.

3. Evaluasi dan Analisis

Arsitektur dua tahap dan *end-to-end* akan dievaluasi dengan data uji yang berbeda dengan data latih. Kinerja diukur menggunakan metrik *phone error rate* (PER), *word error rate* (WER), dan *character error rate* (CER). Perbandingan akan dilakukan untuk menentukan arsitektur yang memberikan kinerja tertinggi.

I.6 Sistematika Pembahasan

Laporan tugas akhir ini terdiri atas lima bab yang dijabarkan sebagai berikut.

1. Bab I Pendahuluan menjelaskan urgensi dan konteks penelitian dengan menguraikan latar belakang permasalahan komunikasi bagi penderita gangguan bicara. Setelah latar belakang tersebut, bab ini juga memaparkan rumusan masalah, menetapkan tujuan dan ukuran keberhasilan, serta membatasi ruang lingkup penelitian. Terakhir, bab ini menjabarkan metodologi penelitian serta menjelaskan struktur laporan.
2. Bab II Kajian Pustaka memaparkan landasan teori yang meliputi prinsip kerja BCI, akuisisi sinyal ECoG, alur dekode sinyal ECoG menjadi teks, arsitektur Transformer dan variasinya, Foundation Model dan jenis-jenisnya, teknik adaptasi modalitas baru untuk Foundation Model, pelatihan Foundation Model, metrik evaluasi, deskripsi dataset Willett et al. (2023), serta penelitian terkait.

3. Bab III Analisis Masalah dan Rancangan Solusi memaparkan analisis terhadap masalah yang mungkin timbul selama mengerjakan penelitian. Untuk setiap masalah tersebut, alternatif solusi yang dapat diambil juga dijabarkan. Terakhir, dipaparkan detil rancangan solusi yang telah dibuat.
4. Bab IV Evaluasi menjelaskan prosedur yang dijalankan untuk mengevaluasi solusi yang dirancang, hasil evaluasi tersebut, serta pembahasan tentang hasil. Bab ini meliputi desain eksperimen-eksperimen yang dilakukan untuk mengukur kinerja solusi. Hasil setiap eksperimen akan dijabarkan dan dianalisis.
5. Bab V Kesimpulan dan Saran menyajikan ringkasan temuan utama, kesimpulan yang menjawab rumusan masalah, dan saran yang dapat dipakai untuk penelitian/pengembangan selanjutnya.


BAB II

KAJIAN PUSTAKA

Bab ini membahas tentang pustaka yang menjadi dasar pengembangan sistem *neuroprosthesis* bicara serta penelitian terkait.

II.1 Brain Computer Interface (BCI)

Brain-Computer Interface (BCI) adalah sistem yang membangun jalur komunikasi langsung antara otak dan perangkat eksternal sehingga tidak perlu melewati jalur neuromuskular konvensional tubuh (Moses et al., 2021; Shih et al., 2012). Teknologi ini penting bagi individu dengan gangguan neurologis berat yang mengalami kelumpuhan seperti *amyotrophic lateral sclerosis* (ALS), stroke batang otak, atau cedera sumsum tulang belakang tingkat tinggi (Beukelman et al., 2007; Moses et al., 2021). Kondisi seperti ALS ditandai dengan pelumpuhan progresif pada neuron motorik yang menyebabkan hilangnya kendali otot secara drastis. Pada tingkat lanjut, hal ini dapat mengakibatkan kondisi *locked-in*, yaitu kondisi ketika fungsi kognitif seseorang tetap utuh, tetapi kemampuan mereka untuk berbicara atau bergerak hilang sepenuhnya (Moses et al., 2021). Studi menunjukkan bahwa 80% hingga 95% individu dengan ALS pada akhirnya akan kehilangan kemampuan untuk mengeluarkan ucapan. Akibatnya, kualitas hidup mereka menurun secara drastis dan koneksi penderita dengan dunia sosial terputus (Beukelman et al., 2007). BCI menyediakan alternatif untuk memulihkan kemampuan dasar manusia ini dengan menciptakan saluran komunikasi yang tidak memerlukan kendali otot.



Gambar II.1 Contoh pemasangan alat BCI (<https://changlab.ucsf.edu>)

Perangkat *augmentative and alternative communication* (AAC) dapat merupakan alternatif, tetapi memiliki keterbatasan dan kendala tersendiri. Teknologi tersebut tetap memerlukan kemampuan mengontrol otot yang dapat menurun seiring berkembangnya tingkat keparahan penyakit (Moses et al., 2021). Lebih lanjut, perangkat ini seringkali lambat dan melelahkan dengan kecepatan komunikasi yang jauh di bawah kecepatan bicara rata-rata manusia, yaitu 160 kata per menit (Willett et al., 2023). Keterbatasan yang mencolok ini menciptakan kebutuhan yang jelas dan mendesak akan saluran komunikasi yang tidak hanya terpisah dari kontrol motorik, tetapi juga mampu mencapai *bandwidth* komunikasi yang lebih tinggi.

II.1.1 Paradigma Komunikasi BCI

Paradigma BCI memberikan definisi tentang aksi tertentu atau stimulus eksternal yang digunakan untuk menyandikan maksud pengguna menjadi sinyal otak yang dapat diproses. Secara historis, paradigma yang umum dan telah dipelajari dengan baik adalah *P300 speller* (Shih et al., 2012). Dalam sistem ini, pengguna disajikan dengan kisi-kisi karakter, dan seiring dengan adanya baris dan kolom yang berkedip secara berurutan, pengguna memfokuskan perhatian mereka pada karakter yang diinginkan. Pada kasus ini, BCI dilatih untuk mendeteksi gelombang otak yang dikenal sebagai peristiwa P300. P300 muncul dalam sinyal EEG sekitar 300 milisekon setelah pengguna menerima stimulus yang merupakan

target pada tugasnya. Dalam hal ini, target tersebut merupakan kedipan karakter yang mereka ingin eja (Shih et al., 2012). Dengan mengidentifikasi kedipan baris dan kolom mana yang memicu respon P300, sistem dapat menentukan karakter yang dipilih. Meskipun efektif, metode ini pada dasarnya bersifat serial dan memerlukan setiap karakter untuk dieja secara satu-persatu sehingga memperlambat *bandwidth* komunikasi.

Paradigma yang lebih maju bertujuan untuk mendekode langsung maksud motorik atau ucapan pengguna. Sistem ini mencoba menafsirkan perintah saraf yang terkait dengan tindakan yang diinginkan. Misalnya, pengguna mungkin membayangkan atau mencoba menggerakkan tangannya untuk mengontrol kursor. Sebagai contoh dalam *neuroprosthesis* bicara, pengguna membayangkan pengucapan kata atau kalimat (Moses et al., 2021). BCI dirancang untuk menerjemahkan pola aktivitas pada otak yang dihasilkan selama suatu tindakan dilakukan secara langsung menjadi perintah atau keluaran teks yang sesuai.

II.1.2 Metode Akuisisi Sinyal pada BCI

Sistem BCI dapat dikategorisasi berdasarkan metode akuisisi sinyalnya menjadi invasif atau non-invasif. Kedua pilihan ini memiliki *trade-off* antara keamanan dan kualitas sinyal.

Metode non-invasif, seperti elektroensefalografi (EEG), merekam aktivitas listrik otak dari elektroda yang dipasang di kulit kepala (Shih et al., 2012). EEG bersifat aman, relatif murah, dan portabel sehingga banyak digunakan dalam penelitian dan klinis. Namun, kegunaannya untuk BCI yang berkinerja tinggi sangat terbatas. Saat sinyal saraf bergerak dari korteks ke kulit kepala, sinyal tersebut dilemahkan dan dikaburkan secara spasial oleh lapisan di antaranya, terutama tengkorak. Hal ini menghasilkan *signal to noise ratio* (SNR) yang rendah, resolusi spasial yang buruk (berkisar beberapa sentimeter), dan kerentanan yang tinggi terhadap artefak dari aktivitas otot, seperti kedipan mata atau gerakan rahang (Schalk & Leuthardt, 2011).

Metode invasif digunakan untuk mengatasi keterbatasan ini. Elektrokortikografi (ECoG) adalah metode akuisisi sinyal yang dilakukan dengan meletakkan serangkaian elektroda secara langsung ke permukaan otak melalui prosedur bedah. Elektroda umumnya diletakkan di ruang subdural di bawah dura mater (Schalk & Leuthardt, 2011). Prosedur bedah yang dilakukan bernama kraniotomi, prosedur yang membawa risiko seperti infeksi dan pendarahan. Namun, dengan menempatkan sensor di dekat sumber saraf, ECoG menghindari efek distorsi tengkorak. Hasilnya adalah sinyal dengan SNR yang jauh lebih unggul, resolusi spasial yang jauh lebih tinggi (dalam orde milimeter), dan *bandwidth* frekuensi yang lebih luas dibandingkan dengan EEG (Michel & Murray, 2011; Schalk & Leuthardt, 2011). Untuk tugas-tugas kompleks dan berkecepatan tinggi, seperti mendekode sinyal saraf dari ucapan kalimat dengan kosakata beragam, kualitas sinyal EEG umumnya tidak mencukupi. Oleh karena itu, kualitas sinyal milik ECoG diperlukan untuk melakukan dekode dengan kinerja tinggi.

II.1.3 Elektrokortikografi (ECoG)

ECoG merupakan jenis elektroensefalografi intrakranial yang merekam aktivitas listrik secara langsung dari permukaan korteks serebral (Metzger et al., 2023). Prosedur klinisnya melibatkan kraniotomi untuk menghasilkan bukaan sementara pada tengkorak dan membukakan dura mater, yaitu membran luar otak. Dura mater kemudian diiris untuk memperlihatkan permukaan kortikal. Serangkaian elektroda kemudian ditempatkan di ruang subdural otak (Schalk & Leuthardt, 2011).


Susunan elektroda tersebut biasanya dibentuk dari bahan yang bersifat biokompatibel, seperti karet silikon, yang dibubuhkan susunan elektroda cakram logam kecil yang terbuat dari paduan platinum-iridium atau *stainless steel* (Metzger et al., 2023). Pada sistem yang berkinerja tinggi, susunan yang dipakai umumnya berdensitas tinggi dan terdiri dari 253 hingga 256 elektroda dengan jarak antar pusat sebesar tiga hingga empat milimeter (Metzger et al., 2023). Sinyal saraf yang terekam ditransmisikan dari elektroda melalui kabel tipis yang disalurkan di bawah kulit menuju konektor pedestal perkutan yang dipasang

secara edah pada tengkorak. Konektor ini berfungsi sebagai tempat pemasangan *headstage* digital untuk melakukan digitalisasi dan transmisi data neural menuju komputer untuk pemrosesan (Metzger et al., 2023).

II.1.4 Produksi Ucapan dalam Otak

Produksi ucapan merupakan salah satu perilaku motorik paling kompleks yang dapat dilakukan manusia. Produksi ucapan memerlukan koordinasi yang tepat dan cepat untuk lebih dari 100 otot yang mengendalikan sistem pernapasan, laring, serta artikulator saluran vokal (bibir, lidah, rahang, dan velum). Tindakan motorik rumit ini diatur oleh jaringan kortikal yang tersebar luas, terutama di daerah lobus frontal, temporal, dan parietal di hemisfer dominan bahasa (yang umumnya merupakan hemisfer kiri).

Untuk keperluan BCI dalam ucapan, kisi ECoG diletakkan secara strategis di daerah kortikal yang memiliki peran penting dalam kontrol motorik dan artikulasi ucapan. Area penting di antaranya adalah *ventral sensorimotor cortex* (vSMC) yang mencakupi sebagian dari *precentral gyrus* dan *postcentral gyrus*. Daerah tersebut mengandung representasi neural dari muka, bibir, lidah, dan laring (Metzger et al., 2023). Daerah kritis lainnya di lobus frontal meliputi korteks premotor yang terlibat dalam merencanakan sekuens motorik. Selain itu, terdapat daerah seperti area Broca yang berperan dalam pemrosesan fonem dan sintaksis (Indefrey, 2011). Selain itu, area lobus temporal, khususnya *superior temporal gyrus* (STG), terlibat dalam memproses umpan balik suara selama ucapan. Pemrosesan ini penting untuk memantau dan membetulkan keluaran ucapan tersendiri (Moses et al., 2021). Area tersebut umum ditargetkan pada pemasangan elektroda ECoG, dengan susunan elektroda yang mencakup *precentral gyrus*, *postcentral gyrus*, *superior temporal gyrus*, serta *middle temporal gyrus* (Metzger et al., 2023; Willet et al., 2023). Pada sistem *neuroprosthesis* bicara milik Metzger et al. (2023), digunakan penempatan ECoG yang seperti pada Gambar II.2.




Gambar II.2 Contoh penempatan kisi ECoG untuk sistem *neuroprosthesis* bicara (Metzger et al., 2023)

II.2 Dataset Willett et al. (2023)

Tugas akhir ini menggunakan dataset publik yang dikumpulkan oleh Willett et al. (2023). Dataset ini berisi rekaman aktivitas neural dari satu partisipan berkode T12, yaitu seorang penderita ALS yang mengalami *anarthria* sehingga ucapannya tidak lagi dapat dipahami. Data dikumpulkan selama beberapa bulan dalam 24 sesi perekaman. Pada setiap *trial*, partisipan disajikan sebuah kalimat dan diminta mencoba mengucapkannya saat diberikan isyarat oleh komputer. Perekaman dihentikan ketika partisipan menekan tombol. Pada sebagian hari, partisipan mencoba mengucapkan kalimat secara normal, sedangkan pada hari lain ia hanya menggerakkan mulut tanpa bersuara (*mouthing*) (Willett et al., 2023). Setiap *trial* memasang potongan waktu aktivitas neural dengan transkripsi teks dari kalimat yang dicoba diucapkan.

Aktivitas neural direkam melalui susunan mikroelektroda intrakortikal yang ditanam pada korteks partisipan. Sinyal mentah dari elektroda kemudian diolah menjadi dua jenis fitur per kanal untuk setiap *bin* waktu selebar 20 milidetik. Fitur pertama adalah *threshold crossings*, yaitu hitungan berapa kali tegangan terekam

melintasi suatu ambang batas dalam satu *bin*. Pada dataset ini, ambang batas yang digunakan adalah -3,5 kali nilai *root mean square* (RMS) sinyal. Fitur kedua adalah *spike band power*, yaitu rata-rata kuadrat tegangan setelah penyaringan *high-pass* pada frekuensi 250 Hz dalam satuan mikrovolt kuadrat. Kedua jenis fitur tersebut telah didenoise dengan teknik *linear regression reference*, yaitu penghilangan derau antarkanal dengan memprediksi dan mengurangi komponen sinyal yang dapat diestimasi dari sinyal-sinyal lain (Willett et al., 2023). Dataset menyediakan empat varian *threshold crossings* dengan ambang berbeda, tetapi penyedia dataset menganjurkan untuk hanya menggunakan varian dengan ambang -3,5 kali RMS.



Gambar II.3 Tata letak dua area kortikal pada susunan elektroda


Susunan elektroda mencakup dua area kortikal, yaitu area 6v dan area 44, sehingga tersedia 256 kanal secara total. Penyedia dataset menganjurkan untuk

hanya menggunakan 128 kanal pertama yang berasal dari area 6v karena area inilah yang paling informatif untuk dekode ucapan (Willett et al., 2023). Dengan demikian, setiap *bin* waktu direpresentasikan oleh vektor berdimensi 256, yaitu 128 nilai *threshold crossings* dan 128 nilai *spike band power* dari kanal area 6v. Tata letak kedua area kortikal beserta kanal yang digunakan ditunjukkan pada Gambar II.3.

Kalimat yang digunakan pada setiap *trial* berasal dari korpus bahasa Inggris berkosakata luas, yaitu korpus Switchboard dan korpus Open Web Text. Seluruh kalimat berasal dari kosakata umum yang bervariasi (Willett et al., 2023). Secara keseluruhan terdapat sekitar 8800 *trial* latih dan 880 *trial* uji.

II.3 Pemrosesan Sinyal ECoG Menjadi Teks

Bagian ini menjelaskan alur mendekode sinyal ECoG menjadi teks koheren sebagaimana dilakukan oleh Willett et al. (2023). Secara ringkas, proses meliputi praproses dan ekstraksi fitur neural, prediksi probabilitas fonem, konstruksi kalimat dengan model bahasa, serta pengukuran kinerja melalui metrik evaluasi. Alur lengkapnya ditunjukkan pada Gambar II.4.



Gambar II.4 Proses mendekode sinyal ECoG menjadi teks (Willett et al., 2023)

II.3.1 Praproses Sinyal ECoG dan Ekstraksi Fitur

Sinyal ECoG mentah yang direkam dari susunan elektroda tidak langsung diteruskan ke model pembelajaran mesin. Sebelum itu, praproses dilakukan untuk mengurangi derau dan mengekstraksi fitur yang lebih informatif tentang niat pengguna. Sinyal mentah terlebih dahulu dikelompokkan menjadi jangka waktu pendek yang disebut *bin*. Proses pengelompokan ini dinamakan *temporal binning*. Pada dataset yang digunakan, lebar satu *bin* ditetapkan pada 20 milidetik (Willett et al., 2023; Metzger et al., 2023).

Untuk setiap *bin*, dihitung dua fitur per elektroda, yaitu *spike band power* dan *threshold crossings* sebagaimana dijelaskan pada bagian II.2. Dataset ini menggunakan *threshold crossings* dan *spike band power* yang menangkap aktivitas potensial di sekitar elektroda (Willett et al., 2023). Keluaran tahap ekstraksi fitur adalah matriks fitur berdimensi $T \times 256$ dengan T sebagai jumlah *bin* waktu dalam satu ujaran.

Matriks fitur tersebut kemudian dinormalisasi dengan *z-score* per sesi untuk mengatasi variasi statistik sinyal antarsesi perekaman yang dapat bernilai cukup besar (Willett et al., 2023). Pada tahap pelatihan, diterapkan pula *Gaussian smoothing* pada dimensi waktu serta augmentasi data berupa penambahan *white noise* dan *constant offset* untuk meningkatkan ketahanan model terhadap variasi sinyal. Teknik *subsampling* pada dimensi waktu juga dilakukan, misalnya dengan faktor empat, agar panjang sekuens lebih ringkas sebelum diproses.

II.3.2 Pemetaan Fitur ECoG Menjadi Probabilitas Fonem

Matriks fitur diteruskan ke suatu jaringan saraf berupa dekoder. Fungsi dekoder adalah mentranslasikan pola temporal dari fitur neural menjadi representasi linguistik perantara. Contoh arsitektur dekoder yang dipilih pada literatur, seperti oleh Willett et al. (2023), adalah *recurrent neural network* (RNN) berbasis *gated recurrent unit* (GRU). RNN adalah jaringan saraf yang didesain untuk memodelkan data sekuensial dengan mempertahankan keadaan tersembunyi (*hidden state*) yang mengandung informasi dari waktu sebelumnya. Akan tetapi,

RNN sederhana sulit mempertahankan informasi pada sekuens yang panjang karena masalah gradien menghilang (*vanishing gradient*). GRU adalah varian RNN yang mengatasi keterbatasan tersebut dengan menambahkan mekanisme gerbang (*gate*), yaitu gerbang pembaruan (*update gate*) dan gerbang pengaturan ulang (*reset gate*). Kedua gerbang ini mengatur seberapa banyak informasi lama yang dipertahankan dan informasi baru yang ditambahkan ke *hidden state* sehingga GRU lebih mampu menangkap dependensi jangka panjang daripada RNN sederhana (Cho et al., 2014).

Alih-alih memprediksi kata secara langsung dari fitur neural, dekoder umumnya dilatih untuk memprediksi fonem, yaitu satuan bunyi mendasar dari suatu bahasa. Sebagai contoh, kata *cat* dalam bahasa Inggris tersusun dari fonem /k/, /æ/, dan /t/. Pendekatan ini memiliki keunggulan dari sisi kompleksitas. Karena tidak memprediksi langsung dari ribuan kemungkinan kata, jumlah kelas yang diprediksi jauh lebih sedikit. Pada penelitian Willett et al. (2023), dekoder memprediksi 39 fonem ditambah satu token jeda sehingga berjumlah 40 kelas, lalu ditambah satu token kosong (*blank*) yang dibutuhkan oleh fungsi *loss* CTC. Hal ini mengurangi kompleksitas pelatihan secara signifikan.

Salah satu tantangan dalam dekode fonem adalah panjang sekuens fitur neural yang jauh lebih besar daripada panjang sekuens fonem keluaran. Selain itu, tidak terdapat penanda waktu yang secara otomatis menyelaraskan fitur neural dengan sekuens fonem. Untuk menangani tantangan tersebut, dekoder dilatih dengan fungsi *loss* berupa *connectionist temporal classification* (CTC) yang memungkinkan pelatihan pada pasangan sekuens yang belum diselaraskan (*unaligned*) (Graves et al., 2006). Untuk setiap *bin* waktu, jaringan menghasilkan distribusi probabilitas atas seluruh kelas fonem ditambah token kosong. Token kosong memungkinkan model menghasilkan keluaran ketika tidak ada fonem yang sedang dihasilkan dan berguna untuk memisahkan fonem yang berulang.

CTC mendefinisikan probabilitas sekuens fonem Y dengan menjumlahkan probabilitas seluruh penyelarasan (alignment) A yang valid, yaitu seluruh deret keluaran sepanjang T yang dapat direduksi menjadi Y . Probabilitas tersebut dirumuskan sebagai berikut.

$$p(Y | X) = \sum_{A \in B^{-1}(Y)} \prod_{t=1}^T p(a_t | X)$$

Pada rumus tersebut, X adalah matriks fitur masukan, a_t adalah keluaran pada *bin* waktu ke- t , dan B adalah fungsi yang menghapus token kosong dan menggabungkan keluaran yang terulang sehingga memetakan suatu *alignment* menjadi sekuens fonem akhir. Fungsi *loss* CTC adalah negatif logaritma dari probabilitas tersebut. Hasil akhir tahap ini adalah matriks probabilitas fonem berdimensi $T \times 41$ dengan 41 sebagai jumlah seluruh kelas keluaran, yaitu 39 fonem, satu token jeda, dan satu token kosong.

II.3.3 Pemetaan Fonem ke Teks

Matriks probabilitas fonem ditranslasikan menjadi teks yang koheren melalui model bahasa yang dipadukan dengan algoritma pencarian. Model bahasa adalah model statistik yang memberikan probabilitas atas suatu rangkaian kata. Hal ini umumnya dilakukan dengan memprediksi probabilitas kata berikutnya jika diberikan beberapa kata sebelumnya. Pada arsitektur dua tahap, pemetaan fonem ke teks dilakukan melalui dua langkah, yaitu dekode dengan model bahasa *n-gram* dan *rescoring* dengan model bahasa neural.

1. Dekode dengan model bahasa *n-gram*

Langkah pertama adalah memakai model bahasa *n-gram*, yaitu model yang mengestimasi probabilitas suatu kata dari sejumlah kata sebelumnya. Willett et al. (2023) menggunakan model *5-gram*. Agar dekode dapat dilakukan secara efisien, model *5-gram* direpresentasikan sebagai *weighted finite-state transducer* (WFST). WFST adalah *finite automata* berbobot yang memetakan sekuens masukan menjadi sekuens keluaran

sambil mengakumulasi bobot di sepanjang jalurnya (Mohri et al., 2002). WFST menyatukan tiga tingkat pengetahuan ke dalam satu graf, yaitu token (T) yang memetakan keluaran CTC menjadi fonem, leksikon (L) yang menghubungkan fonem menjadi kata, serta tata bahasa *n-gram* (G) yang memuat aspek linguistik (Mohri et al., 2002). Komponen T dan L berperan sebagai kerangka yang menentukan jalur fonem dan kata yang sah, sedangkan model bahasa pada graf berasal dari komponen G.

Penelusuran jalur terbaik pada WFST dilakukan dengan algoritma *beam search*. Algoritma ini membangun hipotesis kalimat secara bertahap dari kiri ke kanan. Pada setiap langkah, setiap hipotesis parsial yang masih hidup diperluas dengan kemungkinan kata kelanjutannya, lalu setiap hasil perluasan diberi skor. Alih-alih menelusuri seluruh calon kalimat yang mahal secara komputasi, *beam search* hanya mempertahankan sejumlah hipotesis dengan skor terbaik pada setiap langkah, sedangkan sisanya dipangkas. Jumlah hipotesis yang dipertahankan ini disebut lebar *beam*. Untuk memadukan skor dari dekoder fonem (model akustik) dengan skor dari model bahasa, digunakan teknik *shallow fusion* (Metzger et al., 2023). Pada setiap langkah pencarian, skor total suatu hipotesis dihitung sebagai jumlah berbobot dari skor akustik dan skor model bahasa sebagaimana dirumuskan berikut.

$$skor(W) = \log p_{akustik}(W) + \lambda \cdot \log p_{LM}(W)$$

Pada rumus tersebut, W adalah hipotesis kalimat, $p_{akustik}$ adalah probabilitas dari dekoder fonem, p_{LM} adalah probabilitas dari model bahasa *n-gram*, dan λ adalah bobot yang mengatur pengaruh model bahasa. Skor akustik berasal dari dekoder fonem di luar graf, sedangkan skor linguistik p_{LM} merupakan bobot *n-gram* dari komponen G yang telah tertanam dalam graf WFST. Keluaran langkah ini berupa daftar *n-best*, yaitu sejumlah hipotesis kalimat dengan skor tertinggi.

2. Penskoran ulang (*rescoring*) dengan model bahasa neural

Daftar *n-best* dari langkah pertama kemudian dinilai ulang (*rescoring*) dengan model bahasa neural yang lebih kuat seperti LLaMA-2 (Touvron et al., 2023). Berbeda dengan *n-gram* yang hanya melihat beberapa kata terakhir, model bahasa neural berbasis Transformer mampu mempertimbangkan seluruh konteks kalimat sehingga memberikan penilaian linguistik yang lebih baik (Vaswani et al., 2017). Skor akhir tiap hipotesis dihitung dari kombinasi berbobot antara skor akustik, skor model bahasa neural, dan bonus penyisipan kata sebagaimana dirumuskan berikut.

$$skor_f(W) = s_{ak} \cdot \log p_{ak}(W) + \alpha \cdot \log p_{neur}(W) + \beta \cdot N_{kata}(W)$$

Pada rumus tersebut, W adalah hipotesis kalimat, $\log p_{ak}$ adalah skor akustik hipotesis dari tahap dekode WFST, $\log p_{neur}$ adalah log-probabilitas hipotesis menurut model bahasa neural, dan N_{kata} adalah jumlah kata pada hipotesis. Adapun s_{ak} adalah skala akustik, α adalah bobot model bahasa neural, dan β adalah bobot bonus penyisipan kata. Suku terakhir, yaitu β dikalikan N_{kata} , berperan sebagai bonus penyisipan kata (*word insertion bonus*), yaitu nilai tambahan yang diberikan untuk setiap kata pada hipotesis. Bonus ini diperlukan karena model bahasa cenderung memberi skor lebih tinggi pada hipotesis yang lebih pendek sehingga sistem cenderung menghilangkan kata tanpa bonus tersebut. Dengan memberi tambahan skor untuk setiap kata, kecenderungan menghilangkan kata dapat diimbangi. Hipotesis dengan skor akhir tertinggi dipilih sebagai teks keluaran.

II.3.4 Metrik Evaluasi pada Dekode Sinyal ECoG ke Teks

Terdapat beberapa metrik untuk mengukur kinerja dekode sinyal ECoG ke teks, baik dari aspek akurasi maupun kecepatan. Daftar metrik yang digunakan ditunjukkan pada Tabel II.1.

Tabel II.1 Metrik evaluasi sistem *neuroprosthesis* bicara

Metrik	Definisi	Deskripsi
<i>Word Error Rate (WER)</i>	$(S + D + I) / N_{kata}$	Menghitung ketepatan dalam tingkat kata. Angka S, D, dan I masing-masing merupakan jumlah substitusi, penghapusan, dan penyisipan kata yang perlu dilakukan untuk menyamakan teks dengan referensi (Metzger et al., 2023).
<i>Character Error Rate (CER)</i>	$(S + D + I) / N_{huruf}$	Menghitung ketepatan dalam tingkat kata. Angka S, D, dan I masing-masing merupakan jumlah substitusi, penghapusan, dan penyisipan karakter yang perlu dilakukan untuk menyamakan teks dengan referensi (Metzger et al., 2023).
<i>Phoneme Error Rate (PER)</i>	$(S + D + I) / N_{fonem}$	Menghitung ketepatan dalam tingkat kata. Angka S, D, dan I masing-masing merupakan jumlah substitusi, penghapusan, dan penyisipan fonem yang perlu dilakukan untuk menyamakan teks dengan referensi (Willett et al., 2023).
<i>Words per Minute (WPM)</i>	$(N_{kata \text{ yang didekode}} / T)$	Menghitung kecepatan komunikasi yang disediakan oleh BCI (Metzger et al., 2023).
<i>Real-time Factor (RTF)</i>	$(T_{pemrosesan} / T_{audio})$	Menghitung efisiensi komputasional sistem. Nilai RTF yang kurang

		dari 1.0 penting agar sistem dapat memproses informasi lebih cepat daripada laju informasi baru yang datang (Seto et al., 2025).
--	--	--

II.4 Model Berbasis Transformer

Model berbasis Transformer merupakan pendekatan jaringan saraf neural yang telah menjadi fondasi sebagian besar model modern. Dalam *neuroprosthesis* bicara, Transformer memiliki kegunaan baik untuk dekode fonem maupun untuk Foundation Model. Bagian ini menjelaskan tentang Transformer murni, lalu Conformer sebagai varian untuk *domain* ucapan, dan terakhir *spatial attention* sebagai modul tambahan untuk sinyal ECoG berkanal banyak.

II.4.1 Transformer


Arsitektur Transformer diperkenalkan oleh Vaswani et al. (2017) sebagai alternatif dari model tradisional seperti RNN. Berbeda dengan RNN yang sulit mengingat informasi secara jangka panjang, Transformer memanfaatkan mekanisme *self-attention* yang memungkinkan model untuk mengintegrasikan konteks dari keseluruhan *input* secara sekaligus. Hal ini memberikan potensi bagi Transformer untuk menangkap hubungan spasiotemporal secara lebih optimal dibandingkan RNN. Selain itu, mekanisme *self-attention* memungkinkan Transformer untuk memproses *input* secara paralel, sedangkan RNN harus memproses *input* secara satu persatu. Hal ini memungkinkan pelatihan Transformer yang lebih efisien daripada RNN.

Mekanisme *self-attention* adalah komponen yang memungkinkan model memberikan tingkat kepentingan yang berbeda pada setiap token dalam *input* relatif terhadap elemen lainnya. Pertama, setiap vektor *input* diproyeksikan secara linier menjadi tiga vektor berbeda, yaitu *query* (Q), *key* (K), dan *value* (V). Skor *attention* dihitung dengan melakukan *dot product* antara vektor Q dari satu posisi token dengan vektor K dari seluruh posisi lainnya. Hasil ini menentukan seberapa

besar perhatian yang diberikan posisi saat ini ke posisi lainnya dalam *input*. Skor tersebut dibagi dengan akar kuadrat dari dimensi vektor untuk menjaga stabilitas gradien dan diproses melalui fungsi *softmax*. Hasilnya adalah matriks bobot probabilitas yang kemudian dikalikan dengan vektor V . Posisi dengan bobot tinggi akan memberikan lebih banyak informasi ke representasi akhir pada posisi tersebut.

$$Attention(Q, K, V) = softmax(QK^T / \sqrt{d_k}) V$$

Secara utuh, arsitektur Transformer dapat dilihat pada Gambar II.4. Awalnya, Transformer memproses suatu *input* menjadi vektor berdimensi tinggi terlebih dahulu melalui matriks *embedding*. Setelah itu, karena Transformer tidak secara langsung memiliki informasi tentang letak token relatif terhadap token lainnya, *positional encoding* ditambahkan ke vektor *embedding* agar model dapat membedakan token yang sama pada posisi berbeda. Vektor yang telah memiliki informasi posisi masuk ke lapisan *multi-head attention* (MHA) yang melakukan operasi *self-attention* secara paralel untuk menangkap berbagai jenis hubungan antar token dalam urutan secara bersamaan. Setiap *head* mempelajari aspek hubungan yang berbeda dengan menggunakan proyeksi Q , K , dan V yang berbeda. Setelah itu, *residual connection* dan normalisasi (*add & norm*) masing-masing digunakan untuk mempertahankan informasi awal suatu *token* sebelum *attention* dan untuk menjaga kestabilan distribusi nilai aktivasi. Keluaran dari lapisan MHA diproses oleh jaringan saraf *fully-connected* untuk memperdalam representasi fitur. Hasil dari *fully-connected* akan diproses kembali melalui lapisan linier dan *softmax* untuk mendapat prediksi akhir.



Gambar II.4 Arsitektur Transformer (Vaswani et al., 2017)

Transformer, pada awalnya, seperti yang dijelaskan oleh Vaswani et al. (2017), terdiri dari bagian *encoder* dan *decoder*. Bagian *encoder* berfungsi untuk memproses *input* sehingga menghasilkan representasi matematis darinya. Bagian *decoder* menghasilkan urutan *output* secara autoregresif dan menggunakan *masked self-attention* untuk mencegahnya dari melihat masa depan. Kedua komponen terhubung oleh mekanisme *cross-attention*. Pada mekanisme ini, *decoder* menggunakan representasi dari *encoder* untuk melakukan penyelarasan antara urutan *output* yang sedang dihasilkan dengan informasi penting dari urutan *input*.

Mekanisme *attention* tidak terbatas pada dimensi token atau waktu. Operasi yang sama dapat diterapkan pada dimensi lain, misalnya pada dimensi kanal elektroda untuk sinyal ECoG. Penerapan *attention* pada dimensi elektroda ini disebut *spatial attention*. Pada *spatial attention*, setiap kanal diperlakukan sebagai satu elemen sehingga *attention* dihitung secara antarkanal untuk menyorot kanal yang paling informatif. Karena sinyal ECoG terdiri atas banyak kanal yang memiliki dependensi spasial, *spatial attention* dapat dicoba karena berpotensi membantu model menangkap hubungan antarelektroda yang belum ditangani oleh *attention* pada dimensi waktu.


II.4.2 Conformer

Conformer adalah varian Transformer yang dirancang khusus untuk domain ucapan oleh Gulati et al. (2020). Kelemahan Transformer murni adalah mekanisme *self-attention* yang unggul dalam menangkap dependensi global, tetapi kurang efektif dalam menangkap pola lokal yang berdekatan pada dimensi waktu. Padahal, sinyal ucapan memiliki pola lokal yang penting seperti transisi antarfonem. Untuk mengatasi hal ini, Conformer menambahkan modul konvolusi di dalam blok Transformer sehingga model dapat menangkap pola lokal sekaligus dependensi global (Gulati et al., 2020). Arsitektur *encoder* Conformer secara utuh ditunjukkan pada Gambar II.4.

Bagian kiri Gambar II.4 memperlihatkan alur *encoder* Conformer secara keseluruhan. Masukan terlebih dahulu melewati beberapa tahap awal sebelum diproses oleh blok Conformer. Pertama, masukan melewati SpecAugment, yaitu teknik augmentasi data yang menutup (*masking*) sebagian blok langkah waktu dan sebagian blok fitur pada matriks masukan secara acak selama pelatihan (Park et al., 2019). Dengan menyembunyikan sebagian masukan, model dipaksa untuk tidak bergantung pada bagian tertentu saja sehingga lebih tahan terhadap variasi dan tidak mudah mengalami *overfitting*. Kedua, masukan melewati *convolution subsampling* yang menggabungkan beberapa langkah waktu yang berdekatan menjadi satu sehingga jumlah langkah berkurang dan sekuens menjadi lebih ringkas. Sebagai contoh, pada arsitektur asli Gulati et al. (2020), laju masukan

diturunkan dari satu langkah per 10 milidetik menjadi satu langkah per 40 milidetik. Akibatnya, setiap langkah keluaran merangkum informasi dari sekitar empat langkah masukan sehingga tiap langkah membawa konteks waktu yang lebih lebar. Setelah itu, masukan melewati satu lapisan linier dan *dropout*, lalu diproses oleh N blok Conformer yang ditumpuk secara berurutan.

Bagian kanan Gambar II.4 memperlihatkan susunan satu blok Conformer. Berbeda dengan blok Transformer yang hanya memiliki satu modul *feed-forward*, blok Conformer mengapit modul *multi-head self-attention* dan modul konvolusi dengan dua modul *feed-forward*. Kedua modul *feed-forward* tersebut menerapkan residual setengah, yaitu keluaran modul dikalikan setengah terlebih dahulu sebelum dijumlahkan dengan masukannya. Hal ini dilakukan sehingga pengaruh tiap modul *feed-forward* terhadap representasi diperhalus. Modul lainnya memakai koneksi residual penuh yang menjumlahkan masukan modul dengan keluarannya. Setelah seluruh modul dilewati, blok ditutup dengan *layer normalization*, yaitu normalisasi yang menyetel nilai aktivasi pada setiap langkah agar memiliki rata-rata nol dan variansi satu. Modul konvolusi adalah yang menjadi pembeda utama Conformer dengan Transformer. Modul tersebut menggunakan konvolusi satu dimensi pada dimensi waktu dengan ukuran *kernel* tertentu, misalnya 31. Ukuran *kernel* 31 berarti setiap operasi konvolusi mencakup 31 langkah waktu yang berdekatan sekaligus sehingga modul dapat menangkap pola lokal antar-*bin* dalam jendela tersebut. Dengan susunan ini, Conformer memadukan kekuatan *self-attention* untuk konteks global dan konvolusi untuk pola lokal sehingga lebih sesuai untuk sinyal berderet waktu seperti ucapan (Gulati et al., 2020).



Gambar II.4 Arsitektur *encoder* Conformer (kiri) dan susunan satu blok Conformer (kanan) (Gulati et al., 2020)

II.5 Foundation Model

Foundation Model (FM) adalah model yang dilatih dengan skala data yang sangat luas (umumnya menggunakan metode pembelajaran mandiri) sehingga dapat diadaptasi ke berbagai macam tugas hilir (*downstream tasks*) (Bommasani et al., 2021). Umumnya, Foundation Model memanfaatkan Transformer dalam arsitekturnya karena kemampuannya dalam menangkap dependensi jangka panjang. Terdapat beberapa sifat yang wajib dimiliki oleh FM. FM perlu mampu untuk menangkap distribusi data yang kompleks (*expressivity*), mengelola jumlah

data dan parameter yang sangat besar secara efisien (*scalability*), menghubungkan berbagai jenis modalitas (*multimodality*), menyimpan pengetahuan dalam jangka waktu panjang (*memory capacity*), dan melakukan generalisasi ke konteks dan tugas baru (*compositionality*) (Bommasani et al., 2021). Sifat-sifat tersebut memungkinkan FM untuk memanfaatkan pengetahuan mendalamnya yang diperoleh dari triliunan token data latih untuk melakukan generalisasi pada modalitas baru.

II.5.1 Variasi Arsitektur Foundation Model

Variasi arsitektur FM secara umum dapat dikategorikan berdasarkan konfigurasi blok Transformer dan tujuan pelatihannya. Arsitektur *encoder-only* seperti BERT dirancang utamanya untuk pemahaman bahasa (*natural language understanding*) melalui *masked language modeling*, yaitu menyembunyikan sebagian token lalu memprediksinya kembali dari konteks sekitarnya (Devlin et al., 2019). Arsitektur ini efektif untuk menangkap hubungan dan pola pada suatu teks, tetapi kurang sesuai untuk menghasilkan teks panjang. Arsitektur *encoder-decoder* seperti T5 memiliki *encoder* yang mengekstraksi representasi kontekstual dari input dan *decoder* yang memanfaatkan representasi tersebut melalui *cross-attention* untuk menghasilkan teks target (Raffel et al., 2020). Arsitektur ini unggul untuk tugas *sequence-to-sequence* seperti translasi dan transkripsi ucapan. Terakhir, arsitektur *decoder-only* yang menjadi paradigma umum model generatif berfokus pada pemodelan bahasa autoregresif, yaitu memprediksi token berikutnya dari token-token sebelumnya. Kemampuan ini membuatnya cocok untuk tugas generatif seperti mendekode kalimat.

Untuk arsitektur E2E, baik *decoder-only* maupun *encoder-decoder* sama-sama berpotensi untuk tugas dekode sinyal ECoG, tetapi dengan alasan berbeda. Model *decoder-only* yang berbasis teks unggul dalam pengetahuan linguistik yang luas sehingga kuat dalam merangkai kalimat yang koheren. Model *encoder-decoder* audio telah terlatih untuk memetakan sinyal dari modalitas berbeda menjadi teks sehingga mekanisme *cross-attention*-nya secara alami sesuai untuk memetakan

sinyal neural menjadi teks. Daftar FM yang digunakan dalam tugas akhir ini beserta karakteristiknya ditunjukkan pada Tabel II.3.

Tabel II.3 Daftar Foundation Model yang digunakan beserta karakteristiknya.

Model	Penyedia	Arsitektur	Modalitas Pelatihan
Qwen3.5 (Base)	Alibaba	<i>Decoder-only</i>	Teks
LLaMA-2	Meta	<i>Decoder-only</i>	Teks
Whisper	OpenAI	<i>Encoder-decoder</i>	Audio
Cohere Transcribe	Cohere	<i>Encoder-decoder</i>	Audio
Canary-Qwen	NVIDIA	<i>Decoder-only</i> audio-teks	Audio dan teks
Granite-Speech	IBM	<i>Decoder-only</i> audio-teks	Audio dan teks

Qwen3 adalah keluarga model bahasa *decoder-only* dari Alibaba yang dilatih pada teks berskala besar dengan dukungan banyak bahasa (Qwen Team, 2025). LLaMA-2 adalah keluarga model bahasa *decoder-only* dari Meta yang banyak digunakan sebagai dasar berbagai tugas pemrosesan bahasa (Touvron et al., 2023). Pada tugas akhir ini, LLaMA-2 dipakai sebagai model bahasa neural untuk *rescoring* pada arsitektur dua tahap, sedangkan Qwen3.5 dipakai sebagai dekoder pada arsitektur E2E.

Whisper adalah model *encoder-decoder* untuk pengenalan ucapan otomatis yang dilatih pada jutaan jam audio (Radford et al., 2022). Cohere Transcribe juga merupakan model *encoder-decoder* audio yang dibuat oleh CohereLabs. Keduanya dimanfaatkan secara utuh sebagai model audio dengan sinyal ECoG dimasukkan melalui jalur *cross-attention*, sedangkan *encoder* audio bawaannya tidak dipakai.

Canary-Qwen dan Granite-Speech merupakan model bahasa besar audio-teks yang telah terbukti menjadi fondasi sistem pengenalan ucapan berkinerja tinggi. Pada tugas akhir ini, model bahasa teks di dalamnya digunakan ulang dengan adaptasi untuk dapat memproses sinyal neural. Untuk Canary-Qwen, komponen yang digunakan ulang adalah model bahasa Qwen3-1.7B beserta proyektor yang telah dilatih untuk penyalarsan ucapan. Untuk Granite-Speech, komponen yang digunakan hanyalah model bahasanya, sedangkan encoder audio bawaannya tidak dipakai. Keberhasilan kedua model bahasa ini sebagai fondasi sistem pengenalan ucapan menunjukkan potensinya untuk memetakan sinyal ECoG menjadi teks.

II.5.2 Adaptasi Foundation Model untuk Modalitas Baru

FM yang umumnya berbasis teks atau audio belum dapat langsung menerima sinyal ECoG sebagai input. Oleh karena itu, diperlukan mekanisme adaptasi agar sinyal ECoG dapat dipetakan ke ruang representasi FM. Pada tugas akhir ini, sinyal ECoG terlebih dahulu diproses oleh *encoder* Conformer yang telah dibahas pada bagian II.4 untuk menghasilkan representasi neural. Representasi tersebut kemudian diadaptasi ke FM melalui tiga teknik yang dijelaskan pada subbagian berikut, yaitu proyeksi linier, konkatenasi LLaVA, dan *cross-attention*.

1. Matriks proyeksi linier

Keluaran *encoder* Conformer dapat memiliki dimensi yang berbeda dengan dimensi *embedding* FM. Untuk menjembatani perbedaan ini, digunakan matriks proyeksi linier, yaitu lapisan linier yang mengalikan representasi neural dengan matriks bobot W agar dimensinya sesuai dengan dimensi *embedding* FM (Liu et al., 2023). Misalnya, proyektor mengubah representasi berdimensi 512 dari *encoder* Conformer menjadi 1280 untuk dimensi *embedding* salah satu varian Whisper. Hasil proyeksi ini disebut merupakan *memory* dari ECoG dan menjadi masukan bagi FM. Teknik ini efisien secara komputasi dan hanya menambah sedikit parameter untuk matriks.

2. LLaVA

Untuk FM teks *decoder-only* seperti Qwen3, adaptasi dilakukan dengan gaya LLaVA (Liu et al., 2023). Pada pendekatan ini, token *ECoG memory* hasil proyeksi dikonkatenasi di depan token teks, lalu seluruh urutan gabungan diproses bersama oleh dekoder. Dengan demikian, sinyal ECoG diperlakukan seolah-olah sebagai token bahasa tambahan yang mendahului teks. Pendekatan ini sederhana dan langsung memanfaatkan kemampuan *decoder-only* dalam memproses urutan token. Akan tetapi, terdapat risiko bahwa token teks dapat mengakses token teks sebelumnya secara langsung melalui *self-attention* sehingga model dapat memprediksi teks hanya dari teks sebelumnya tanpa benar-benar memanfaatkan sinyal ECoG. Risiko ini dikenal sebagai *text shortcut*.

3. *Cross-attention*

Untuk FM audio *encoder-decoder* seperti Whisper dan Cohere, ECoG *memory* dimanfaatkan sebagai sumber *cross-attention* pada dekoder FM (Alayrac et al., 2022). Di dalam setiap lapisan dekoder, token teks terlebih dahulu melewati *self-attention* yang hanya melihat token teks sebelumnya. Setelah itu, token teks mengakses ECoG *memory* melalui *cross-attention*. Pada mekanisme ini, token teks berperan sebagai *query*, sedangkan ECoG *memory* berperan sebagai *key* dan *value*. Rancangan ini memastikan sinyal ECoG tidak pernah berada di dalam jendela *self-attention* teks sehingga satu-satunya jalur dari sinyal ECoG menuju prediksi teks adalah *cross-attention*. Dengan demikian, pendekatan ini mengatasi *text shortcut* yang muncul pada pendekatan LLaVA.

II.5.3 *Parameter-Efficient Fine-Tuning (PEFT) dengan LoRA*

Setelah mekanisme adaptasi modalitas ditentukan, FM perlu disetel agar terbiasa memproses input ECoG. Proses *fine-tuning* dilakukan untuk mengadaptasi FM terhadap tugas baru. Mengingat besarnya jumlah parameter FM, pelatihan ulang seluruh parameter (*full fine-tuning*) sering kali tidak praktis. Pendekatan ini membutuhkan sumber daya komputasi yang sangat besar untuk menyimpan gradien seluruh parameter dan berisiko menyebabkan *catastrophic forgetting*,

yaitu hilangnya kemampuan linguistik generik model karena seluruh bobotnya dimodifikasi (Ding et al., 2023).

Untuk mengatasi keterbatasan tersebut, dikembangkan strategi *parameter-efficient fine-tuning* (PEFT) yang mengadaptasi model dengan hanya melatih sebagian kecil parameter. Salah satu metode PEFT yang paling banyak digunakan adalah Low-Rank Adaptation (LoRA) (Hu et al., 2021). Perbandingan ringkas antara *full fine-tuning* dan LoRA ditunjukkan pada Tabel II.4.

Tabel II.4 Perbandingan *full fine-tuning* dan LoRA

Aspek	<i>Full Fine-Tuning</i>	LoRA
Persentase parameter dilatih	100%	sekitar 0,1% hingga 1%
Kebutuhan memori	Sangat tinggi	Rendah
Risiko <i>catastrophic forgetting</i>	Tinggi	Rendah
Efektivitas adaptasi	Tinggi	Hampir setara <i>full fine-tuning</i>


LoRA bekerja dengan asumsi bahwa perubahan bobot yang diperlukan untuk adaptasi ke tugas baru memiliki *rank* yang rendah. Alih-alih memperbarui matriks bobot asli W_0 secara langsung, LoRA membekukan W_0 dan menambahkan perubahan bobot ΔW yang difaktorkan menjadi perkalian dua matriks beruang rendah (Hu et al., 2021). Hal ini dirumuskan sebagai berikut.

$$W = W_0 + \Delta W = W_0 + (\alpha / r) B A$$

Pada rumus tersebut, W_0 adalah matriks bobot asli yang dibekukan berdimensi $d \times k$, B adalah matriks berdimensi $d \times r$, A adalah matriks berdimensi $r \times k$, r adalah *rank* yang nilainya jauh lebih kecil daripada d dan k , dan α adalah faktor penskalaan. Karena hanya matriks A dan B yang dilatih, jumlah parameter yang diperbarui jauh lebih kecil daripada *full fine-tuning*. Setelah pelatihan, hasil $B * A$

dapat digabungkan kembali ke bobot asli sehingga LoRA tidak menambah latensi inferensi (Hu et al., 2021).

Struktur LoRA ditunjukkan pada Gambar II.5. Pada awal pelatihan, matriks B diinisialisasi nol dan matriks A diinisialisasi dengan nilai acak dari distribusi normal sehingga perubahan bobot $B * A$ bernilai nol. Setelah itu, A dan B secara perlahan menyesuaikan diri terhadap tugas baru. Pada saat inferensi, masukan x diproses oleh bobot asli W_0 sekaligus oleh jalur A dan B , lalu kedua keluaran dijumlahkan menjadi keluaran akhir h .



Gambar II.5 Struktur Low-Rank Adaptation (LoRA) (Hu et al., 2021)

II.6 Penelitian Terkait

Saat ini penelitian dalam sistem *neuroprosthesis* bicara telah mengalami perkembangan. Willett et al. (2023) telah mengimplementasi sistem *neuroprosthesis* bicara dua tahap dengan RNN sebagai modul decode fonem dan

model bahasa 5-gram. Sistem ini mampu mendapatkan WER sebesar 17.4% dan kecepatan 62 kata per menit. Setelah itu, Seto et al. (2025) mengembangkan sistem tersebut dengan fokus pada model bahasa. Dengan menggantikan model trigram dengan Transformer, khususnya LLaMA 2, ia berhasil menurunkan WER menjadi 16.9%. Namun, hingga saat ini, modul dekode fonem dalam sistem tersebut masih mengandalkan arsitektur berbasis RNN dan belum ada penelitian yang memanfaatkan model berbasis Transformer sebagai alternatifnya yang lebih mampu menangkap dependensi jangka panjang.

Dari sisi penggunaan Foundation Model, paradigma ini sebenarnya telah terbukti sangat sukses pada berbagai modalitas, seperti gambar, bahasa, dan suara. Akan tetapi, pemanfaatan FM dalam domain sinyal otak masih sangat terbatas. Sebagian besar riset terkait Foundation Model untuk BCI saat ini difokuskan pada sinyal EEG yang bersifat noninvasif. Selain itu, fokus penelitian tersebut umumnya tidak memanfaatkan FM berbasis teks untuk *downstream tasks*, tetapi membangun FM yang dilatih khusus dengan sinyal otak, seperti LaBraM dan CBraMod (Jiang et al., 2024; Wang et al., 2025). Oleh karena itu, penggunaan Foundation Model untuk mendekode kalimat dari sinyal ECoG secara *end-to-end* masih menjadi celah penelitian.

Berdasarkan penelitian terkait tersebut, terdapat dua celah utama yang diangkat dalam penelitian ini. Pertama, belum ada penggunaan arsitektur Transformer sebagai pengganti RNN untuk memetakan sinyal neural ECoG secara langsung menjadi probabilitas fonem. Kedua, belum ada sistem yang memanfaatkan Foundation Model untuk melakukan dekode kalimat dari sinyal ECoG secara *end-to-end*.

BAB III

ANALISIS MASALAH DAN RANCANGAN SOLUSI

Bab ini memaparkan analisis terhadap permasalahan yang muncul selama pengembangan sistem *neuroprosthesis* bicara pada tugas akhir ini beserta rancangan solusinya. Bagian III.1 menguraikan permasalahan yang dihadapi. Bagian III.2 memaparkan alternatif solusi untuk setiap permasalahan tersebut beserta pilihan yang diambil. Terakhir, bagian III.3 menjabarkan rancangan solusi secara detail untuk arsitektur dua tahap dan arsitektur *end-to-end* (E2E).

III.1 Analisis Masalah

Tugas akhir ini bertujuan membangun dan membandingkan sistem *neuroprosthesis* bicara dengan arsitektur dua tahap dan arsitektur E2E berbasis *Foundation Model* (FM). Agar tujuan tersebut tercapai, terdapat beberapa permasalahan dan ketidakpastian yang perlu ditangani. Permasalahan tersebut diuraikan sebagai berikut.

1. Pemilihan Varian Transformer

Arsitektur berbasis Transformer dapat diimplementasikan dengan banyak cara dan tiap pilihan memengaruhi kemampuan model menangkap pola pada sinyal ECoG. Terdapat dua aspek pilihan utama. Aspek pertama adalah varian arsitektur. Model dapat berupa Transformer murni, Conformer (yang menambahkan modul konvolusi untuk menangkap pola lokal pada sinyal akustik) (Gulati et al., 2020), atau Conformer yang dilengkapi *spatial attention* untuk menangkap dependensi antarelektroda. Aspek kedua adalah hiperparameter, seperti ukuran model (dimensi *hidden*, jumlah lapisan, jumlah *head*, dan dimensi lapisan *feed-forward*), nilai *dropout*, serta ukuran *kernel* konvolusi. Kombinasi varian dan hiperparameter yang paling tepat untuk dekode fonem dari sinyal ECoG belum diketahui di awal dan harus ditemukan melalui eksperimen.

2. Pemilihan Arsitektur Foundation Model

Terdapat banyak FM dengan karakteristik berbeda. Dari sisi arsitektur, FM dapat berupa *decoder-only*, *encoder-only*, atau *encoder-decoder*. Dari sisi modalitas pelatihan, FM dapat dilatih pada teks, audio, atau keduanya. FM juga berbeda dalam ukuran parameter dan kemampuan pemrosesan linguistik. Permasalahan utamanya adalah menentukan FM yang tidak hanya akurat dalam mendekode kalimat, tetapi juga memproses sinyal dalam waktu yang wajar.

3. Adaptasi Model terhadap Jenis Input Baru

FM saat ini dapat memproses berbagai modalitas, seperti teks, audio, dan gambar. Akan tetapi, FM belum mendukung sinyal ECoG sebagai input. Oleh karena itu, terdapat dua keputusan yang perlu diambil. Keputusan pertama adalah cara mengubah sinyal ECoG menjadi bentuk yang dapat diterima FM. Keputusan kedua adalah cara melatih FM agar terbiasa memproses input ECoG secara efisien tanpa harus melatih ulang seluruh parameternya.

4. Latensi Inferensi dan Beban Komputasi

Idealnya, sistem *neuroprosthesis* bicara mampu bekerja secara *real-time* agar komunikasi terasa alami. Namun, FM memiliki ukuran yang besar sehingga menimbulkan beban komputasi yang tinggi, baik dari sisi latensi inferensi maupun kebutuhan memori dan penyimpanan. Oleh karena itu, dari sisi waktu inferensi dan kebutuhan penyimpanan, sistem yang dibangun pada tugas akhir ini perlu melampaui atau setidaknya kompetitif dengan sistem milik Willett et al. (2023).


III.2 Analisis Solusi

Bagian ini memaparkan solusi untuk setiap permasalahan pada bagian III.1.

1. Pemilihan Varian Transformer

Solusi yang diambil adalah bereksperimen dengan tiga varian, yaitu Transformer murni, Conformer, dan Conformer dengan *spatial attention*.

Transformer murni dipilih sebagai dasar karena mekanisme *self-attention*-nya mampu menangkap dependensi jangka panjang pada keseluruhan input secara langsung (Vaswani et al., 2017). Conformer dipilih karena menambahkan modul konvolusi yang menangkap pola lokal sehingga lebih sesuai untuk sinyal deret waktu seperti ucapan (Gulati et al., 2020). Conformer dengan *spatial attention* dipilih karena menambahkan *attention* pada dimensi elektroda sehingga model dapat menangkap dependensi antarelektroda pada sinyal ECoG yang terdiri dari banyak kanal. Perbandingan susunan blok ketiga varian ditunjukkan pada Gambar III.1. Untuk setiap varian, pelatihan dimulai dengan hiperparameter asli dari paper masing-masing varian, kemudian dilakukan penyetelan hiperparameter (*hyperparameter tuning*) sepanjang penelitian. Hiperparameter yang disetel meliputi dimensi *hidden* model, jumlah lapisan, jumlah *attention head*, dimensi lapisan *feed-forward*, *learning rate*, serta jadwal *learning rate decay*



* hiperparameter yang disetel: jumlah head (MHSA), dimensi feed-forward, jumlah lapisan. Selain itu, d_{model} (seluruh blok), learning rate, dan jadwal peluruhannya juga disetel.

Gambar III.1 Perbandingan susunan blok Transformer, Conformer, dan Conformer dengan *spatial attention*

2. Pemilihan Arsitektur Foundation Model

Solusi yang diambil adalah bereksperimen dengan beragam FM yang berbeda dari sisi arsitektur, modalitas pelatihan, dan ukuran. Daftar FM yang digunakan beserta karakteristiknya ditunjukkan pada Tabel III.1.

Tabel III.1 Daftar Foundation Model yang digunakan beserta karakteristiknya

Model	Penyedia	Modalitas Pelatihan	Mekanisme Adaptasi Modalitas
Qwen3.5-0.8B-Base	Alibaba	Teks	Proyeksi dan konkatenasi (LLaVA)
Whisper-medium.en	OpenAI	Audio	<i>Cross-attention</i>
Whisper-large-v3	OpenAI	Audio	<i>Cross-attention</i>
Cohere Transcribe	Cohere	Audio	<i>Cross-attention</i>
Canary-Qwen-2.5B	NVIDIA	Audio dan teks	Proyeksi dan konkatenasi (LLaVA)
Granite-Speech-4.1-2B	IBM	Audio dan teks	Proyeksi dan konkatenasi (LLaVA)

Kelompok model ini sengaja dipilih untuk mencakup variasi yang luas. Variasi tersebut meliputi arsitektur (LLM teks *decoder-only* atau *encoder-decoder* audio), modalitas pelatihan (teks murni, audio, atau keduanya), ukuran (dari sekitar 769 juta hingga 2,5 miliar parameter), serta mekanisme adaptasi modalitas (konkatenasi gaya LLaVA atau *cross-attention*). Dengan keragaman ini, perbandingan dapat menjawab pendekatan mana yang paling cocok untuk sinyal ECoG. Whisper dan Cohere dimanfaatkan sebagai model *encoder-decoder* audio melalui *cross-attention*, sedangkan Canary-Qwen dan Granite-Speech dimanfaatkan dengan menggunakan ulang model bahasa teks di dalamnya melalui LLaVA. Untuk Canary-Qwen, komponen yang digunakan ulang adalah model bahasa Qwen3-1.7B beserta proyektor dan *adapter* LoRA yang telah dilatih untuk penyelarasan ucapan. Untuk Granite-Speech, komponen yang digunakan hanyalah model bahasa teksnya, sedangkan *encoder* audio bawaannya tidak dipakai. Alasan lain pemilihan

Canary-Qwen dan Granite-Speech adalah keduanya merupakan model bahasa yang telah terbukti berfungsi dalam sistem ASR berkinerja tinggi. Keberhasilan adaptasi tersebut menunjukkan keluarga model bahasa ini cocok untuk memetakan ucapan menjadi teks sehingga berpotensi untuk memetakan sinyal ECoG menjadi teks secara baik.

3. Adaptasi Model terhadap Jenis Input Baru

Untuk adaptasi modalitas, digunakan dua metode sesuai jenis FM. Untuk model bahasa teks *decoder-only* (Qwen, serta model bahasa dari Canary-Qwen dan Granite-Speech), digunakan proyeksi fitur yang diikuti konkatenasi token dengan gaya *LLaVA* (Liu et al., 2023). Untuk model audio *encoder-decoder* (Whisper dan Cohere), digunakan proyeksi fitur yang diikuti *cross-attention*. Pendekatan *cross-attention* dipilih untuk kasus ini agar sinyal ECoG hanya masuk melalui jalur *cross-attention* dan tidak melalui jalur *self-attention* teks. Hal ini menghindari permasalahan model belajar memprediksi teks dari teks sebelumnya tanpa benar-benar memanfaatkan sinyal ECoG. Untuk *fine-tuning*, dipilih LoRA karena mampu mengadaptasi model besar secara efektif dengan hanya melatih sebagian kecil parameter dan tanpa menambah latensi inferensi (Hu et al., 2021).

4. Latensi Inferensi dan Beban Komputasi

Pada tugas akhir ini, pertimbangan kecepatan dan beban komputasi dimasukkan ke dalam tahap pemilihan model, yaitu dengan memilih arsitektur yang ukuran parameternya tidak terlalu besar agar latensi inferensi dan kebutuhan memori tetap wajar. Selanjutnya, latensi inferensi dan beban penyimpanan sistem yang dibangun diukur secara empiris melalui metrik RTF dan kata per menit, lalu dibandingkan dengan *baseline* Willett et al. (2023) pada lingkungan komputasi yang sama agar perbandingannya adil.


III.3 Rancangan Solusi

Bagian ini menjabarkan rancangan solusi secara detail. Bagian III.3.1 menjelaskan praproses dan ekstraksi fitur yang sama untuk kedua arsitektur. Bagian III.3.2

menjelaskan rancangan arsitektur dua tahap, sedangkan bagian III.3.3 menjelaskan rancangan arsitektur E2E.

III.3.1 Praproses dan Ekstraksi Fitur

Arsitektur dua tahap dan arsitektur E2E menerima input fitur neural yang diproses dengan cara yang sama sehingga praproses dan ekstraksi fiturnya dijelaskan satu kali pada bagian ini. Alur praproses ditunjukkan pada Gambar III.2.




Gambar III.2 Alur praproses dan ekstraksi fitur dari sinyal ECoG mentah menjadi matriks fitur ternormalisasi.

Dataset Willett et al. (2023) terdiri atas 24 sesi perekaman dari satu partisipan (T12) yang dikumpulkan selama beberapa bulan. Untuk setiap rentang waktu

(*bin*) selebar 20 milidetik, dataset menyediakan dua jenis fitur per kanal elektroda, yaitu *threshold crossings* dan *spike band power*. Fitur *threshold crossings* menghitung berapa kali sinyal melintasi suatu ambang batas, sedangkan *spike band power* merepresentasikan daya aktivitas *spiking* lokal (Willett et al., 2023). Fitur dari 128 kanal elektroda kemudian digabungkan sehingga setiap *bin* direpresentasikan oleh vektor berdimensi 256, yaitu 128 nilai *threshold crossings* dan 128 nilai *spike band power*. Seluruh *bin* dalam satu ujaran membentuk matriks fitur berukuran $T \times 256$ dengan T sebagai jumlah *bin* waktu. Matriks tersebut kemudian dinormalisasi dengan *z-score* per sesi untuk mengatasi variasi statistik sinyal antarsesi perekaman. Pada tahap pelatihan, diterapkan pula *gaussian smoothing* pada dimensi waktu serta augmentasi data berupa penambahan *white noise* dan *constant offset* untuk meningkatkan ketahanan model terhadap variasi sinyal.

III.3.2 Rancangan Solusi Dua Tahap

Arsitektur dua tahap memetakan fitur neural menjadi teks melalui representasi fonem perantara. Alur lengkapnya ditunjukkan pada Gambar III.3. Tahap pertama adalah model akustik yang memetakan fitur neural menjadi probabilitas fonem. Tahap kedua adalah model bahasa yang mengubah probabilitas fonem menjadi teks koheren. Rancangan tiap komponen dijelaskan pada subbagian berikut.



Gambar III.3 Alur arsitektur dua tahap dari fitur neural hingga teks akhir.

1. Dekoder Fonem

Dekoder fonem bertugas memetakan matriks fitur neural menjadi matriks probabilitas fonem. Modul ini dapat diisi oleh salah satu varian model berbasis Transformer yang telah dijelaskan pada bagian III.2, yaitu Transformer murni, Conformer, atau Conformer dengan *spatial attention*. Apa pun varian yang dipilih, dekoder menerima matriks fitur berukuran $T \times 256$ dan menghasilkan distribusi probabilitas fonem untuk setiap *bin* waktu. Keluaran dekoder berupa

distribusi atas 40 kelas, yaitu 39 fonem dan satu token jeda, ditambah satu token kosong (*blank*) yang dibutuhkan oleh fungsi *loss* CTC.

Khusus untuk varian Conformer dengan *spatial attention*, modul *spatial attention* bekerja pada masukan mentah 256 kanal sebelum *subsampling* sehingga identitas tiap elektroda masih utuh. Modul ini meringkas tiap kanal elektroda menjadi satu nilai melalui rata-rata terhadap waktu, memproyeksikannya ke representasi berdimensi 64 yang ditambah *embedding* identitas tiap elektroda, lalu menjalankan *self-attention* antarelektroda dengan 4 *head*. Keluaran modul berupa gerbang bernilai 0 sampai 1 untuk tiap kanal yang menimbang ulang 256 kanal masukan. Mekanisme ini membuat model dapat menekankan elektroda yang paling informatif sebelum pemrosesan oleh blok Conformer.

2. Pelatihan Model

Dekoder fonem dilatih dengan fungsi *loss connectionist temporal classification* (CTC) yang memungkinkan pelatihan pada pasangan sekuens yang belum diselaraskan (*unaligned*) (Graves et al., 2006). Pelatihan menggunakan optimizer Adam dengan *epsilon* sebesar 0,1 dan *gradient clipping* sebesar 10. Ukuran *batch* yang digunakan adalah 32. Laju pembelajaran (*learning rate*) mengikuti jadwal *cosine* dengan nilai awal 0,04 yang meluruh hingga 0,004 dan didahului 1000 langkah *warmup*. Untuk menghemat penggunaan memori, pelatihan dilakukan dengan presisi campuran (*mixed precision*). Pelatihan dijalankan hingga 150000 langkah dengan validasi setiap 500 langkah dan *early stopping* berdasarkan *phoneme error rate* (PER) validasi. *Early stopping* dipicu jika PER validasi tidak membaik melebihi 0,0001 selama 50 siklus validasi berturut-turut. Bobot model dengan PER validasi terendah disimpan sebagai hasil akhir.

3. Model Bahasa

Setelah probabilitas fonem dihasilkan, tahap kedua mengubahnya menjadi teks melalui dua langkah. Langkah pertama adalah dekode dengan model

bahasa 5-gram yang direpresentasikan dalam bentuk *weighted finite-state transducer* (WFST). Dekode dilakukan dengan algoritma *beam search* yang menggabungkan skor akustik dari probabilitas fonem dan skor linguistik dari model 5-gram melalui *shallow fusion* (Metzger et al., 2023). Langkah ini menghasilkan daftar *n-best*, yaitu sejumlah hipotesis kalimat yang paling memungkinkan. Langkah kedua adalah *rescoring* daftar *n-best* tersebut dengan model bahasa neural LLaMA-2 7B (Touvron et al., 2023). Skor akhir setiap hipotesis dihitung dari kombinasi berbobot antara skor akustik, skor model bahasa neural, dan bonus penyisipan kata. Bobot kombinasi dicari melalui *grid search*, yaitu mencoba berbagai kombinasi nilai untuk skala akustik (*acoustic scale*), bobot model bahasa, dan bonus penyisipan kata, lalu memilih kombinasi yang memberikan kesalahan terendah pada data validasi.

III.3.3 Rancangan Solusi End-to-End


Arsitektur E2E memetakan sinyal ECoG langsung menjadi teks tanpa representasi fonem perantara. Rancangannya dijelaskan melalui dua bagian, yaitu penyiapan arsitektur dan pelatihannya.

1. Arsitektur *End-to-End*

Arsitektur E2E terdiri atas tiga komponen utama, yaitu *encoder*, proyektor, dan dekoder FM. Sinyal ECoG berukuran 256 kanal terlebih dahulu diproses oleh *encoder* Conformer yang berarsitektur sama dengan dekoder fonem pada arsitektur dua tahap, yaitu Conformer dengan *spatial attention* berdimensi 512 yang melakukan *subsampling* sekitar empat kali pada dimensi waktu. Keluaran *encoder* kemudian dipetakan oleh proyektor berupa lapisan *linear* yang diikuti *layer normalization*. Proyektor ini mengubah dimensi keluaran *encoder* dari 512 menjadi dimensi *hidden* FM, misalnya 1280 untuk Whisper-large-v3. Hasil proyeksi ini disebut *ECoG memory*.

Cara integrasi *ECoG memory* dengan dekoder FM bergantung pada jenis FM. Untuk FM teks *decoder-only* seperti Qwen, adaptasi dilakukan dengan gaya *LLaVA* seperti pada Gambar III.4. Token *ECoG memory* dikonkatenasi di


depan token teks, lalu seluruh urutan gabungan diproses bersama oleh dekoder. Kekurangan pendekatan ini adalah token teks dapat mengakses token teks sebelumnya secara langsung melalui *self-attention* sehingga model berisiko memprediksi teks hanya dari teks sebelumnya tanpa benar-benar memanfaatkan sinyal ECoG. Risiko ini dikenal sebagai *text shortcut*.



Gambar III.4 Alur arsitektur *end-to-end* gaya LLaVA untuk *Foundation Model* teks *decoder-only*.

Untuk FM audio *encoder-decoder* seperti Whisper dan Cohere, *ECoG memory* dimanfaatkan sebagai sumber *cross-attention* pada dekoder FM seperti pada

Gambar III.5. Di dalam setiap lapisan dekoder, token teks pertama-tama melalui *self-attention* kausal yang hanya melihat token teks sebelumnya. Setelah itu, token teks mengakses *ECoG memory* melalui *cross-attention*. Pada mekanisme ini, token teks berperan sebagai *query* dan *ECoG memory* berperan sebagai *key* dan *value*. Rancangan ini memastikan sinyal ECoG tidak pernah berada di dalam jendela *self-attention* teks sehingga satu-satunya jalur dari sinyal ECoG menuju prediksi teks adalah *cross-attention*. Dengan demikian, pendekatan ini mengatasi *text shortcut* yang muncul pada pendekatan LLaVA. Pada kedua pendekatan, dekoder FM diadaptasi dengan LoRA agar dapat memproses input ECoG tanpa menambah latensi inferensi.



Gambar III.5 Alur arsitektur *end-to-end* yang memanfaatkan *Foundation Model* audio melalui *cross-attention*.

2. Pelatihan

Komponen *encoder* Conformer terlebih dahulu dilatih secara tersendiri dengan CTC sebelum dipakai pada arsitektur E2E. Pada tahap ini, *encoder* dilengkapi satu lapisan keluaran linier yang memetakan representasi *encoder* menjadi probabilitas karakter, lalu dilatih dengan fungsi *loss* CTC (Graves et al., 2006) untuk memprediksi karakter teks langsung dari sinyal ECoG. Pelatihan menggunakan optimizer AdamW dengan laju pembelajaran 1×10^{-3} yang mengikuti jadwal *cosine* beserta *warmup*, *weight decay* sebesar 0,01, dan ukuran *batch* 16. Tahap ini menghasilkan *encoder* yang sudah mampu mengekstraksi representasi bermakna dari sinyal ECoG dan dipakai sebagai inisialisasi *encoder* pada arsitektur E2E.

Pelatihan arsitektur E2E menggunakan fungsi *loss cross-entropy* yang hanya dihitung pada posisi token teks, sedangkan posisi *prefix* diabaikan. Pelatihan dilakukan pada 24 sesi perekaman dengan 8800 data latih dan 880 data uji. *Encoder* diinisialisasi dari hasil pelatihan CTC tersebut sehingga tidak dilatih dari nol. Setelah inisialisasi tersebut, *encoder* dan proyektor tidak dibekukan, tetapi dilatih sepenuhnya bersama dekoder selama pelatihan E2E. Seluruh parameter *encoder* dan proyektor diperbarui, sedangkan dekoder FM hanya di-*finetune* melalui LoRA. Karena *encoder* sudah memiliki bobot terlatih dari tahap CTC, laju pembelajarannya dibuat jauh lebih kecil daripada proyektor agar bobot yang sudah baik tidak rusak. Adaptasi LoRA diterapkan pada modul *attention* (*query*, *key*, *value*, dan proyeksi keluaran), modul *cross-attention*, serta lapisan *feed-forward* decoder. Nilai *rank* yang digunakan adalah 16, *alpha* sebesar 32, dan *dropout* sebesar 0,1. Pelatihan dijalankan hingga 15000 langkah dengan ukuran *batch* efektif 16, 500 langkah *warmup*, dan presisi campuran. Laju pembelajaran mengikuti jadwal *cosine* dengan nilai puncak yang berbeda untuk tiap kelompok parameter, yaitu $6,9 \times 10^{-5}$

untuk *encoder*, $1,0 \times 10^{-3}$ untuk proyektor dan *cross-attention*, serta $1,75 \times 10^{-4}$ untuk LoRA. Pada saat inferensi, teks dibangkitkan secara autoregresif.

BAB IV

EVALUASI

Bab ini menjelaskan prosedur yang dijalankan untuk mengevaluasi solusi yang dirancang pada Bab III beserta hasil dan pembahasannya. Bagian IV.1 memaparkan lingkungan pengembangan tempat seluruh eksperimen dijalankan. Bagian IV.2 menjabarkan desain eksperimen yang dilakukan. Bagian IV.3 memaparkan hasil setiap eksperimen. Terakhir, bagian IV.4 membahas dan menganalisis hasil tersebut.

IV.1 Lingkungan Pengembangan

Seluruh proses pelatihan dan evaluasi model dijalankan pada GPU *cloud* yang disewa melalui layanan RunPod. GPU yang dipilih adalah NVIDIA GeForce RTX 4090. Pilihan ini didasari oleh ketersediaan, biaya sewa yang wajar, serta kapasitas memori 24 GB yang mencukupi untuk melatih *Foundation Model* berukuran besar dengan teknik LoRA. Spesifikasi lengkap lingkungan pengembangan ditunjukkan pada Tabel IV.1.

Tabel IV.1 Spesifikasi lingkungan pengembangan

Komponen	Spesifikasi
Prosesor	16 vCPU (host AMD EPYC)
RAM	62 GB
GPU	NVIDIA GeForce RTX 4090, 24 GB GDDR6X, arsitektur Ada Lovelace, 16.384 CUDA core
Penyimpanan	200 GB
Sistem Operasi	Ubuntu 22.04 LTS
Lingkungan virtual	Python venv berisi PyTorch (CUDA 12) dan TensorFlow 2.15

Lingkungan virtual (*virtual environment*) dibagi sesuai kebutuhan tiap jalur. Jalur *end-to-end* (E2E) dan *rescoring* model bahasa neural menggunakan PyTorch beserta pustaka transformers dan peft. Sementara itu, dekoder fonem dan dekode WFST pada arsitektur dua tahap menggunakan TensorFlow. Metrik kesalahan dihitung dengan pustaka jiwer.

IV.2 Desain Eksperimen

Terdapat dua eksperimen yang dilakukan pada tugas akhir ini. Eksperimen pertama menguji kinerja dekoder fonem sebagai tahap pertama arsitektur dua tahap. Eksperimen kedua membandingkan kinerja arsitektur secara utuh, baik arsitektur dua tahap maupun arsitektur E2E, dari sisi akurasi dan efisiensi.

IV.2.1 Eksperimen Dekode Fonem

Eksperimen ini bertujuan membandingkan kinerja empat dekoder fonem dalam memetakan fitur neural menjadi probabilitas fonem. Keempat dekoder tersebut adalah GRU sebagai *baseline*, Transformer murni, Conformer murni, dan Conformer dengan *spatial attention*. GRU dipilih sebagai *baseline* karena merupakan dekoder yang digunakan oleh Willett et al. (2023). Transformer murni, Conformer murni, dan Conformer dengan *spatial attention* dipilih untuk menguji apakah arsitektur berbasis Transformer dapat melampaui *baseline* tersebut. Metrik yang digunakan adalah *phoneme error rate* (PER).

Setiap dekoder memiliki hiperparameter spesifik sebagai berikut.

1. GRU

Model terdiri atas 5 lapisan GRU searah dengan 1024 unit per lapisan dan berjumlah sekitar 53,6 juta parameter. Fitur masukan terlebih dahulu melewati lapisan input berdimensi 256 dengan fungsi aktivasi *softsign* dan *dropout* sebesar 0,4. Masukan juga ditumpuk pada dimensi waktu untuk melakukan *subsampling* dengan faktor empat sebelum diproses lapisan GRU.

2. Transformer murni

Model memiliki dimensi *hidden* 512, 4 lapisan, 8 *attention head*, dimensi lapisan *feed-forward* 2048, dan *dropout* sebesar 0,1. Informasi posisi dibubuhkan dengan *positional encoding* sinusoidal. Berbeda dengan dekoder lain, Transformer murni dilatih dengan *learning rate* yang lebih kecil, yaitu 0,015, untuk menjaga kestabilan pelatihan.

3. Conformer murni

Model memiliki dimensi *hidden* 512, 4 lapisan, 8 *attention head*, dimensi lapisan *feed-forward* 2048, *kernel* konvolusi berukuran 31, dan *dropout* sebesar 0,1. Informasi posisi disandikan dengan *positional encoding* sinusoidal.

4. Conformer dengan *spatial attention*

Model memiliki konfigurasi yang sama dengan Conformer vanilla, tetapi ditambah modul *spatial attention* pada dimensi elektroda dengan dimensi representasi internal 64 dan 4 *head*. Mekanisme modul ini dijelaskan pada Bab III bagian III.3.2.

Keempat dekoder dilatih dengan fungsi *loss* CTC, *optimizer* Adam, dan ukuran *batch* 32. Laju pembelajaran mengikuti jadwal *cosine* dengan *warmup* seperti yang dijelaskan pada Bab III. Pelatihan menggunakan *early stopping* berdasarkan PER validasi, dan bobot model dengan PER validasi terendah disimpan sebagai hasil akhir.

IV.2.2 Eksperimen Evaluasi Arsitektur

Eksperimen ini bertujuan membandingkan kinerja arsitektur secara utuh dari sisi akurasi dan efisiensi. Akurasi diukur dengan WER dan CER, sedangkan efisiensi diukur dengan ukuran penyimpanan, RTF, dan WPM. Arsitektur yang dibandingkan adalah arsitektur dua tahap dan arsitektur E2E dengan berbagai *Foundation Model* yang telah dijelaskan pada Bab III. Daftar arsitektur yang dievaluasi adalah sebagai berikut.

1. Dua tahap (GRU + 5-gram)

2. Dua tahap (Transformer + 5-gram)
3. Dua tahap (Conformer + 5-gram)
4. Dua tahap (GRU + 5-gram + LLaMA-2 7B)
5. Dua tahap (Conformer + 5-gram + LLaMA-2 7B)
6. E2E Qwen (LLaVA)
7. E2E Whisper-medium.en (*cross-attention*)
8. E2E Whisper-large-v3 (*cross-attention*)
9. E2E Cohere Transcribe (*cross-attention*)
10. E2E Canary-Qwen (LLaVA)
11. E2E Granite-Speech (LLaVA)

WER dan CER dihitung pada tingkat korpus, yaitu jumlah seluruh kesalahan dibagi jumlah seluruh kata atau karakter pada data uji. Sama seperti eksperimen dekode fonem, akurasi dilaporkan pada data uji dengan sesi perekaman yang sebanding dengan laporan Willett et al. (2023).

IV.3 Hasil Eksperimen

Berikut merupakan hasil dari eksperimen yang telah dijalankan.

IV.3.1 Hasil Dekode Fonem

Hasil PER keempat dekoder fonem ditunjukkan pada Tabel IV.2. Conformer dengan *spatial attention* mencapai PER terendah, yaitu 0,1428. Conformer vanilla menempati posisi kedua. GRU *baseline* berada di atas kedua varian Conformer tersebut, sedangkan Transformer murni memiliki PER tertinggi.

Tabel IV.2 Hasil PER empat dekoder fonem.

Dekoder Fonem	PER
GRU 1024 unit 5 lapisan	0,1597
Transformer murni	0,2444
Conformer vanilla	0,1477

Conformer + <i>spatial attention</i>	0,1428
---	---------------

Hasil ini menunjukkan kedua varian Conformer mengungguli GRU *baseline*, sedangkan Transformer murni justru berada di bawah GRU. Hal ini menunjukkan mekanisme *self-attention* murni belum cukup untuk dekode fonem dari sinyal ECoG dan modul konvolusi pada Conformer berperan penting dalam menangkap pola lokal sinyal. Conformer dengan *spatial attention* juga mengungguli dekoder fonem GRU pada penelitian Seto (2025) yang memiliki PER sekitar 0,192. Dengan demikian, dekoder fonem berbasis Conformer terbukti lebih baik dalam memetakan fitur neural menjadi probabilitas fonem.

IV.3.2 Hasil Evaluasi Arsitektur

Hasil akurasi setiap arsitektur ditunjukkan pada Tabel IV.3. Arsitektur dua tahap dengan *rescoring* LLaMA-2 7B mencapai WER terendah, yaitu 0,1556. Di antara arsitektur E2E, Whisper-large-v3 mencapai akurasi tertinggi dengan WER 0,1716.

Tabel IV.3 Hasil WER dan CER setiap arsitektur.

Arsitektur	WER	CER
Dua tahap (GRU + 5-gram)	0,1828	0,1327
Dua tahap (Transformer + 5-gram)	0,2927	0,2094
Dua tahap (Conformer + 5-gram)	0,1858	0,1253
Dua tahap (GRU + 5-gram + LLaMA-2 7B)	0,1638	0,1194
Dua tahap (Conformer + 5-gram + LLaMA-2 7B)	0,1556	0,1127
E2E Qwen (gaya <i>LLaVA</i>)	0,2537	0,2413
E2E Whisper-medium.en	0,1760	0,1508

E2E Whisper-large-v3	0,1716	0,1428
E2E Cohere Transcribe	0,1776	0,1523
E2E Canary-Qwen	0,2384	0,2115
E2E Granite-Speech	0,2337	0,2097

Hasil efisiensi setiap arsitektur ditunjukkan pada Tabel IV.4. Seluruh arsitektur, baik dua tahap maupun E2E, memiliki RTF jauh di bawah satu sehingga semuanya mampu bekerja lebih cepat daripada durasi ucapan aslinya. Dari sisi penyimpanan, arsitektur E2E jauh lebih ringan, yaitu 2,0 hingga 9,9 GB, dibandingkan arsitektur dua tahap yang mencapai 44,2 hingga 57,8 GB.

Tabel IV.4 Jumlah parameter, ukuran penyimpanan, dan kecepatan untuk masing-masing arsitektur.

Arsitektur	Total Parameter (komponen terbesar)	Penyimpanan Total (komponen terbesar)	RTF	WPM
Dua tahap (GRU + 5-gram)	53,6 juta (GRU fonem 53,55 juta)	44,3 GB (TLG.fst 44,1 GB)	0,0155	4.556
Dua tahap (Transformer + 5-gram)	16,8 juta	44,2 GB (TLG.fst 44,1 GB)	0,0044	6.573
Dua tahap (Conformer + 5-gram)	28,5 juta (Conformer fonem 28,49 juta)	44,2 GB (TLG.fst 44,1 GB)	0,0069	10.307
Dua tahap (GRU + 5-gram +	6,79 miliar (LLaMA-2 6,74 miliar)	57,8 GB (TLG.fst 44,1 GB)	0,0756	935

LLaMA-2 7B)				
Dua tahap (Conformer + 5-gram + LLaMA-2 7B)	6,77 miliar (LLaMA-2 6,74 miliar)	57,7 GB (TLG.fst 44,1 GB)	0,0430	1.650
E2E Qwen (<i>LLaVA</i>)	~0,86 miliar (FM 0,8 miliar)	2,1 GB (FM 1,77 GB)	0,0710	895
E2E Whisper-med ium.en	~0,80 miliar (FM 769 juta)	2,0 GB (FM 1,54 GB)	0,0455	1.394
E2E Whisper-larg e-v3	~1,57 miliar (FM 1,54 miliar)	3,6 GB (FM 3,09 GB)	0,0742	857
E2E Cohere Transcribe	~2,0 miliar (FM ~2 miliar)	4,5 GB (FM 4,13 GB)	0,0206	3.091
E2E Canary-Qwe n	~4,2 miliar (encoder Canary 2,5 miliar)	9,9 GB (encoder Canary 5,12 GB)	0,3207	503
E2E Granite-Spee ch	~2,0 miliar (FM ~2 miliar)	5,3 GB (FM 4,87 GB)	0,0672	943

Nilai RTF pada Tabel IV.4 adalah perbandingan waktu dekode terhadap durasi sinyal otak, sedangkan WPM adalah jumlah kata yang dihasilkan per menit (*wall-clock*) sebagai ukuran kecepatan *output*. RTF dan WPM tidak menghitung waktu muat model. Pada model 5-gram, berkas TLG.fst tidak memiliki parameter

terlatih (non-parametrik), tetapi tetap memakan sebagian besar penyimpanan sebesar 44,1 GB.

IV.4 Analisis

Bagian ini memaparkan analisis lanjutan terhadap hasil eksperimen utama untuk memahami pola, kesalahan, dan keterbatasan kedua arsitektur.

IV.4.1 Perbedaan Distribusi Probabilitas Fonem pada Dekoder 5-gram

Berdasarkan Tabel IV.2 dan Tabel IV.3, terdapat pola yang tidak intuitif pada hubungan antara PER dekode fonem dan WER arsitektur dua tahap. Conformer dengan *spatial attention* memiliki PER sebesar 0,1428. Nilai PER ini lebih baik daripada GRU sebesar 0,1597. Akan tetapi, untuk variasi dekode 5-gram tanpa *rescoring*, dekode GRU justru menghasilkan WER sebesar 0,1828 yang sedikit lebih rendah daripada Conformer (0,1858). Salah satu hipotesis untuk menjelaskan pola ini adalah ketajaman distribusi probabilitas fonem antarvarian dekode yang berbeda mempengaruhi proses *beam search* WFST. Distribusi yang lebih tajam memangkas jalur secara lebih agresif sehingga berpotensi membuang jalur yang sebenarnya benar.

Untuk menguji hipotesis ini, dihitung entropi rata-rata distribusi probabilitas fonem per *frame* logit dari keluaran dekode Conformer dengan *spatial attention* dan GRU. Hasilnya, Conformer memiliki entropi 0,0950 nats, sedangkan GRU memiliki entropi 0,1448 nats. Distribusi Conformer sekitar 34% lebih tajam daripada GRU.

Untuk mengonfirmasi mekanismenya secara lebih langsung, dihitung pula *coverage* dan WER *oracle* dari daftar *n-best* WFST 5-gram kedua dekode pada pengaturan dekode yang sama dengan Tabel IV.3. Nilai *coverage* adalah fraksi ujaran yang transkrip referensinya muncul persis di dalam daftar *n* hipotesis terbaik. WER *oracle* adalah WER terendah yang dapat dicapai jika selalu dipilih hipotesis terbaik dari daftar tersebut. Hasilnya ditunjukkan pada Tabel IV.5.


Tabel IV.5 *Coverage*, WER *oracle*, dan ukuran rata-rata *n-best* dari *beam search* 5-gram untuk kedua dekoder pada data uji.

Dekoder	<i>Coverage</i>	<i>Oracle</i> WER	Rata-rata ukuran <i>n-best</i>
Conformer + <i>spatial attention</i>	58,0%	0,1018	32,6
GRU	68,3%	0,0796	48,3

Daftar *n-best* Conformer memiliki *coverage* yang lebih rendah, WER *oracle* yang lebih tinggi, dan rata-rata jumlah hipotesis yang lebih sedikit daripada GRU, meskipun batas maksimum *n-best*-nya sama. Dapat diartikan bahwa *beam search* Conformer memang memangkas hipotesis lebih agresif sehingga jalur yang sebenarnya benar lebih sering hilang dari *beam* sebelum tahap *rescoring* dilakukan.

IV.4.2 Pengaruh Panjang Ujaran terhadap WER

Ujaran uji dibagi berdasarkan panjang transkrip referensi dalam jumlah kata, lalu WER dihitung per panjang transkrip untuk kedua arsitektur. Hasilnya ditunjukkan pada Gambar IV.1.



Gambar IV.1 WER setiap arsitektur untuk panjang ujaran referensi pada data uji WER kedua arsitektur cenderung menurun seiring panjang ujaran yang lebih panjang. Untuk ujaran terpendek (2-3 kata, $n=61$), dua tahap mencapai WER 0,3653 dan E2E mencapai WER 0,3533. WER kedua arsitektur kemudian menurun menjadi sekitar 0,14 untuk panjang 10 kata ke atas. E2E memiliki WER yang lebih rendah pada hampir seluruh panjang kata, kecuali pada panjang 5 kata yang dimenangkan dua tahap dengan WER 0,1750 dibandingkan E2E (WER 0,2006).

IV.4.3 Perbandingan Kesalahan E2E dan Dua Tahap

Analisis ini dilakukan untuk melihat perbedaan kesalahan yang dibuat masing-masing arsitektur. Setiap ujaran uji diklasifikasikan berdasarkan apakah E2E Whisper-large-v3 dan dua tahap (Conformer + 5-gram) menghasilkan transkripsi yang benar (WER=0) atau salah. Hasilnya ditunjukkan pada Tabel IV.6.

Tabel IV.6 Tabel kebenaran E2E dan dua tahap

	Dua tahap benar	Dua tahap salah
E2E benar	175 (29,2%)	71 (11,8%)
E2E salah	66 (11,0%)	288 (48,0%)

Sebanyak 22,8% ujaran benar pada satu arsitektur tetapi salah pada arsitektur yang lain. Untuk mengukur potensi maksimum gabungan kedua arsitektur, dihitung pula *best-of-two* WER, yaitu WER yang diperoleh jika untuk setiap ujaran dipilih arsitektur dengan WER lebih rendah. Hasilnya adalah WER sebesar 0,1249. Nilai ini jauh di bawah WER masing-masing arsitektur tunggal, yaitu 0,1716 untuk E2E Whisper-large-v3 dan 0,1858 untuk dua tahap (Conformer + 5-gram).

IV.5 Pembahasan

Di antara seluruh arsitektur, E2E Whisper-large-v3 memberikan keseimbangan terbaik antara akurasi dan efisiensi. Dari sisi akurasi, model ini hanya kalah dari arsitektur dua tahap yang memakai *rescoring* LLaMA-2 7B. Apabila bantuan model bahasa neural tersebut ditiadakan, seluruh arsitektur dua tahap justru kalah dari Whisper-large-v3, baik GRU, Conformer, maupun Transformer. Dari sisi efisiensi, Whisper-large-v3 hanya membutuhkan 3,6 GB penyimpanan. Kebutuhan ini jauh lebih kecil daripada arsitektur dua tahap mana pun. Oleh karena itu, Whisper-large-v3 menjadi pilihan paling seimbang untuk penerapan nyata.

Arsitektur dua tahap dengan *rescoring* LLaMA-2 7B memang mencapai WER dan CER terendah secara keseluruhan. WER tersebut juga lebih baik daripada *baseline* Willett et al. (2023) yang sekitar 0,174 dan hasil Seto (2025) yang sekitar 0,169. Akan tetapi, keunggulan akurasi ini ditukar dengan beban penyimpanan dan komputasi yang besar. Penyimpanannya yang sebesar 57,7 GB didominasi berkas TLG *finite state automata* dan bobot LLaMA-2 7B. Penambahan *rescoring* juga memperlambat dekode beberapa kali lipat. Hal ini terlihat dari RTF dekode GRU yang naik dari 0,0155 menjadi 0,0756.

Lebih lanjut, analisis *coverage* dan WER *oracle* pada bagian IV.4.1 menunjukkan jalur dua tahap memiliki *bottleneck* yang membatasi kinerjanya. Pada lebih dari 40% ujaran uji, transkrip referensi tidak muncul di daftar *n-best* sehingga *rescorer* tidak mungkin dapat memperbaiki ujaran-ujaran tersebut. WER *oracle* yang hanya 0,1018 menjadi batas bawah yang dapat dicapai oleh *rescorer* sebaik apa pun pada *beam* tersebut. Arsitektur E2E tidak mengalami kendala ini karena menghasilkan teks langsung tanpa representasi fonem perantara. Permasalahan *bottleneck* tersebut dapat menjadi argumen tambahan untuk pendekatan E2E di luar pertimbangan akurasi.

Dari sisi kecepatan, seluruh arsitektur sudah bekerja lebih cepat daripada waktu nyata, bahkan untuk arsitektur yang paling lambat sekalipun. Oleh karena itu, pertimbangan utama bukan kecepatan, melainkan penyimpanan dan akurasi. Pada

aspek penyimpanan, arsitektur E2E unggul jauh dengan kebutuhan 2,0 hingga 9,9 GB dibandingkan 44,2 hingga 57,8 GB pada arsitektur dua tahap. Beban penyimpanan dua tahap hampir seluruhnya berasal dari berkas TLG.fst, sedangkan dekoder fonemnya sendiri hanya berukuran ratusan *megabyte*.

Di antara arsitektur E2E, model audio yang diadaptasi melalui *cross-attention* pada umumnya mengungguli model bahasa teks dengan mekanisme LLaVA. Whisper-large-v3, Whisper-medium.en, dan Cohere Transcribe seluruhnya memiliki WER yang jauh lebih rendah daripada Qwen yang memiliki pendekatan LLaVA. Di antara model audio, model yang lebih besar memberikan akurasi yang lebih baik. Hal ini terlihat dari Whisper-large-v3 yang mengungguli Whisper-medium.en. Cohere Transcribe menjadi varian tercepat meskipun jumlah parameternya paling besar. Hal ini terjadi karena latensi dekode dipengaruhi oleh kedalaman dekoder. Pada jalur *cross-attention*, *encoder* audio bawaan FM tidak dijalankan karena keluaran *encoder* ECoG menggantikannya sehingga hanya dekoder yang berjalan secara autoregresif. Dekoder Cohere hanya memiliki 8 lapisan, sedangkan dekoder Whisper-large-v3 memiliki 32 lapisan.

Pada eksperimen dekode fonem, penambahan *spatial attention* menurunkan PER dibandingkan Conformer biasa. Hasil ini menunjukkan modul *spatial attention* membantu model menangkap dependensi antarelektroda pada sinyal ECoG yang terdiri atas banyak kanal. Kedua varian Conformer juga mengungguli GRU, sedangkan Transformer murni memiliki PER tertinggi. Oleh karena itu, modul konvolusi pada Conformer berperan penting dan Transformer murni belum cukup untuk dekode fonem dari sinyal ECoG.

Ketajaman distribusi fonem yang terukur pada bagian IV.4.1 menjelaskan mengapa GRU sedikit unggul terhadap Conformer pada dekode *5-gram* tanpa *rescoring* meskipun PER-nya lebih tinggi. Keunggulan WER GRU tersebut hilang setelah *rescoring* dengan LLaMA-2 7B. Conformer dengan *spatial attention* kembali unggul dengan WER 0,1556 dibandingkan 0,1638 milik GRU karena model bahasa neural mampu memilih hipotesis yang lebih baik dari daftar *n-best* sehingga memulihkan keunggulan akurasi fonem Conformer.

Pola panjang ujaran pada bagian IV.4.2 menunjukkan WER kedua arsitektur sama-sama menurun seiring panjang ujaran yang lebih panjang. E2E Whisper-large-v3 lebih unggul pada hampir semua panjang ujaran. Dua tahap hanya unggul pada ujaran dengan tepat 5 kata. Pola ini dapat dijelaskan oleh perbedaan jangkauan konteks kedua arsitektur. Model bahasa *5-gram* memiliki jangkauan konteks tetap, yaitu empat kata sebelumnya, sehingga model ini bekerja paling optimal tepat pada ujaran 5 kata di mana seluruh kata pendahulu masih muat di dalam jendela konteksnya. Pada ujaran yang lebih panjang, jendela *5-gram* tetap terbatas pada empat kata terakhir sehingga konteks tambahan yang dimiliki E2E menjadi keunggulan. Sebaliknya, dekoder *cross-attention* Whisper bersifat autoregresif tanpa jendela tetap sehingga setiap token yang dibangkitkan dapat memanfaatkan seluruh token yang sudah dibangkitkan sebelumnya.

Analisis tumpang tindih kesalahan pada bagian IV.4.3 menunjukkan 22,8% ujaran benar pada satu arsitektur tetapi salah pada arsitektur yang lain. Kedua arsitektur menangkap pola kesalahan yang berbeda. Jika untuk setiap ujaran selalu dipilih arsitektur dengan WER lebih rendah, WER gabungannya turun menjadi 0,1249. Nilai ini jauh di bawah WER tunggal masing-masing arsitektur dan menunjukkan potensi bagi *ensembling* untuk mengangkat akurasi melebihi tiap arsitektur tunggal sebagai arah pengembangan selanjutnya.

Arsitektur E2E pada tugas akhir ini cenderung mengalami *overfitting* karena jumlah data latih yang terbatas. Beberapa percobaan lanjutan dengan pelatihan yang lebih panjang maupun penambahan parameter tidak mampu menurunkan WER arsitektur E2E secara berarti. Hal ini menunjukkan kinerja arsitektur E2E lebih dibatasi oleh ketersediaan data daripada oleh kapasitas model. Penambahan data latih ECoG, baik melalui perekaman tambahan maupun melalui pralatih *encoder* pada data neural lintas-subjek, berpotensi meningkatkan kinerja arsitektur E2E dan dapat menjadi arah pengembangan selanjutnya.

BAB V

KESIMPULAN DAN SARAN

Bab ini memaparkan kesimpulan dari penelitian yang telah dilakukan serta saran untuk penelitian dan pengembangan selanjutnya.

V.1 Kesimpulan

Berdasarkan tujuan tugas akhir ini dan hasil pada bab sebelumnya, dapat ditarik kesimpulan sebagai berikut.

1. Arsitektur dua tahap dengan model berbasis Transformer berhasil dirancang dan diimplementasikan, serta mengungguli kinerja sistem Seto et al. (2025). Tahap pertama berupa dekoder fonem Conformer dengan *spatial attention* yang mencapai PER 0,1428 dan lebih baik daripada PER dekoder fonem GRU pada penelitian Seto et al. (2025) (PER 0,192). Sistem dua tahap dengan tambahan LLaMA-2 7B mencapai WER 0,1556 yang juga lebih baik daripada WER hasil Seto et al. (2025) sebesar 0,169. Dengan demikian, tujuan dan ukuran keberhasilan pertama telah tercapai.
2. Arsitektur *end-to-end* berbasis Foundation Model berhasil dirancang dan diimplementasikan. E2E Whisper-large-v3 dengan mekanisme *cross-attention* mencapai WER 0,1716. Nilai ini lebih baik daripada seluruh varian arsitektur dua tahap tanpa *rescoring* model bahasa neural. Penambahan *rescoring* LLaMA-2 7B memang menurunkan WER arsitektur dua tahap menjadi 0,1556 sehingga sedikit lebih baik daripada E2E. Akan tetapi, penambahan ini juga meningkatkan kebutuhan penyimpanan dari 44,2 GB menjadi 57,7 GB serta memperlambat dekode beberapa kali lipat. Sebaliknya, E2E Whisper-large-v3 hanya membutuhkan 3,6 GB penyimpanan dan tetap bekerja jauh lebih cepat daripada waktu nyata. Dengan demikian, tujuan dan ukuran keberhasilan kedua telah tercapai karena arsitektur E2E memberikan keseimbangan yang lebih baik antara akurasi, penyimpanan, dan kecepatan inferensi.

3. Analisis perbandingan antara arsitektur dua tahap dan arsitektur E2E telah dilakukan secara menyeluruh dari sisi akurasi, efisiensi, pola kesalahan, dan keterbatasan. Analisis pada Bab IV menemukan bahwa arsitektur dua tahap dengan tambahan LLaMA-2 7B mencapai akurasi tertinggi, tetapi memerlukan penyimpanan yang sangat besar, yaitu 57,7 GB. Sebaliknya, arsitektur E2E bersifat lebih ringan (2,0 hingga 9,9 GB, 3,6 GB untuk varian terbaik) dan tetap memiliki akurasi yang kompetitif. Analisis lanjutan juga menemukan bahwa kedua arsitektur saling melengkapi pada 22,8% ujaran uji, bahwa pendekatan E2E lebih unggul seiring dengan bertambah panjangnya suatu kalimat, dan bahwa pendekatan dua tahap memiliki *bottleneck* yang membatasi peningkatan akurasi melalui *rescoring*. Dengan demikian, tujuan dan ukuran keberhasilan ketiga telah tercapai.

V.2 Saran

Berdasarkan temuan dan keterbatasan penelitian ini, beberapa saran untuk penelitian dan pengembangan selanjutnya dipaparkan sebagai berikut.

1. Penambahan data latih

Pembahasan pada Bab IV menunjukkan kinerja arsitektur E2E lebih dibatasi oleh ketersediaan data daripada oleh kapasitas model. Penambahan jumlah perekaman ECoG atau pemanfaatan teknik *transfer learning* dari *encoder* yang sudah dilatih pada data neural lintassubjek berpotensi meningkatkan kinerja arsitektur E2E.

2. Pemanfaatan *ensembling* antara arsitektur E2E dan dua tahap

Analisis perbandingan kesalahan pada Bab IV menunjukkan bahwa kedua arsitektur menangkap pola kesalahan yang berbeda. Jika untuk setiap ujaran dipilih arsitektur dengan WER lebih rendah, WER gabungannya turun menjadi 0,1249. Angka ini jauh di bawah WER tunggal masing-masing arsitektur. Mekanisme *ensembling* yang dapat menyatukan kekuatan kedua arsitektur secara efektif berpotensi mengangkat akurasi setiap arsitektur secara tersendiri.

3. Pengembangan *neuroprosthesis* bicara yang *speaker-independent*

Sesuai batasan pada Bab I, penelitian ini dilakukan pada satu partisipan tunggal sehingga model belum dapat langsung dipakai pada partisipan lain. Pengembangan teknik adaptasi domain atau *pre-training* dengan data multipartisipan dapat menjadi topik penelitian selanjutnya.

4. Perluasan kosakata dan pengujian pada dataset lain

Sesuai batasan pada Bab I, penelitian ini terbatas pada kosakata yang tersedia dalam dataset Willett et al. (2023). Pengujian arsitektur pada dataset BCI lain dengan kosakata atau domain yang berbeda akan memperluas pemahaman tentang generalisasi, khususnya kemampuan Foundation Model untuk memanfaatkan pengetahuan linguistik yang dimilikinya untuk kosakata terbuka.

DAFTAR PUSTAKA

- Alayrac, J. B., et al. (2022). Flamingo: a visual language model for few-shot learning. *Advances in Neural Information Processing Systems*, 35, 23716-23736.
- Ba, J. L., Kiros, J. R., & Hinton, G. E. (2016). Layer Normalization. *arXiv preprint arXiv:1607.06450*.
- Beukelman, D. R., Fager, S., Ball, L., & Dietz, A. (2007). AAC for adults with acquired neurological conditions: A review. *Augmentative and Alternative Communication*, 23(3), 230-242.
- Bommasani, R. et al. (2021). On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*.
- Ding, N., Qin, Y., Yang, G., Wei, F., Yang, Z., Su, Y., ... & Sun, M. (2023). Parameter-efficient fine-tuning of large-scale pre-trained language models: A benchmark. *Nature Machine Intelligence*, 5(3), 220-235.
- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 1724-1734). *arXiv preprint arXiv:1406.1078*.
- Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)* (pp. 4171-4186). Association for Computational Linguistics.
- Feng, S., Liu, H., Wang, Y., & Wang, Y. (2024). Towards an End-to-End Framework for Invasive Brain Signal Decoding with Large Language Models. In *Proceedings of Interspeech 2024*. *arXiv preprint arXiv:2406.11568*.

Graves, A., Fernández, S., Gomez, F., & Schmidhuber, J. (2006). Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks. *Proceedings of the 23rd International Conference on Machine Learning*, 369-376.

Gulati, A., Qin, J., Chiu, C.-C., Parmar, N., Zhang, Y., Yu, J., ... & Pang, R. (2020). Conformer: Convolution-augmented Transformer for Speech Recognition. In *Proceedings of Interspeech 2020* (pp. 5036-5040).

Hannun, Y., et al. (2014). Deep Speech: Scaling up end-to-end speech recognition. *arXiv preprint arXiv:1412.5567*.

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). LoRA: Low-Rank Adaptation of Large Language Models. *arXiv preprint arXiv:2106.09685*.

Indefrey, P. (2011). The spatial and temporal signatures of word production components: A critical review. *Language and Cognitive Processes*, 26(9), 1349-1376.

Jiang, W.-B., Zhao, L.-M., & Lu, B.-L. (2024). Large Brain Model for Learning Generic Representations with Tremendous EEG Data in BCI. In *The Twelfth International Conference on Learning Representations (ICLR 2024)*.

Lialin, V., Deshpande, O., & Rumshisky, A. (2023). Scaling Down to Scale Up: A Guide to Parameter-Efficient Fine-Tuning. *arXiv preprint arXiv:2303.15647*.

Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). Visual instruction tuning. *Advances in Neural Information Processing Systems*, 36.

Metzger, S. L., Littlejohn, K. T., Silva, A. B., Moses, D. A., Seaton, M. P., Wang, R.,... & Chang, E. F. (2023). A high-performance neuroprosthesis for speech decoding and avatar control. *Nature*, 620(7976), 1037-1046.

Michel, C. M., & Murray, M. M. (2011). Towards the utilization of EEG as a brain imaging tool. *NeuroImage*, 61(2), 371-385.

Mohri, M., Pereira, F., & Riley, M. (2002). Weighted finite-state transducers in speech recognition. *Computer Speech & Language*, 16(1), 69-88.

Moses, D. A., Metzger, S. L., Liu, J. R., Anumanchipalli, G. K., Makin, J. G., Sun, P. F.,... & Chang, E. F. (2021). Neuroprosthesis for decoding speech in a paralyzed person with anarthria. *New England Journal of Medicine*, 385(3), 217-227.

Park, D. S., Chan, W., Zhang, Y., Chiu, C.-C., Zoph, B., Cubuk, E. D., & Le, Q. V. (2019). SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition. In *Proceedings of Interspeech 2019* (pp. 2613-2617). arXiv preprint arXiv:1904.08779.

Qwen Team. (2025). Qwen3 Technical Report. arXiv preprint arXiv:2505.09388.

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022). Robust Speech Recognition via Large-Scale Weak Supervision. arXiv preprint arXiv:2212.04356.

Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., ... & Liu, P. J. (2020). Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140), 1-67.

Schalk, G., & Leuthardt, E. C. (2011). Brain-computer interfaces using electrocorticographic signals. *IEEE Reviews in Biomedical Engineering*, 4, 140-154.

Seto, B. (2025). Implementasi dan Perbandingan Model Bahasa Berbasis N-Gram dan Transformer pada Sistem Neuroprosthesis Bicara. Institut Teknologi Bandung.

Shih, J. J., Krusienski, D. J., & Wolpaw, J. R. (2012). Brain-computer interfaces in medicine. *Mayo Clinic Proceedings*, 87(3), 268-279.

Silva, A. B., Littlejohn, K. T., Liu, J. R., Moses, D. A., & Chang, E. F. (2024). The speech neuroprosthesis. *Nature Reviews Neuroscience*, 25(7), 473-492.

Simeral, J. D., Hosman, T., Saab, J., Flesher, S. N., Vilela, M., Franco, B., ... & Hochberg, L. R. (2021). Home Use of a Percutaneous Wireless Intracortical Brain-Computer Interface by Individuals With Tetraplegia. *IEEE Transactions on Biomedical Engineering*, 68(7), 2313-2325.

Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., ... & Scialom, T. (2023). Llama 2: Open Foundation and Fine-Tuned Chat Models. *arXiv preprint arXiv:2307.09288*.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N.,... & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.

Wang, J., Zhao, S., Luo, Z., Zhou, Y., Jiang, H., Li, S., Li, T., & Pan, G. (2025). CBraMod: A Criss-Cross Brain Foundation Model for EEG Decoding. In *The Thirteenth International Conference on Learning Representations (ICLR 2025)*.

Willett, F. R., Kunz, E. M., Fan, C., Avansino, D. T., Wilson, G. H., Choi, E. Y.,... & Henderson, J. M. (2023). A high-performance speech neuroprosthesis. *Nature*, 620(7976), 1031-1036.

Zhang, Y., He, L., Fan, C., Liu, T., Yu, H., Le, T., Li, J., Linderman, S., Duncker, L., Willett, F. R., Mesgarani, N., & Paninski, L. (2025). A cross-species neural foundation model for end-to-end speech decoding. *arXiv preprint arXiv:2511.21740*.